

3. 基礎数学

3.1 システムズアナリシス

社会の中の人、モノ、資源などの要素はそれぞれ独立に変化しているわけではなく、複雑な相互作用の中で時間とともに変化し、結果的に釣合いのとれた状態に落ち着くことが多い。もちろん、落ち着き先の状態は一つではなく、複数の状態から選ばれることもある。このように社会の中の一部を、複数の要素とその相互作用から作られるシステムとみなし、その状態や変化、制御の方法を論理的に究明する方法がシステムズアナリシス (systems analysis) であり、3.1 節ではそのうち、数学的な解析手法を紹介する。

土木工学を含む工学では、なんらかの目的を達成するためのものや仕組みを提案することを目指すため、往々にして「目的にかなうように、限られた人員や資源をいくつかのものに配分したり、異なる作業にどう割り当てべきか」という問題に直面する。これに答えるための数学的手法が3.1.1 項のオペレーションズリサーチ (operations research, OR) である。土木計画が対象とする社会システムの状態はわれわれが直接操作できない各種の要素の影響を受ける。そのため、将来の状態を確定的に知ることはできない中で、判断や意思決定を行う上では、複数の取り得る状態と確率の組合せを考えることが有用である。3.1.2 項では、確率モデル (stochastic model) と意思決定論 (decision-making theory) について述べる。さらに、3.1.3 項では、将来のシステムの状態を予測するためのシミュレーション手法を解説する。

システムズアナリシス手法はコンピューターや計算技術とともに急速に進歩しつつある。土木計画での応用に当たっては、実際に取り扱うシステムや意思決定問題の性質をよく吟味し、適切な手法を選択することが必要となる。本節ではその基礎となるよう、代表的なシステムズアナリシス手法の考え方の解説に重点を置き、必要に応じて節末の引用・参考文献に沿って理解を深めていただくことを期待する。

3.1.1 OR

(1) 線形計画法^{1)~3)}

土木計画学に限らず、工学の分野では、なんらかの

制約条件の下で最適な計画を策定しなければならない場面が多くある。例えば、与えられた材料に上限があるという制約条件の下で利益を最大にする製品の生産量を求めたり、求められる性能を満たすという制約条件の下で費用を最小にする製品の設計を求めたりするようなものである。

このような問題を一般に数理計画問題 (mathematical programming problem) と呼ぶ。このとき、最適化のために最大化あるいは最小化する関数を目的関数 (objective function)、変数が変化する範囲を定めている関数を制約条件 (constraint) と呼ぶ。このうち、目的関数、制約条件のいずれもが線形関数で表されるものを線形計画問題 (linear programming problem) と呼び、目的関数、制約条件のいずれかが線形関数ではないものを非線形計画問題 (nonlinear programming problem) と呼ぶ (表 3.1 参照)。

表 3.1 数理計画問題の分類

		制約条件	
		線形	非線形
目的関数	線形	線形計画問題	
	非線形	非線形計画問題	

もちろん、土木計画学で取り扱う現実の計画問題が、すべてこのような単純化した数理計画問題として表せるわけではないが、ある程度の単純化を許容して数学的に解ける問題とすることにより、合理的な計画を策定するための方法論として利用することができる。

(1) 線形計画問題の定式化 数理計画問題のうち、線形計画問題を解く方法を線形計画法 (linear programming) と呼ぶ。

例として、以下のような問題を考える。

2 種類の材料 A, B を用いて、2 種類の製品 S, T を生産する。製品 S を 1 kg 生産するためには材料 A, B がそれぞれ 3 kg, 5 kg 必要であり、製品 T を 1 kg 生産するためには材料 A, B がそれぞれ 4 kg, 2 kg 必要である。また、利用できる材料 A, B には上限があり、それぞれ 480 kg, 520 kg である。製品 S の利益が 1 kg 当り 90 万円、製品 T の利益が 1 kg 当り 60 万

円であるとき、利益が最大となるような製品 S, T の生産量を求めたい。

製品 S, T の生産量をそれぞれ x_1, x_2 とすると、この問題の目的関数は以下ようになる。

$$z = 90x_1 + 60x_2 \rightarrow \max \quad (3.1)$$

また、この問題の制約条件は以下ようになる。

$$\left. \begin{aligned} 3x_1 + 4x_2 &\leq 480 \\ 5x_1 + 2x_2 &\leq 520 \\ x_1 &\geq 0 \\ x_2 &\geq 0 \end{aligned} \right\} \quad (3.2)$$

式 (3.1) の z は、製品 S, T の生産量がそれぞれ x_1, x_2 であった場合の利益を表しており、式 (3.1) はこれを最大化することを表している。また式 (3.2) は、利用できる材料 A, B の上限がそれぞれ 480 kg, 520 kg であること、製品 S, T の生産量は 0 または正の値であることを表している。

このように、目的関数、制約条件のいずれもが線形関数で表される線形計画問題をより一般的に表すと、以下ようになる。

$$z = c_1x_1 + \cdots + c_nx_n \rightarrow \max \quad (3.3)$$

$$\left. \begin{aligned} a_{11}x_1 + \cdots + a_{1n}x_n &\leq b_1 \\ a_{21}x_1 + \cdots + a_{2n}x_n &\leq b_2 \\ &\vdots \\ a_{m1}x_1 + \cdots + a_{mn}x_n &\leq b_m \\ x_1, \cdots, x_n &\geq 0 \end{aligned} \right\} \quad (3.4)$$

線形計画問題において、制約条件をすべて満たす変数の値を**実行可能解** (feasible solution) と呼び、そのうち目的関数を最大化 (あるいは最小化) する変数の値を**最適解** (optimal solution) と呼ぶ。

(2) **図解法** 変数が二つの場合、図解法を用いて解くことが可能である。先の例題の場合、横軸に x_1 、縦軸に x_2 をとり、制約条件となる式 (3.2) を図示すると、図 3.1 のようになる。図中の網掛け部分が制約条件をすべて満たす変数 x_1, x_2 の範囲であり、これを**実行可能領域** (feasible region) と呼ぶ。ここで、実行可能領域を表す四角形の各辺は、それぞれ式 (3.2) の四つの不等式の不等号を等号とした場合の直線に相当している。

式 (3.1) の目的関数を変形すると $x_2 = (-3/2)x_1 + (z/60)$ となり、 $x_1 - x_2$ 平面上では傾き $-3/2$ 、切片 $z/60$ の直線となる。これを図 3.1 に重ねて描いたものが図 3.2 である。 z の値の大小によって切片の値が変化するため、 z の値によっては直線が実行可能領




図 3.1 実行可能領域




図 3.2 実行可能領域と目的関数

域を通過しない場合も存在する。

制約条件を満たす範囲で目的関数を最大にするためには、直線が実行可能領域と交差するか接する範囲で z の値が最も大きくなる場合、すなわち切片の値が最も大きくなる場合を探索すればよい。この例題では、図 3.3 のように実行可能領域を表す四角形の端点 $(80, 60)$ で z の値が最も大きくなるため、この点が最適解となる。また式 (3.1) より、このときの z の




図 3.3 最適解

値は10800である。すなわち、利益を最大にする生産量は製品Sが80kg、製品Tが60kgであり、このときの利益は10800万円であることがわかる。

線形計画問題では目的関数、制約条件のいずれもが線形関数で表されるため、変数が二つの場合、目的関数は直線、実行可能領域は凸多角形で表されることになる。このため、最適解は実行可能領域の内側に存在することはなく、実行可能領域の外周部分に存在する。目的関数の直線の傾きと制約条件の直線（実行可能領域の多角形の辺）の傾きが異なるという通常の場合には、図3.3のように最適解は実行可能領域を表す多角形の端点の一つとなる。ただし、目的関数の直線の傾きと制約条件の直線の傾きがたまたま等しい場合には、最適解は実行可能領域を表す多角形の一つの辺全体（両側の端点を含む）となることがある。

この性質は変数が三つ以上の場合でも同様であり、線形計画問題では、最適解は実行可能領域の端点、あるいは同じ目的関数値を持つ端点を結ぶ線、または平面となることがわかっている。

(3) シンプレックス法 図解法は簡便であるが、変数が三つ以上になると用いることができない。そこで上記のように、最適解が実行可能領域の端点となることを利用して、機械的に最適解を求めようという方法がシンプレックス法（単体法）(simplex method)である。

先の例題の場合、実行可能領域は四角形で表され、四角形の各辺は、式(3.2)の四つの不等式の不等号を等号と置いた場合に相当している。すなわち、実行可能領域の端点は、式(3.2)の四つの不等式のうち二つを等号とし、他の二つが不等号になっている場合に相当している。

これを解くため、式(3.2)の不等式を、スラック変数 (slack variable) λ_1, λ_2 を用いて等式に変換する。

$$\left. \begin{aligned} 3x_1 + 4x_2 + \lambda_1 &= 480 \\ 5x_1 + 2x_2 + \lambda_2 &= 520 \\ x_1 &\geq 0 \\ x_2 &\geq 0 \\ \lambda_1 &\geq 0 \\ \lambda_2 &\geq 0 \end{aligned} \right\} \quad (3.5)$$

なお、一般式の場合には、式(3.4)の不等式を式(3.6)のように等式に変換する。

$$\left. \begin{aligned} a_{11}x_1 + \cdots + a_{1n}x_n + \lambda_1 &= b_1 \\ a_{21}x_1 + \cdots + a_{2n}x_n + \lambda_2 &= b_2 \\ &\vdots \\ a_{m1}x_1 + \cdots + a_{mn}x_n + \lambda_m &= b_m \\ x_1, \cdots, x_n &\geq 0 \\ \lambda_1, \cdots, \lambda_m &\geq 0 \end{aligned} \right\} \quad (3.6)$$

これを先の図解法と比較すると、実行可能領域の端点は変数 x_1, x_2 およびスラック変数 λ_1, λ_2 のうち二つが0、他の二つが正の値となっている場合に相当している。このとき、正の値となっている変数を**基底変数** (basic variable)、0となっている変数を**非基底変数** (non-basic variable) と呼ぶ。この組合せの数は C_2 すなわち6通りであるから、この中から実行可能領域に含まれ、かつ目的関数の値が最も大きくなるものを探索すればよいことになる。

しかしながら、変数や制約条件の数が多き場合にはこの組合せの数は大きくなるため、すべての組合せに対して目的関数の値を求めて探索することは困難である。そのため、変数 x_1, x_2 およびスラック変数 λ_1, λ_2 のうち二つを基底変数に選び、他の二つを非基底変数とした初期実行可能解を作成して、そこから目的関数の値が大きくなるように基底変数と非基底変数を入れ替えていくこととする。

シンプレックス法の計算手順は以下のとおりである。

まず、目的関数、制約条件の係数を基に、表3.2のようなシンプレックス表を作成する。

表3.2 シンプレックス表（初期実行可能解）

基底変数	基底変数の値	x_1	x_2	λ_1	λ_2	θ
λ_1	480	3	4	1	0	
λ_2	520	5	2	0	1	
z	0	-90	-60	0	0	

つぎに、 z 行の値が負で絶対値が最も大きな値の列を選択する。この列にある変数の値を増加させることによって目的関数の値を増加させることができる。各行について、この列の値で基底変数の値を割り、その結果を θ の列に記入する。この値はこの変数の値を増加させるときに実行可能領域に含まれる上限値を表しており、この中から正で最も小さな値となる行を選択する。選択した列と行の交点をピボットとして、この値を1に、同じ列の他の値を0にするような掃出し計算を行う。これにより、基底変数と非基底変数を入

れ替えることができる。

この計算を、 z 行の値がすべて 0 または正の値となるまで繰り返す。 z 行の値がすべて 0 または正の値となった場合には、目的関数の値をこれ以上増加させることができないため、この時点での変数の値が最適解となる。

先の例題の場合、表 3.3 のような計算過程となる。なお、表中の網掛け部分が上記の計算過程で選択された列と行であり、その交点がピボットである。最終段階での基底変数とその値を見ると、基底変数が x_1 , x_2 でそれぞれの値が 80 と 60、また目的関数 z の値は 10 800 となっており、図解法による最適解と合致していることがわかる。

表 3.3 シンプレックス表 (計算過程)

基底変数	基底変数の値	x_1	x_2	λ_1	λ_2	θ
λ_1	480	3	4	1	0	160
λ_2	520	5	2	0	1	104
z	0	-90	-60	0	0	
λ_1	168	0	14/5	1	-3/5	60
x_1	104	1	2/5	0	1/5	260
z	9 360	0	-24	0	18	
x_2	60	0	1	5/14	-3/14	
x_1	80	1	0	-1/7	2/7	
z	10 800	0	0	24	18/5	

また、計算過程における基底変数とその値を見ると、初期実行可能解は (0, 0)、そのつぎの実行可能解は (104, 0)、最適解は (80, 60) に対応しており、図解法における実行可能領域の端点を順に移動していることがわかる。

このように、シンプレックス法であれば、変数や制約条件の数が多く場合であっても機械的に最適解を求めることができる。ここでは目的関数が式 (3.3)、制約条件が式 (3.4) に表されるような標準形の線形計画問題を対象としているが、その他の形式、例えば目的関数を最小化する問題である場合、等式の制約条件がある場合、制約条件の不等号の向きが逆である場合などにも、技巧変数や罰金と呼ばれる数を導入することにより、シンプレックス法を用いて最適解を求めることが可能である。

(4) その他の解法 線形計画問題を解く方法には、図解法、シンプレックス法以外にも、内点法 (interior point method) などがある。内点法は非線形計画問題にも適用することが可能である。 (小川圭一)

[2] その他の数値計画法^{4)~6)}

数値計画問題は多様で、その目的関数および制約条件の特徴に応じて、各種の解法が提案されている。前述された線形計画法は、その一例として位置付けられる。ここでは、その他の数値計画問題として、非線形計画問題 (nonlinear programming problem) から、形式に特定の特徴がある代表的な問題について記述する。

(1) 非線形計画問題の定式化 数値計画問題では、制約条件で規定される実行可能領域において、計画者の価値判断が表現された目的関数を最適化 (最大化あるいは最小化) する解 $x = (x_1, \dots, x_n)$ を求めることが要求される。目的関数あるいは制約条件のいずれかが非線形関数で記述される場合には、非線形計画問題となる。目的関数 $f(x_1, \dots, x_n)$ を最小化する非線形計画問題の基本型は、以下のように定式化される。

$$\min f(x_1, \dots, x_n) \quad (3.7)$$

$$\text{subject to } g_m(x_1, \dots, x_n) \leq 0 \quad (m=1, \dots, M) \quad (3.8)$$

$$h_j(x_1, \dots, x_n) = 0 \quad (j=1, \dots, J) \quad (3.9)$$

式 (3.8) は不等式制約を、式 (3.9) は等式制約を表し、不等式制約のみ、等式制約のみが与えられる場合もある。また、これらの制約条件のない場合もある。これらの制約条件に加えて、以下のような変数の非負条件が制約として与えられる場合もある。

$$x_1 \geq 0, \dots, x_i \geq 0, \dots, x_n \geq 0 \quad (i=1, \dots, n) \quad (3.10)$$

(2) 局所最適解と大域的最適解 代表的な形式の非線形計画問題として、目的関数が実行可能領域内において連続で微分可能である場合を考える。例として、図 3.4 に示すような一変数の目的関数 $f(x)$ を持つ最小化問題を取り上げる。




図 3.4 局所解と大域解

この問題では、目的関数に対する接線の傾き (微分係数) が 0 となる停留点のうち、その点の近傍で接線の傾きが単調増加する場合に、極小値を与える点となり、解の候補となる。このように極小値を与える点を

局所最小解 (local minimum solution) という。例えば、図 3.4 では a, d のように局所最小解が複数存在する。制約条件がない場合には、局所最小解が複数存在すれば、そのうちの少なくとも 1 点が **大域的最低解** (global minimum solution) となる。したがって、最小化問題ではまず局所最小解を与える条件 (局所最適性の条件) が重要となる。

(3) **局所最適性の条件** 実行可能領域内において連続で二階微分可能な変数の目的関数 $f(x)$ の最小化問題では、局所最小解 x^* が満たすべき必要条件は、微分係数が 0 であり、かつ、二階微分係数が非負であることを表す式 (3.11) のように整理できる。

$$\frac{df(x^*)}{dx} = 0 \quad \text{and} \quad \frac{d^2f(x^*)}{dx^2} \geq 0 \quad (3.11)$$

同様に、実行可能領域内において連続で二階偏微分可能な多変数の目的関数 $f(x_1, \dots, x_n)$ の場合には、局所最小解 x^* が満たすべき必要条件は、**勾配ベクトル** (gradient vector) ∇f が 0 であることを表す式 (3.12) および二階偏微分行列 (Hessian 行列) $\nabla^2 f$ が非負定値行列であることを表す式 (3.13) で規定される。

$$\nabla f(x^*) = \left(\frac{\partial f(x^*)}{\partial x_1}, \dots, \frac{\partial f(x^*)}{\partial x_n} \right)^T = 0 \quad (3.12)$$

$$(u_1, \dots, u_n) \begin{bmatrix} \frac{\partial^2 f(x^*)}{\partial x_1^2} & \dots & \frac{\partial^2 f(x^*)}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f(x^*)}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 f(x^*)}{\partial x_n^2} \end{bmatrix} \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} \geq 0 \quad (3.13)$$

ここで $(u_1, \dots, u_n)$ は任意の微小ベクトルである。

(4) **凸計画問題とその最適解の種類** 実行可能領域が**凸集合** (convex set) であり、かつ目的関数が実行可能領域内で**凸関数** (convex function) である場合の非線形計画問題を凸計画問題と呼ぶ。実行可能領域内の任意の 2 点を結ぶ線分上の任意の点が、その領域内に含まれていることを凸集合の定義とする。また、領域内の任意の 2 点 x_a および x_b について、 $0 < \lambda < 1$ を満たす任意 λ が与えられたとき、目的関数 f に対してつねに式 (3.14) が成立するとき、目的関数 f を凸関数であると定義する。

$$f(\lambda x_a + (1-\lambda)x_b) \leq \lambda f(x_a) + (1-\lambda)f(x_b) \quad (3.14)$$

さらに連続で二階偏微分可能な多変数の目的関数が凸関数であることは、実行可能領域内の任意の点で式 (3.13) が成立し、Hessian 行列 $\nabla^2 f$ が非負定値行列であることと同値である。また、式 (3.13) の非負

定値条件の成立は、Hessian 行列 $\nabla^2 f$ のすべての固有値が非負であることと同値である。したがって、固有値の非負条件の成立は、目的関数 f が凸関数であることと同値となる。

つぎに、実行可能領域との関係により最適解を分類する。ここでは例として、図 3.5 に示すような変数の凸関数 $f(x)$ を目的関数とする最小化問題を取り上げる。目的関数が凸関数である場合、局所最小解は式 (3.11) を満たせばよい。まず制約条件がない問題では、この局所最小解 x_A^* が大域的最低解となる。




図 3.5 内点解と端点解

つぎに、制約条件により実行可能領域が規定される場合を考える。図 3.5 の実行可能領域 A のように、その中に局所最小解 x_A^* が含まれる場合、局所最小解 x_A^* は大域的最低解であり、これを内点解と呼ぶ。一方で、実行可能領域 B のように、その中に極小値を与える点が存在しない場合、最適解は実行可能領域の境界となり、端点解と呼ぶ。このように、凸計画問題では、内点解あるいは端点解を求めることになるが、いずれもシステムティックに求解可能である。


一方、目的関数が凸関数でない場合には、凸関数として扱えるように実行可能領域を適当に分割し、分割後の領域内でそれぞれ最適解となる点を求め、それらの点から大域的最低解を探索すればよい。

(5) 不等式制約付き凸計画問題の最適性条件


目的関数が多変数の二階微分可能な凸関数であり、すべての変数に非負制約 ($x_i \geq 0$) があり、不等式制約により実行可能領域が凸集合となる最小化問題を考える。多変数の場合においても、最適解が内点解と端点解になる場合があり、それらが満たすべき条件 (最適性条件) は相違する。ここでは、二変数 (x_1 および x_2) で表される目的関数 $f(x_1, x_2)$ および 2 種類の制約条件 $g_1(x_1, x_2)$ および $g_2(x_1, x_2)$ を持つ最小化問題を例として、最適性条件を整理する。

最適解と実行可能領域の位置関係で場合分けした 4 種類のケースにおける目的関数の勾配ベクトルを図

3.6 (a)~(d) に示す。すなわち、図 (a)：内点解で実行可能領域の境界線を除く内部に解が存在する場合、図 (b)：制約条件式で表される領域境界線上（線分 pq または線分 qr ）の内分点 s が解となる場合、図 (c)：端点解で領域の境界線の交点（点 q ）が解となる場合、図 (d)：領域境界線と非負制約を表す軸線との交点（点 p または点 r ）が解となる場合、に分類して考える。



(a) 内点解：領域境界線を除く内部の点が解となる例 (b) 領域境界線上の点が解となる例



(c) 端点解：領域境界線の交点が解となる例 (d) 端点解：領域境界線の端点が解となる例

図 3.6 制約付き問題の最適性条件の整理

図 (a) 実行可能領域の境界線を除く内部に解が存在する場合には、目的関数の勾配ベクトル ∇f が 0 となることが最適解の条件となる。したがって、式 (3.12) が成立する。

図 (b) 不等式制約 g_l による実行可能領域境界線上の内分点が最適解 x^* となる場合には、その点で目的関数の等高線と領域境界線が接することになる。すなわち、目的関数の勾配ベクトルと有効な制約条件 g_l の勾配ベクトルは同一方向となるため、係数 λ_l^* の値を適切にとれば、式 (3.15) が成立する。

$$\frac{\partial f(x^*)}{\partial x_i} = \lambda_l^* \frac{\partial g_l(x^*)}{\partial x_i} \quad (i=1, \dots, n) \quad (3.15)$$

図 (c) 端点解で、実行可能領域境界線の交点が最適解 x^* となる場合には、目的関数の勾配ベクトルが有効な制約条件の勾配ベクトルの間に位置することになる。したがって、この場合、係数 λ_m^* の値を適

切にとれば、目的関数の勾配ベクトルが、制約条件の勾配ベクトルの非負線形結合で表される。

$$\frac{\partial f(x^*)}{\partial x_i} = \sum_{m=1}^M \lambda_m^* \frac{\partial g_m(x^*)}{\partial x_i} \quad (i=1, \dots, n) \quad (3.16)$$

図 (d) 端点解で、不等式制約 g_l による領域境界線上にあり、変数 x_k の非負制約条件との交点が最適解 x^* となる場合、式 (3.17) が成立する。

$$g_l(x^*) = 0 \text{ and } x_k^* = 0 \quad (3.17)$$

(6) 不等式制約付き凸計画問題の解法 以上の最適解と実行可能領域の位置関係に着目した分類ごとに導出された最適性条件を、統一的に表すことを考える。ここで式 (3.8) の不等式制約 g_m に対応したラグランジュ乗数 (Lagrange multiplier) λ_m を用いて、式 (3.18) のように定義されるラグランジュ関数 (Lagrange function) を導入する。

$$L(x, \lambda_1, \dots, \lambda_M) = f(x) - \sum_{m=1}^M \lambda_m g_m(x) \quad (3.18)$$

このラグランジュ関数を変数 x_i により偏微分すると、式 (3.19) が得られる。

$$\frac{\partial L(x, \lambda)}{\partial x_i} = \frac{\partial f(x)}{\partial x_i} - \sum_{m=1}^M \lambda_m \frac{\partial g_m(x)}{\partial x_i} \quad (i=1, \dots, n) \quad (3.19)$$

ここで、図 (c) 実行可能領域境界線の交点が解となる場合には、ラグランジュの未定乗数 λ_m を適切な値 λ_m^* と置くと、最適解 x^* について式 (3.16) が成立する。このため、式 (3.16) および式 (3.19) より、式 (3.20) に示すようにラグランジュ関数の勾配ベクトルが 0 となることがわかる。

$$\frac{\partial L(x^*, \lambda^*)}{\partial x_i} = \frac{\partial f(x^*)}{\partial x_i} - \sum_{m=1}^M \lambda_m^* \frac{\partial g_m(x^*)}{\partial x_i} = 0 \quad (i=1, \dots, n) \quad (3.20)$$

この式 (3.20) において、 $\lambda_m^* = 0$ ($m=1, \dots, M$) とすれば式 (3.12) となり、 $m=l$ の場合を除いて $\lambda_m^* = 0$ とすれば、式 (3.15) が導出できる。したがって、図 (a) 実行可能領域の境界線を除く内部に解が存在する場合 (内点解)、および、図 (b) 不等式制約 g_l の領域境界線上の内分点が解となる場合にも、係数 λ_m^* の値を適切にとれば、式 (3.20) は成立する。また、図 (d) 不等式制約 g_l による領域境界線上にあり ($g_l(x^*) = 0$)、変数 x_k の非負制約条件が有効 ($x_k^* = 0$) となる場合においても、 $i=k$ の場合を除いて式 (3.20) が成立する。したがって、これらをまとめると以下のような相補条件 (complementary condition) として整理できる。

$$x_i^* = 0 \quad \text{or} \quad \frac{\partial L(x^*, \lambda^*)}{\partial x_i} = 0 \quad (i=1, \dots, n) \quad (3.21)$$

$$\lambda_m^* = 0 \quad \text{or} \quad g(x^*) = 0 \quad (m=1, \dots, M) \quad (3.22)$$

以上より、最適解が満たすべき必要十分条件は、式(3.23)～(3.26)に示される **Karush-Kuhn-Tucker 条件** が満たされることである。

$$x_i^* \frac{\partial L(x^*, \lambda^*)}{\partial x_i} = 0 \quad (i=1, \dots, n) \quad (3.23)$$

$$x_i^* \geq 0, \quad \frac{\partial L(x^*, \lambda^*)}{\partial x_i} \leq 0 \quad (i=1, \dots, n) \quad (3.24)$$

$$\lambda_m^* \frac{\partial L(x^*, \lambda^*)}{\partial \lambda_m} = -\lambda_m^* g_m(x^*) = 0 \quad (m=1, \dots, M) \quad (3.25)$$

$$\lambda_m^* \geq 0, \quad g_m(x^*) \leq 0 \quad (m=1, \dots, M) \quad (3.26)$$

ここまで、二変数を前提に最適性条件を整理したが、この Karush-Kuhn-Tucker 条件は二変数以上の場合でも成立する。このため、Karush-Kuhn-Tucker 条件で表される連立方程式を解くことで、最適解 x^* および最適なラグランジュ乗数 λ^* が求められる。

(7) **等式制約付き凸計画問題の解法** 等式制約だけの非線形計画問題は、不等式制約付き問題の領域境界線上に解がある場合と同様に考えることができる。したがって、等式制約付き凸計画問題の最適解をシステマティックに導出する方法として、**ラグランジュの未定乗数法** (Lagrange multiplier method) が適用可能である。ここでラグランジュ関数は、式(3.9)の等式制約および等式制約 h_j に対応したラグランジュ未定乗数 λ_j を用いて、式(3.27)のように定義される。

$$L(x, \lambda_1, \dots, \lambda_J) = f(x) - \sum_{j=1}^J \lambda_j h_j(x) \quad (3.27)$$

ここで最適解 x^* は、式(3.20)の不等式制約 g_m を等式制約 h_j に置き換えた式(3.28)を満たす。

$$\frac{\partial L(x^*, \lambda^*)}{\partial x_i} = \frac{\partial f(x^*)}{\partial x_i} - \sum_{j=1}^J \lambda_j^* \frac{\partial h_j(x^*)}{\partial x_i} = 0 \quad (i=1, \dots, n) \quad (3.28)$$

したがって、最適解 x^* においては、ラグランジュ関数の勾配ベクトルが0となる。この式(3.28)および等式制約式(3.9)で構成される連立方程式を解けば、最適解 x^* および最適なラグランジュ乗数 λ^* が求められる。

(8) **鞍点定理** 凸計画問題において、ラグランジュ関数 L に最適解 x^* および最適なラグランジュ乗数 λ^* を代入すると、相補条件により式(3.25)が成立しているので、目的関数 f の最適値が得られる。

$$L(x^*, \lambda^*) = f(x^*) \quad (3.29)$$

図3.7に示すように、ラグランジュ関数 L のラグランジュ乗数を λ^* に固定した場合、関数 $L(x, \lambda^*)$ は下向きに凸関数となり、制約条件なしでの x に関する最小化問題 $\min L(x, \lambda^*)$ の解は、目的関数 f の最小化問題の最適解 x^* と一致する。一方、ラグランジュ関数 L の変数を x^* に固定した場合、ラグランジュ乗数 λ を変数とした関数 $L(x^*, \lambda)$ は凸関数となり、制約条件なしでの λ に関する最大化問題 $\max L(x^*, \lambda)$ の解は、目的関数 f の最小化問題の最適解 x^* と一致する。以上より、式(3.30)に示す鞍点定理が成立する。

$$L(x^*, \lambda) \leq L(x^*, \lambda^*) \leq L(x, \lambda^*) \quad (3.30)$$

したがって、最適解 x^* は、ラグランジュ関数の停留点である。




図3.7 ラグランジュ関数の停留点

(9) **数値計画問題の数値解法** 変数あるいは制約条件が多数ある数値計画問題では、コンピュータを用いて数値解を求める場合も多い。制約条件のない凸計画問題には、最急降下法、ニュートン・ラフソン法、共役勾配法などの数値解法が適用できる。例えば最急降下法では、当該点 $x^{[l]}$ に対して、[1] 負の勾配ベクトルを降下方向とし、[2] 降下方向で目的関数値が最小となる係数 α を求め、[3] 式(3.31)により解を更新する。

$$x^{[l+1]} = x^{[l]} - \alpha \nabla f(x^{[l]}) \quad (3.31)$$

この過程を繰り返し、目的関数の勾配ベクトル $\nabla f(x^{[l]})$ が0に収束するまで探索を行う。ニュートン・ラフソン法では、Hessian 行列 $\nabla^2 f$ の逆行列を用

いた式 (3.32) で解の更新を行うことで、収束計算の効率を高めている。

$$x^{[l+1]} = x^{[l]} - [\nabla^2 f(x^{[l]})]^{-1} \nabla f(x^{[l]}) \quad (3.32)$$

制約条件がある凸計画問題には、逐次二次計画法、ペナルティ関数法などが適用できる。逐次二次計画法では、探索方向ベクトルを変数とし、ラグランジュ関数をテイラー展開した二次近似を目的関数、制約条件を一次近似した最小化問題を解いて、探索方向が決定される。このように、凸計画問題の数値解法では、勾配ベクトルに基づいて探索方向を決め、逐次的に解を更新していく計算法となっている。(奥嶋政嗣)

〔3〕 メタヒューリスティクス

(1) 近似的な解と解法 土木計画の分野における、公共施設の最適配置問題、交通ネットワーク上の起終点間の最短経路(最小費用経路)問題や、起点からの最短巡回路問題などは、数理計画の分野においては、**組合せ最適化問題**(combinatorial optimization problem)として、取り扱うことができる。これらの問題は、0か1かをとるような、もしくは、整数値をとるような、**離散変数**(discrete variable)を含む最適化問題として定式化できることが多い。一般に、組合せ最適化問題は、有限個の**実行可能解**(feasible solution)(以下、単に解と呼ぶ)から成る実行可能集合の中から、目的関数の値が最小もしくは最大となる解、すなわち、**大域的最適解**(global optimal solution)を見つける問題である。

組合せ最適化問題においては、解の数が有限なので、すべての解について目的関数の値を計算して列挙する**列挙法**(enumeration method, complete enumeration)を用いれば、必ず大域的最適解が見つかる。しかし、列挙法は、変数が多くなり組合せ数が増大すると、計算時間の面から使用できなくなる。**分枝限定法**(branch and bound method)や**動的計画法**(dynamic programming)も、組合せ最適化問題の大域的最適解を求める方法、すなわち、**厳密解法**(strict solution method, exact solution method)であるが、これらの方法も本質的には列挙法であるので、計算量が問題の大きさに対して指数関数的に増加する問題、いわゆる**NP困難**(NP (nondeterministic polynomial time)-hard)な問題に対しては、組合せ数が大きくなると、適用できない。

一般に、NP困難な問題に対しては、最適解を求めることをあきらめて、現実的な計算時間内で実行可能解、すなわち、**近似解**(あるいは、**近似最適解**(approximate solution))を求めることになる。その際に使用される解法には、**近似解法**(approximation algorithm, approximation method)と**ヒューリスティクス**(ある

いは、**ヒューリスティック解法**、**発見的解法**(heuristics))がある。両者に明確な定義はないが、例えば、上界や下界など、解の精度保証があるアルゴリズム(計算法)を近似解法と呼び、精度保証がないものをヒューリスティクスと呼んで区別されることがある。ただし、近似解法とヒューリスティクスのいずれであっても、優れたアルゴリズムとは、最適解に近い高精度な解を、比較的小さな計算時間で効率的に求めるものを指す。

ヒューリスティクスは、発見的解法とも呼ばれるように、対象とする問題に対して、経験や知見を通して解を見つける、あるいは、解を改善するアルゴリズムの総称である。ヒューリスティクスとは、いわば、対象とする問題の性質や構造を熟慮して、その問題のためにカスタマイズされた近似解法である。

ヒューリスティクスを用いて得られた近似解に対して、追加的で部分的な修正を繰り返し実施すると、近似解の精度が向上すること、すなわち、最適解に近づくことが多い。そのような戦略を有する基本アルゴリズムの総称が、**メタヒューリスティクス**(metaheuristics)である。つまり、メタヒューリスティクスは、ヒューリスティクスに操作を追加して、多くの問題を扱えるように汎用性を高めたアルゴリズムである。この追加的操作がまたヒューリスティクスであることも多く、ヒューリスティクスを有機的に結合したアルゴリズムともいえる。ヒューリスティクスを核としたさまざまな手法の集合体であること、ないしは、ヒューリスティクスがヒューリスティクスを内包すること、すなわち、メタ構造を有する手法であることから、「メタ」ヒューリスティクスと称される。

(2) **アルゴリズムの特徴** 上述のように、複数の手法を内包した構造であるので、メタヒューリスティクスに属するアルゴリズムは一般的に、多くの操作とパラメーターを含む。したがって、その性能は、実装する操作や設定するパラメーターの値に大きく左右される。近似解法やヒューリスティクスと比較して、メタヒューリスティクスは、汎用性を有するので、当然ながら、連続変数から成る最適化問題や、パターン認識問題にも適用可能である。ただし、ヒューリスティクスと同様に、メタヒューリスティクスに属するアルゴリズムがもたらす解の精度には、理論的な保証はなく、アルゴリズムの理論的説明もそれほど進んではいない。

メタヒューリスティクスには、アルゴリズムの終了条件をユーザーが定めることができる、すなわち、計算終了時間を自由に制御できる特性がある。多数の解を生成、評価し、その中で最良の解を出力するので、

計算時間をかければかけるほど、良い解（精度の高い解）を探索できる可能性が高くなる。そのため、コンピュータの演算速度が、アルゴリズムの性能に強い影響を及ぼす。また、ランダム性や確率性を有する操作が包含されるので、到達する近似解は、試行回によって異なる可能性がある。

メタヒューリスティクスでは、基本的に、過去に探索した履歴を基にして新しい解を生成する操作と、生成された解を評価してつぎの解の探索に必要な情報を抽出する操作を含み、両操作の反復からアルゴリズムが構成される。前者の操作において、効果的に探索するために、**集中化**(intensification)と**多様化**(diversification)が活用される。集中化とは、良い解の近傍には、より良い解が存在する可能性が高いという概念に基づいて、良い解の周辺を集中的に探索することである。集中化は、ヒューリスティクスの代表的なアルゴリズムである**局所探索法**(local search, あるいは、**近傍探索法**(neighborhood search)、**山登り法**もしくは**丘登り法**(hill climbing method))に類似する。それゆえ、メタヒューリスティクスに属するアルゴリズムの大半は、局所探索法を拡張したものともみなせる。局所探索法では、任意の解 x の一部を修正して得られる解の集合を近傍 $N(x)$ として、 $N(x)$ の中で目的関数の値を改善できるものがあれば、それに置き換えるという操作を繰り返す。目的関数の値を改善できるものがなければ計算を終了する。この手順は、**局所解**（あるいは、**局所最適解**、**局所的最適解**(local optimal solution))の定義そのものであるので、局所探索法で得られる解は、最適解ではなく、局所解である。

集中化だけでは、狭い領域内で、もはや改善しようのない状態になり、悪い（精度の低い）局所解に陥る可能性がある。多様化は、局所解の周辺で探索が停滞することを避けるために、集中的に探索した空間とは異なる空間へと探索を強制的に遷移させる操作である。メタヒューリスティクスが、高精度な解を効率的に発見できるのは、集中化と多様化をバランスよく実現しながら解の探索を行うためである。集中化と多様化を実現する方法にはさまざまなものがあり、その設計や選択がアルゴリズムの性能に大きな影響を及ぼす。

メタヒューリスティクスに属するアルゴリズムは、単一の解を保持しながら探索するか、あるいは、複数解を保持しながら探索するかで区別できる。また、改善型か構築型かによっても、分類できる。改善型は、初期解から徐々に解を改善していく手法であり、ヒューリスティクスでいえば局所探索法が相当する。一方、構築型とは、解を徐々に作っていくようなアル

ゴリズムであり、ヒューリスティクスでは、**貪欲法**（あるいは、**欲張り法**(greedy algorithm))が知られている。貪欲法では、目的関数への貢献度に基づいて解要素を局所的に評価し、その評価に基づいて、解を構築していく。

(3) **代表的なアルゴリズム** 以下に、メタヒューリスティクスに属する代表的なアルゴリズムについて、その概略を示す。

局所探索法では、精度の低い局所解に到達して、探索が終了してしまう可能性がある。この可能性を減らすために、初期解を変えて局所探索法を繰り返すアルゴリズムが、**多スタート局所探索法**(multi-start local search)である。その中で、初期解がランダムに生成される場合が、ランダム多スタート局所探索法であり、初期解の生成に工夫を加える場合が、**反復局所探索法**(iterated local search)である。反復局所探索法では、近傍 $N(x)$ とは別に、近傍 $N'(x)$ を定義して、局所探索を行う。そこで得られた解 x' に対して、近傍 $N'(x')$ 内の一つの解 x'' をランダムに生成して初期解とする。近傍 $N'(x')$ の適切なサイズを固定的に定めることは難しいことから、 $N'(x')$ のサイズを適応的に変化させた反復局所探索法が、**可変近傍探索法**(variable neighborhood search)である。解の評価に用いる関数は、目的関数をそのまま用いて評価関数とするのが通常であるが、探索の状況に応じて評価関数を変化させることも可能である。**誘導局所探索法**(guided local search)は、評価関数の構成に工夫を加えた方法で、評価関数をアルゴリズムの途中で適応的に変形することによって、局所解からの脱出を図る。これら一群の局所探索法に基づくアルゴリズムはすべて、単一の解を保持しながら探索する改善型アルゴリズムである。

シミュレーテッドアニーリング（あるいは、**アニーリング法**、**焼なまし法**、**疑似焼なまし法**(simulated annealing, SA)では、解が改悪となる場合でも、目的関数値の差の大きさに応じて、ある確率でつぎの解として選ばれることを許す。それゆえ、改悪されていたとしても、つぎの解への移動が可能であるので、局所解からの脱出が可能となる。その確率は、物理現象である焼なましを模倣して、温度と呼ばれるパラメータによって制御される。温度が高いと、相対的に悪い解でも採用される可能性が大きくなり、温度が低いと、良い解の近傍を集中的に探索ようになる。温度の調整方法は冷却スケジュールと呼ばれる。シミュレーテッドアニーリングも、単一の解を保持しながら探索する改善型アルゴリズムである。

人間の記憶過程にアナロジーを持つ、単一の解を保

持しながら探索する改善型アルゴリズムが、**タブー探索法**(あるいは、**タブーサーチ**、**禁断探索法**(tabu search, **TS**))である。タブー探索法では、近傍に含まれる解がすべて評価され、それが改善であれ改悪であれ、現在の解を除く最良の解がつぎの解として選ばれるので、局所解からの脱出が可能である。ただし、この操作だけでは、同じ解が繰り返し現れること、すなわち、サイクリングが生じかねない。そのため、過去の探索における移動パターンを、タブーリストと呼ばれる解集合を作って記憶しておき、この集合に含まれる解への移動を一定期間において禁止する。タブーリストは、探索が進むにつれて、古いものから新しいものへと更新される。

複数解を保持しながら探索する改善型アルゴリズムの代表例が、**遺伝的アルゴリズム**(genetic algorithm, **GA**)である。遺伝的アルゴリズムでは、生物の進化過程が応用されている。すなわち、個体群(解集合)における個体(解)の交叉や突然変異によって新しい個体群が形成され、弱い個体は淘汰されて強い個体が残る。複数の世代(繰返し回)にわたって、これら一連の操作が繰り返される。個体群における複数の個体を組み合わせて、新たな解を生成する操作が交叉である。突然変異は、多様性を高めるために、各個体にわずかな変化を施して、新たな個体を生成する操作である。交叉や突然変異によって新たな個体群を生成し、現在の個体群と新たな個体群における個体の中から、淘汰(あるいは、再生)と呼ばれる確率的操作に従って、一定数をつぎの世代の個体群として保持する。ただし、単純な遺伝的アルゴリズムは、集中化の能力が弱いために、局所探索法が組み合わされることがある。このアルゴリズムは、**遺伝的局所探索法**(genetic local search, **GLS**, または **memetic algorithm**)と呼ばれる。

粒子群最適化法(particle swarm optimization, **PSO**)も、複数解を保持しながら探索する改善型アルゴリズムである。鳥や魚などの群れの採餌行動をアナロジーに持つ手法であり、複数の粒子(解)が粒子群(解集合)を構成し、粒子間の相互作用によって、各粒子が実行可能領域を動き回ることにより、有望な領域を探索する。各粒子は、位置ベクトル(現在の解)を保持しており、位置ベクトルを更新してつぎの解へと移動する。各粒子のつぎの位置ベクトルは、現在の位置ベクトルと、移動の方向を定める速度ベクトルから決定される。速度ベクトルは、以前の速度ベクトル、その粒子がそれまでに経験した最良解の位置ベクトル、粒子群全体でそれまでに経験した最良解の位置ベクトルを用いて算定される。

貪欲法に基づいて、単一の解を保持しながら探索する構築型アルゴリズムが、**GRASP法**(greedy randomized adaptive search procedure)である。貪欲法では、目的関数への貢献度が最も高い要素が選択されるが、貢献度の高い方から順にいくつかの候補を有して、その中からランダムに選択するのが、ランダム化貪欲法である。GRASP法では、ランダム化貪欲法により解を得て、それになんらかの局所探索法を適用するという、一連の操作が繰り返される。

複数解を保持しながら探索する構築型アルゴリズムの一つが、**アント法**(あるいは、**アントコロニー最適化法**、**アントシステム**(ant colony optimization, **ACO**, または **ant system**))である。蟻がコロニーを形成しながら知性的行動をとることが、コロニーで共有するフェロモンを使った非直接的なコミュニケーションによって説明できることにヒントを得た手法である。アント法では、リンクとノードから成るグラフ上を、道標となるフェロモンに基づいて、蟻が確率的に探索し、その確率の手順で解要素を逐次的に追加して、解が構築される。複数の蟻が同時に独立に意思決定するので、良い解のリンクとノード上には、フェロモンが増加する。

メタヒューリスティクスには、上述のもの以外にも、多数のアルゴリズムが存在する。メタヒューリスティクスの包括的な紹介や、各アルゴリズムの詳細については、例えば、文献7)~14)を参照されたい。

(4) **適用する際の留意点** 数理モデルを開発ないしは使用する際には、それが規範的であれ、記述的であれ、モデル内に最適化問題が包含されることが多い。それゆえ、最適化手法の役割は重要であり、土木計画の分野においても、2000年代以降、メタヒューリスティクスの使用が増加している。ただし、メタヒューリスティクスを適切に使用するためには、以下の点に留意する必要がある。

高精度の解を効率的に探索するには、アルゴリズムに含まれるパラメーターを適切な値に設定し、有効な操作を組み込む必要がある。タブー探索法や遺伝的アルゴリズムは、高精度な解を探索できる可能性が高く、それゆえ多様な分野での広範な適用事例が見られるが、実際のところ、これらの有力なアルゴリズムにおいても、基本的な操作のみを使い、精査されていないパラメーター値を用いた場合には、精度の低い解が得られることが多い。

解の精度に理論的保証がないからといって、得られた解の精度に関して何の情報も開示しないのは誤りである。実装した操作や設定したパラメーターの値次第では、ランダムに探索した解と大差のないことが十分

に起こり得るからである。操作やパラメーター値が適切であるかどうかについては、対象とする問題が、ベンチマーク問題と呼ばれる基本問題と同じか、同種の構造である場合には、ベンチマーク問題に適用して、アルゴリズムの性能検証をすべきである。ベンチマーク問題がない場合には、丹念な数値実験により、操作とパラメーター値の妥当性を示さなければならない。

先述のように、アルゴリズムが到達する近似解は、試行回によって異なる可能性があるため、全試行回における近似解の**最良値** (best solution)、**最悪値** (worst solution)、**平均値** (average solution) などを用いて、計算結果が評価されなければならない。したがって、例えば、最悪値と最良値の差が5%であった場合、最良値だけを示して5%未満の改善効果を提示しても、最悪値では効果が保証されないために、その提示は意味を持たない。

メタヒューリスティクスは本質的に、先述の「メタ」構造を有しており、集中化と多様化の操作設計の自由度が高いので、さまざまな拡張が可能である。一般に、少数の単純な操作から成るアルゴリズムは、計算時間は小さいが、解の精度は低くなる。一方、多数の複雑な操作を組み込めば、精度向上の可能性は高まるが、計算時間を要してしまう。それゆえ、両者のバランスを保つように設計することが肝要である。さらに、同じアルゴリズムを用いたとしても、有効な追加的操作は、対象とする問題によって異なる。つまり、メタヒューリスティクスは、汎用性を高めたアルゴリズムでありながら、その性能を高めるためには、対象とする問題に応じて個別に修正する必要がある。カスタマイズ指向であるヒューリスティクスとしての特性が強まるのである。また、この高い操作性ゆえに、異なるアルゴリズムの優劣を論じようとしても、例えば、タブー探索法と遺伝的アルゴリズムのどちらが優秀かを論じようとしても、アルゴリズムに実装する操作次第で性能が変わるので、比較に関する一般的な結論を出すことは難しい。

最後に、いうまでもないことであるが、厳密解法が適用可能な問題に対しては、厳密解法を用いるべきである。(山田忠史)

〔4〕 ネットワークデザインに関わる基礎数学

海上輸送や航空輸送、あるいはトラック輸送など、第三者にヒト・モノの移動行為を委託することを一般に**輸送** (transport) と呼ぶ。輸送を行う際には、その基本となる輸送ネットワークを設計する必要がある。

輸送ネットワークは単純なリンクの集合体ではない。輸送ネットワーク設計のためには、① 輸送に供

用する輸送機材、② 輸送時間、③ ターミナルでのさまざまな制約、を考慮する必要がある。通常、輸送主体（キャリア carrier と呼ばれることが多い）は利潤最大化を目的とした企業として設定されることが多く、企業戦略立案のためには上記の項目に加えて顧客の行動も考慮されるべきものとして組み込まれる。また、長期的な戦略として、ハブやデポなどのベースをどこに設置するのか (hub setting problem)^{15), 16)}、機材割当てを含めたスケジュールの管理¹⁷⁾、運航に関わるクルーの割当てをどのようにするのか (crew dispatch problem)¹⁸⁾ といった問題も、古典的なものから最新のものまで幅広く課題として設定されている¹⁸⁾。

これらのネットワークデザイン問題には共通の特徴がある。輸送ネットワーク設計に関して最も基本的なものは、「路線を張る・張らない」を決定する**整数計画** (integer programming problem, **IP**) として規定される。例えば、ある時間帯 t に空港 i から空港 j に運航される便の有無を示す変数を δ_{ij}^t と表すでしょう。ネットワークデザインでは目的に従って（例えば全体の運航費用を最小にする、など）、この便を設定する ($\delta_{ij}^t = 1$)、あるいは設定しない ($\delta_{ij}^t = 0$) を決定することとなる。ネットワークデザインでは図 3.8 に示すように時空間ネットワーク上でのデザインとなることも少なくないため、しばしば数学的には相当複雑になる。

図 3.8 は単純な飛行機の機材スケジュール例である。この例では飛行機は 06 時に空港 B を出発し、空港 A → 空港 D → 空港 C → 空港 B の順で運航され、空港 B で 22 時に降駐機されることを示している。その




図 3.8 時空間ネットワークの設計例 (機材スケジュール)

間に各空港に2時間ずつ滞在していることを示している。このようなスケジュール管理には「飛行時間帯」、「飛行方向」という二つの制御が存在することになり、複雑な管理が必要になることがわかるであろう。

ネットワークデザイン問題の典型的（基本的）な定式化としてはつぎのように定式化される。

$$\min z = f(\mathbf{x})$$

subject to

$$\mathbf{x} = (0, 1) \quad (3.33)$$

$f(\mathbf{x})$ はなんらかのネットワーク評価関数（目的関数）であり、 $\mathbf{x}$ はリンクに関わる運航の有無を示す制御変数であるとする（前出の δ_{ij}^l などに対応する）。制御変数が前出の例のように $(0, 1)$ の二値変数になっていることから、この問題はIPとして取り扱われる。

さて、輸送ネットワークを整数計画問題として設計する場合、通常2種類のアプローチの適用が一般的である。厳密解法とヒューリスティック解法である。後者については、3.1.3項で紹介されているので、ここでは厳密解法について簡単に触れておく。

IPの厳密解法で最もよく知られた方法論は**分枝限定法**（branch and bound, **BB**）と呼ばれる探索型の最適化手法である。これは最小化問題を考える際に、変数の制約に整数制約が加わっている場合、変数の値の変更によって生み出される目的関数の改善値を下限値として利用し、既存の解よりも改善できる見込みがある組合せの方向に再帰的に探索方向を絞り込む、というものである。

図3.9はBBの探索イメージを簡単に示したものである。まず、いま、階層 k 番目の第1番目のブランチに対して、そこから可能な分岐候補 $(a, b, \dots)$ の値を計算する。このとき、さらに分岐を持つ場合 $(i, ii, \dots)$ は、その候補が生成する値を比較する。これらによって生成された値をそれぞれ候補 a, b のブランチの値として列挙し、最も改善される値が得られるものを k ブランチの値として採用し、つぎのブランチ（階




図3.9 BBの探索イメージ

層 k に属する第2番目のブランチ）の計算に移行する、というものである。

BBにおける原始的なパターンは、各ブランチで可能な組合せを発生させていき、後に挙げる「探索停止条件」を満たすまでさらに下位のブランチに進んで候補の計算を行うというものである。例えば、 P, Q, R という変数がそれぞれ $(0, 1, 2), (0, 1), (0, 1)$ という整数値のみを選択可能であるとする。このとき最初のブランチで $P=0$ をとるとして、このブランチの下位に $Q=0$ の候補ブランチと $Q=1$ の候補ブランチが構成できる。さらに $Q=0$ のブランチの下位に $R=0$ のブランチと $R=1$ のブランチが構成され、これらの計算値に基づき $Q=0$ のブランチの値を計算できる。これらを順に行い、解が改善されるブランチの情報のみを残していく、というものである。

このようにBBは、基本的には全数探索に近い形で探索を行うため、厳密に実行する（整数探索のみで列挙型で実施する）には大規模すぎることが往々にしてある。なぜなら、次元数が上昇すると探索のブランチ数が指数関数的に増加して、事実上探索が不可能となるためである。ゆえに合理的な探索を行う場合、整数制約をなんらかの形で緩和し、そこから最小限の整数探索を実施することで解を得る**緩和法**（relaxation method）の導入が不可欠となる¹⁹⁾。最も簡単なものは整数制約を緩和して連続問題として解くものである。いま、簡単のために線形整数計画問題を考える。

$$\min z = c\mathbf{x}$$

subject to

$$A\mathbf{x} \leq B$$

$$\mathbf{x} : \text{integer} \quad (3.34)$$

上記において、 $\mathbf{x} : \text{integer}$ という条件が問題を扱いにくいものとしている。これを例えば $\mathbf{x} \geq 0$ という実数制約に緩和して「普通の」線形計画問題として解き、さらにそこから整数の探索を行う場合にBBを適用する、というアルゴリズムが考えられる。以降、緩和問題を内蔵するBBについて簡単にその構造に触れておく。

いま、探索すべきあるブランチにて緩和問題の解を得たとする。その解を $\tilde{\mathbf{x}}$ とする。 $\tilde{\mathbf{x}}$ の要素 $\tilde{x}_j$ は通常、整数解ではないので、つぎのような子問題を構成し、 $\tilde{x}_j$ が整数解として採択されるまで分岐を続ける^{20), 21)}。

【子問題の形成：今野らの整理による²¹⁾】

A：元の問題の制約を、 $\tilde{x}_j$ の下限値 $\leq x_j \leq \tilde{x}_j$ の整数値（切下げ）、に変更して解を求める。

B：元の問題の制約を、 $\tilde{x}_j$ の整数値 $+1 \leq x_j \leq \tilde{x}_j$ の上限値、に変更して解を求める。

これらの子問題を構成し、その解をすでに得られている解と比較することで、より好ましい新しいブランチに限定して探索を進めることができる。なお、計算の効率化のためには、すでに計算した解の中で最も望ましい値を記憶して、計算ごとにこの値を更新して計算を進めていく、という方法がとられる。

さて、前出の原始的なパターンの場合も含めて、BBではブランチ探索をなんらかの基準で停止する必要がある。「探索停止条件」としてはつぎのようなものが挙げられる²¹⁾。

【BBにおける探索停止条件】

- (i) 緩和問題において、得られた解がすべて整数解となった場合
- (ii) 解の改善が見られない場合
- (iii) 実行可能解を持たない場合

これらの条件のいずれかを満たした場合、ブランチの生成を止める（分枝停止）こととなる。換言すると、あるブランチからさらに枝分かれを発生させる（分枝操作）過程はつぎのような構造を持つ。いま、第 k 番目ブランチにおいて、(i) ブランチからさらに分岐する「子問題」に分解されていない、または、(ii) 対応する子問題が分枝停止になっていない、という条件が満たされた場合にのみ、探索すべき条件を備えたブランチであるとして、子問題を構成し、枝分かれを続ける²¹⁾。

ブランチの計算効率と精度は両立させることが困難であるため、できるだけブランチの探索値を精密に行う（深さ優先）か、より多くの最適候補の可能性を探索するか（幅優先）は、設計者の意図により変える必要がある。ただし、これらの工夫をもってしても依然として大規模計算であることには変わりはなく、ヒューリスティクスなど他の解法と併用するなど計算量緩和の方法が検討されている。また、問題構造によっては、線形計画問題の構造を利用し計算量を縮小する列遅延生成法（column generation）を組み合わせた²²⁾、ブランチごとに解探索に有効な不等式を付加し、BBの緩和問題を効果的に解くことができるように工夫した Branch and Cut²³⁾などが提案されている。これらの計算過程の工夫は、問題構造に大きく依存するため、問題構造の見極めが重要であることはいうまでもない。（竹林幹雄）

3.1.2 確率モデルと意思決定論

〔1〕 確率的意思想定

社会基盤事業の多くは、当該事業から発生する便益が不確実であることが多い。本項では、こうした不確実性の下での合理的な意思決定を取り扱う。

(1) リスク中立的意思想定²⁴⁾ 現在 ($t=0$) と将来 ($t=1$) の2時点を考え、 $t=1$ で起こり得る事象の集合を Ω で表す。事象 $\omega \in \Omega$ の生起確率を $P(\omega)$ で表す。 (Ω, P) を確率空間と呼ぶ。可能な意思決定の集合を S で表す。ある意思決定 $s \in S$ において当該事象において事業から発生する利得を $f_s(\omega)$ で表す。意思決定 x に対する利得の期待値は $E[\tilde{f}_s(x)] = \sum_{\omega \in \Omega} P(\omega) f_s(\omega)$ と表される。図3.10は、二つの選択肢 $s=1, 2$ について、確率空間 $\Omega=(\omega_1, \omega_2, \omega_3)$ 、 $P=(0.2, 0.5, 0.3)$ 上での各利得を示したものである。




図3.10 確率的利得の例

確率的意思想定の最もシンプルな基準は、利得の期待値が最大となる意思決定を行うもの（期待値基準）である。

$$\max_{s \in S} E[\tilde{f}_s] \quad (3.35)$$

図3.10の例に期待値基準を採用した場合、より期待値の大きい選択肢1が選ばれる。

(2) 期待効用理論とリスクプレミアム^{24), 25)}

上述の期待値基準では、例えば、確実に500億円の便益をもたらす堅実な事業と、5%の確率で1兆円の便益をもたらすが95%の確率で1円の便益ももたらさないギャンブル性の高い事業が無差別（リスク中立的）になってしまう。

意思決定者のリスクに対する態度（中立的／回避的／愛好的）を表現する手法として標準的なのが期待効用理論である。期待効用基準は、利得の期待値そのものではなく、利得 $\tilde{f}_s$ に対する効用 $U(\tilde{f}_s)$ の期待値を最大化するような意思決定を行う。

$$\max_{s \in S} E[U(\tilde{f}_s(x))]$$

(3.36)

リスク回避の選好は凸な効用関数、リスク愛好的選好は凹な効用関数で表現できる。リスク回避（愛好）の度合いは限界効用 $U'(\cdot)$ で表される。

図3.10の例に対して $U(f)=\sqrt{f}$ なるリスク回避型の効用関数を用いた期待効用基準を採用する場合、よりリスクの小さな選択肢2が選ばれる。確率的利得 $\tilde{f}$ と確定的利得 g が無差別、すなわち $E[U(\tilde{f})]=U(g)$ となるとき

$$\rho = \frac{E[\tilde{f}] - g}{E[\tilde{f}]} \quad (3.37)$$

をリスクプレミアムレート (risk premium rate) と呼ぶ。 ρ は確実な所得 g と比較した不確実な収益 $\tilde{f}$ の割引率として解釈できる。

(3) 動学的不確実性と多段階意思決定 社会基盤整備事業の多くは、発生する便益が (景気、為替、人口、気候などの影響を受けて) 確率動的に変動する。こうした動学的不確実性の下では、時々刻々獲得される情報に応じた多段階意思決定が必要となることも少なくない。

こうした動学的不確実性下での多段階意思決定問題を記述・分析するには、図 3.11 に示すような状態推移モデル (図(a)参照) や意思決定木 (図(b)参照) を用いる方法が必要である。織田澤・長谷川・小林²⁶⁾ は、供用後の事業価値の動学不確実性を考慮した上で、公共事業の休止・再評価を考慮した事業評価問題を多段階意思決定として記述・分析する枠組みを示している。長江・赤松²⁷⁾ は、より複雑な連鎖的意思決定構造を有向グラフとして表現するオプショングラフモデルとその定量的分析手法を構築している。




図 3.11 事業価値の推移モデル (図(a)) と意思決定木 (図(b)) (長江剛志)

[2] 待ち行列モデル

(1) 待ち行列システムの定義と表記法 駅改札での乗客の滞留、高速道路料金所での車の渋滞、航空機が空港へ着陸する際の上空待機など、人や物があるサービスを受ける際に待ちが発生するシステムの性能評価にしばしば使用される理論が待ち行列理論 (queueing theory) である。例えば、平均的な待ち時間や待ち行列の長さといったシステムの特性に関する諸量を計算することが目的となる。この待ち行列システムを一般的に図で表すと図 3.12 のようになる²⁸⁾。つまり、改札のようにあるモノを処理する (サービスを提供する) 窓口に着客が到着し、サービス終了後そこを退出する、といったシステムである。

待ち行列システムは、通常つぎのような六つの要素で特徴付けられ、それら要素から成る確率モデルとし




図 3.12 待ち行列システム

て表現される²⁹⁾。

- 客の到着分布
- 窓口の処理時間分布
- 窓口の数
- システムの容量 (許容可能な待ち行列長)
- システムに来る客の数 (無限または有限母集団)
- サービスの規範 (先着順、後着順など)

以下、それぞれの要素について概説する。

a) 客の到着分布 客の到着の仕方、つまりどのような時間間隔で到着するかは、システムの入力過程となり、待ち行列の特性を決める重要な要素である。対象としているシステムで実際に測定された到着分布に最も適合する確率分布を当てはめて考えることが必要になるが、最も基礎的なものは客がランダムに (でたらめに) 到着するというポアソン過程モデルであり、その到着時間間隔は指数分布となる。指数分布ではつぎの客が到着するまでの時間間隔が現在の状態だけに依存して決まり、過去の経緯とは無関係であるというマルコフ性 (Markov property) を有するため、後述のケンドールの記号では M と表す。乗客や車がある場所へ到着する際には、それぞれの人が特に申し合わせをすることなくバラバラに到着することがしばしばであるので、そのようなケースではランダム到着を仮定すればよいが、到着のスケジュールが決まっていたり、対象のシステムに入る前になんらかの整流化されていたりする場合も存在するため、そのようなケースでは規則型到着 (D: Deterministic) を仮定することになる。また、ランダム型と規則型の中間的な分布としてアーラン分布 (E: Erlang) があり、一般の分布を考えるとときは G (General) の記号で表す。

b) 窓口の処理時間分布 サービスを提供する窓口で客を処理する時間の長さの分布も、到着分布とともに待ち行列の特性を決める重要な要素となる。到着分布と同等、最も基礎的な分布として仮定されるのが指数分布であるが、対象としているシステムの実際の分布に合わせて適当な確率分布を仮定する必要がある。

c) 窓口の数 サービスを提供する窓口の数であり、単一窓口の場合と複数窓口の場合がある。

d) システムの容量 窓口がサービス中でふさがっているときに待ち行列を作ることができる容量で

あり、待合室の大きさのようなものである。無限の場合と有限の場合がある。

e) システムに来る客の数 システムにやってくる可能性のある客の数であり、多くの場合は無限であると考えられる(無限母集団)。有限である場合(有限母集団)もある。

f) サービスの規範 待ち行列に待っている客をどのような順序でサービスするかのルールであり、多くの場合は先着順(first come first served, FCFS)である。そのほか、最後の客からサービスをする後着順、またランダム順や優先権を持った客からサービスされる場合もある。

以上の各要素から多くの型の待ち行列システムを考えることができるが、その型を表現するために以下のケンドールの記号(Kendall's notation)がよく用いられる。

$$A/B/C/K/m/Z$$

ここで、 A から Z はそれぞれ前述の要素に対応しており、つまり、 A は客の到着分布、 B は窓口の処理時間分布、 C は窓口数、 K はシステム容量、 m はシステムに来る客の数、 Z はサービスの規範を表す。後半三つの記号は省略されることも多く、その場合はそれぞれ $K=\infty$ 、 $m=\infty$ 、 $Z=FCFS$ であるとされる。または K をカッコ付きで記載し $A/B/C(K)$ と記載することもある。例えば、客の到着分布が指数分布 M で、窓口サービスの処理間隔が一般分布 G で、窓口の数が s 個、待ち行列の上限が N である待ち行列システムは $M/G/s(N)$ と表す。

(2) 待ち行列システムの基本方程式 ($M/M/1$)

まず、最も基本的な待ち行列システムである $M/M/1$ を考える。このシステムでは客の到着がランダムで到着時間間隔が指数分布(平均到着間隔: $1/\lambda$)に従い、窓口は一つでそのサービス時間間隔も指数分布(平均サービス時間: $1/\mu$)に従い、システムの容量が無限である。

はじめに、システム内にいる人数に関して時間軸上の過渡状態を考える。システム時刻 t におけるシステム内の客の数(待っている客+サービスを受けている客)を $N(t)$ とする。 t から Δt 後の人数 $N(t+\Delta t)$ が n 人となるためには、以下の状態変化が必要となる。なお、微小時間 Δt ではシステムの状態は隣接する状態にのみ変化するものとする(つまり Δt ではたかだか 1 人しか到着、またはサービス終了をしない)。

- ① $N(t)=n$ で Δt の間に状態が変化しない(新しい客も到着せず、サービスを受けている客も退出しない)。
- ② $N(t)=n-1$ で Δt の間に新しい客が来て、か

つサービスは終了しない。

- ③ $N(t)=n+1$ で Δt の間に新しい客は到着せず、サービスが終了する。

ここで到着間隔が指数分布であるため、 t 時間の間に少なくとも 1 人が到着する確率 $A(t)$ 、つまり指数分布の分布関数は

$$A(t)=1-\exp(-\lambda t) \quad (3.38)$$

で表される。 $\exp(-\lambda t)$ をテイラー展開すると $1-\lambda t+(\lambda^2/2!)t^2-\dots$ となるから、微小な時間区間 Δt に対して $A(\Delta t)$ を考え、 Δt 以上の高次の微小量を見捨てる

$$A(\Delta t)=\lambda \Delta t \quad (3.39)$$

となる。サービス時間間隔についても指数分布であることから同様に、 Δt の間にサービスが終了する確率 $B(\Delta t)$ は

$$B(\Delta t)=\mu \Delta t \quad (3.40)$$

となる。以上から、 $N(t+\Delta t)=n$ となる確率 $P_n(t+\Delta t)$ は上記三つの状態変化の確率の和となるため

$$\begin{aligned} P_n(t+\Delta t) &= P_n(t)(1-\lambda \Delta t)(1-\mu \Delta t) \\ &\quad + P_{n-1}(t)(\lambda \Delta t)(1-\mu \Delta t) \\ &\quad + P_{n+1}(t)(1-\lambda \Delta t)(\mu \Delta t) \end{aligned} \quad (3.41)$$

となる。 Δt 以上の高次の微小量を見捨てる、整理すると

$$\begin{aligned} \frac{P_n(t+\Delta t)-P_n(t)}{\Delta t} &= \lambda P_{n-1}(t) - (\lambda + \mu)P_n(t) \\ &\quad + \mu P_{n+1}(t) \end{aligned} \quad (3.42)$$

となる。 $\Delta t \rightarrow 0$ とすれば、次式が得られる。

$$P'_n(t) = \lambda P_{n-1}(t) - (\lambda + \mu)P_n(t) + \mu P_{n+1}(t) \quad (3.43)$$

$P_0(t+\Delta t)$ は別途

$$\begin{aligned} P_0(t+\Delta t) &= P_0(t)(1-\lambda \Delta t) \\ &\quad + P_1(t)(1-\lambda \Delta t)(\mu \Delta t) \end{aligned} \quad (3.44)$$

となり、同様に次式を得る。

$$P'_0(t) = -\lambda P_0(t) + \mu P_1(t) \quad (3.45)$$

適当な初期条件を与えて、これら微分方程式を解けばよいが、一般にはこの過渡方程式を解くことは難しいので、システムの定常状態を考える。つまり $t \rightarrow \infty$ として $P_n(t)$ が t に無関係な P_n が存在すれば $P'_n(t) = 0$ となるから、式 (3.45)、(3.43) は次式のようになる。

$$-\lambda P_0(t) + \mu P_1(t) = 0 \quad (3.46)$$

$$\lambda P_{n-1}(t) - (\lambda + \mu)P_n(t) + \mu P_{n+1}(t) = 0 \quad (3.47)$$

これが待ち行列システムの定常状態における基本方程式であり、システム内の客数に関して隣接する状態

確率の間の釣合い式を表す。この基本方程式とすべての客数状態確率の和が1になるという式 (3.48) の条件から、待ち行列システムに関する諸量の解析解が得られる。

$$\sum_{n=0}^{\infty} P_n = 1 \quad (3.48)$$

式 (3.47) を順次解くと

$$P_n = \rho^n P_0 \quad (n=1, 2, \dots)$$

となる。ここで $\rho_n = \lambda/\mu$ である。全確率の式 (3.48) から、 $\rho < 1$ であれば

$$\sum_{n=0}^{\infty} P_n = P_0 \frac{1}{1-\rho} = 1 \quad (3.49)$$

となるから

$$P_0 = 1 - \rho \quad (3.50)$$

である。したがって、システム内に n 人の客がいる確率 P_n は次式となる。

$$P_n = \rho^n (1 - \rho) \quad (3.51)$$

なお、 $\rho > 1$ のとき待ち行列長や待ち時間は発散する (待ち行列長に上限がある $M/M/1(N)$ などではシステムがいつばいのときには客は立ち去る前提なので $\rho > 1$ でもかまわない)。以下、式 (3.51) の P_n からさまざまな待ち行列の特性を表す諸量を求めることができる。例えば、システム内に客がいない確率 P_0 は

$$P_0 = 1 - \rho \quad (3.52)$$

となる。したがって、 ρ は窓口が利用されている確率を表すため、利用率と呼ばれることがある。システム内にある平均客数 L は

$$L = \sum_{n=1}^{\infty} n P_n = (1 - \rho) \sum_{n=1}^{\infty} n \rho^n = \frac{\rho}{1 - \rho} \quad (3.53)$$

となり、窓口でサービスを受けている人を除いた平均待ち行列長 L_q は、 L から窓口利用確率 ρ を引けばよいので

$$L_q = L - \rho = \frac{\rho^2}{1 - \rho} \quad (3.54)$$

となる。ここで、平均客数 L と平均滞在時間 W (待ち時間 + サービス時間) の間には

$$L = \lambda W \quad (3.55)$$

の関係が成立する。これをリトルの公式 (Little's law) というが、客がシステム内に平均 W 時間滞在する間に平均して λW [人] がシステムに到着することになるので、それがシステム内平均客数となることを意味する。これより、システム内での平均滞在時間 W は

$$W = \frac{L}{\lambda} = \frac{\rho}{\lambda(1-\rho)} = \frac{1}{\mu - \lambda} \quad (3.56)$$

となり、サービスを受けるまでの平均待ち時間 W_q は

$$W_q = \frac{L_q}{\lambda} = \frac{\rho^2}{\lambda(1-\rho)} = \frac{\lambda}{\mu(\mu - \lambda)} \quad (3.57)$$

となる。

(3) サービス時間が一般分布の場合 ($M/G/1$)

客の到着とサービスの確率分布がランダム、つまり指数分布に従う場合の待ち行列システムの特性値は比較的簡単に解析解が得られることがわかった。一方、到着はランダムであってもサービスの処理時間が一定である場合やその他の確率分布に従う場合も多いが、一見解析がやさしそうな規則型を含め、ランダム型以外の分布では一般に解析が困難である。そのようなシステムの待ち行列解析でも適用可能な便利な公式がボラチェック・ヒンチンの公式 (Pollaczek-Khinchine formula) である。

いま、 B をサービス時間 (平均サービス時間 $\cdot 1/\mu$)、 R を新しい客が到着したときに窓口でサービスを受けている客の残りサービス時間を表す確率変数とする。そうすると、新たに来た客がサービスを受けるまでに平均して待つ時間 W_q は、すでに待っている客数 L_q がすべて処理される時間と R の期待値の和であるので

$$W_q = \frac{L_q}{\mu} + \rho E(R) \quad (3.58)$$

となる。リトルの公式から $L_q = \lambda W_q$ であるので、これを代入して以下の式を得る。

$$W_q = \frac{\rho E(R)}{1 - \rho} \quad (3.59)$$

ここで、 i 番目の客のサービス時間が $B = b_i$ であるとき、その客へのサービス開始時点から s 時間後 ($0 \leq s < b_i$) の R は $R = b_i - s$ となり、 b_i 時間後にはつぎの客のサービス時間 b_{i+1} に不連続に変化し、再び同様に時間経過に応じて線形に R は減少する。時間経過に応じて R はこれを繰り返すことになるため、 R の期待値 $E(R)$ は

$$\begin{aligned} E(R) &= \lim_{t \rightarrow \infty} \frac{1}{t} \int_0^t R dt = \lim_{t \rightarrow \infty} \frac{1}{t} \sum_{i=1}^{\infty} \int_0^{b_i} (b_i - s) ds \\ &= \lim_{t \rightarrow \infty} \frac{1}{t} \sum_{i=1}^{\infty} \frac{b_i^2}{2} = \lim_{t \rightarrow \infty} \frac{1}{E(B)} \frac{1}{t} \sum_{i=1}^{\infty} \frac{b_i^2}{2} \end{aligned} \quad (3.60)$$

となる。ここで、 $t/E(B)$ は t 時間に処理される平均客数であるため

$$\frac{1}{t/E(B)} \sum_{i=1}^{\infty} b_i^2 = E(B^2) \quad (3.61)$$

となる。したがって

$$E(R) = \frac{1}{E(B)} \frac{E(B^2)}{2} \quad (3.62)$$

となり（余命の平均²⁹⁾）、式（3.59）はけっきよく

$$\begin{aligned} W_q &= \frac{\rho}{1-\rho} \frac{E(B^2)}{2E(B)} = \frac{\lambda}{\mu-\lambda} \frac{\sigma^2 + E(B)^2}{2E(B)} \\ &= \frac{\lambda}{\mu(\mu-\lambda)} \frac{c_B^2 + 1}{2} \end{aligned} \quad (3.63)$$

と表せる。式（3.63）をボラチェック・ヒンチンの公式という。 σ^2 は B の分散、 c_B は B の変動係数である。この式から $M/G/1$ のサービス分布の平均と分散がわかれば平均待ち時間が求まり、分散が大きいほど待ち時間が大きくなることがわかる。また、 $M/G/1$ の平均待ち時間は $M/M/1$ の場合の $(c_B^2 + 1)/2$ 倍になることもわかる。なお、システム内の平均滞在時間 W と客数の平均 L はそれぞれ以下の式で求められる。

$$W = W_q + E(B) \quad (3.64)$$

$$L = L_q + \rho \quad (3.65)$$

さて、この公式は $M/G/1$ にも適用可能だが、当然ながら指数分布でも規則型（確定）分布でも適用可能である。例えば、 $M/M/1$ では B の変動係数は1であるので式（3.57）に一致することがわかる。また $M/D/1$ であれば B は規則型なので分散・変動係数ともに0となり

$$W_q = \frac{\lambda}{2\mu(\mu-\lambda)} \quad (3.66)$$

となり、 $M/M/1$ の待ち時間の半分になることがわかる。ランダム型（指数分布）と規則型の間であるアーラン分布は、サービス間隔が指数分布である窓口が k 個直列につながった場合のトータルのサービス時間 t の分布を表し、平均サービス時間を $1/\mu$ とした場合のその分布は k 相アーラン分布と呼ばれ

$$f(t) = \frac{(k\lambda)^k}{(k-1)!} t^{k-1} e^{-k\lambda t} \quad (3.67)$$

で表される。 $k=1$ で指数分布、 $k=\infty$ で規則型となる（図3.13参照）。

なお、0がピークで単調減少する指数分布は実際のサービス間隔に合わないこともあり、その場合にはある値にピークを持つ単峰形のアーラン分布の方が望ましいこともある。 k 相アーラン分布のサービス時間の分散は $1/k\mu^2$ であるため、平均待ち時間は




図3.13 k 相アーラン分布（ $\lambda=\mu=1$ ）

$$W_q = \frac{\lambda}{2\mu(\mu-\lambda)} \left(\frac{1}{2} + \frac{1}{2k} \right) \quad (3.68)$$

となり、平均待ち時間は $M/D/1$ と $M/M/1$ の間になる。以上のような代表的な確率分布以外の一般分布においても平均と分散がわかればボラチェック・ヒンチンの公式で平均待ち時間等が求められる。

（平田輝満）

〔3〕 マルコフ過程とアセットマネジメントの基礎

（1）アセットマネジメントとマルコフ過程 アセットマネジメント（asset management, AM）を実践する上での当面の目標は、社会基盤施設のライフサイクル費用（life cycle cost）を最小化するような補修施策を決定することである。一般的には予防保全か、事後保全かを選択することになる。ライフサイクル費用の算出に際しては、補修費用の積算もさることながら、補修タイミングを決定するための劣化予測（deterioration prediction）が重要な要素技術となる。

劣化予測に関しては力学的な挙動や材料特性を考慮した方法論がその中心であったが、近年のアセットマネジメント分野においては統計的劣化予測が主流となってきた。これは、社会基盤施設に対する点検は目視が主体であり、目視点検を通して得られる情報が離散的な多段階の健全度情報であることに起因する。つまり、離散的健全度間の推移状態を記述することができれば劣化過程を表現することが可能となるが、これはマルコフ過程（Markov process）と整合的であることが従来から指摘されていた。さらに、マルコフ過程に基づいて劣化予測を行った上で、補修工法と補修費用に関する情報を追加すれば、マルコフ決定過程を援用することによりライフサイクル費用最小化を達成するような補修施策を決定することができる。すなわち、現状の点検体制に則した形でアセットマネジメントを実践することができる。

（2）目視点検の不確実性と確率過程 社会基盤

施設に対する目視点検データは通常、多段階の離散的な健全度として与えられる。いま、ある社会基盤施設の劣化過程が図3.14のように与えられたと仮定する。さらに目視点検データが J 段階の健全度で評価されると考える。健全度1が新設状態であり、健全度 J は最も劣化が進行した使用限界状態である。同図において、社会基盤施設は時点 τ_{i-1} で健全度 $i-1$ から i へ、時点 τ_i で健全度 i から $i+1$ へ進展している。




図3.14 社会基盤施設の劣化過程

継続的なモニタリングが実施可能である場合には、当該社会基盤施設をセンサー等により常時監視することによって、図3.14のような劣化過程に関する完全な情報を得ることができる。一方で、 τ_A と τ_B は目視点検を実施した時点をそれぞれ表している。容易に理解できるように、目視点検を通して劣化過程に関して獲得できる情報は、1回目の目視点検の時点 τ_A で健全度が i であること、2回目の目視点検の時点 τ_B で健全度が j であることだけである。すなわち、目視点検は点検時点での健全度を記録しているに過ぎず、任意時点の健全度からつぎの健全度に推移する正確な時点(τ_{i-1} や τ_i)を捉えることはできない。したがって、目視点検データを用いて劣化予測を行う場合には、このような目視点検データに介在する不確実性に留意することが重要である。

また、実際の健全度の推移に基づいて劣化予測を行う場合には、2回の目視点検の点検間隔 $z(z=\tau_B-\tau_A)$ が重要となる。すなわち、健全度が同じ i から j に推移するような場合であっても、点検間隔 z が異なると劣化過程も異なる。点検間隔はマニュアルなどで定められているものの、すべての社会基盤施設に対して厳密には一律ではない。点検間隔 z も変数であり、不確実性を含む。先述したように、目視点検では劣化過程に関する限定的な情報しか獲得できないばかりか、獲得可能な情報にも不確実性が介在する。しかしながら、限定的かつ不確実性を有する情報のみであって

も、確率モデルにより劣化過程を定式化し、目視点検データを用いて劣化過程を統計的に推計することで、社会基盤施設の劣化予測を行うことが可能である。

(3) **マルコフ過程適用の前提** 社会基盤施設の管理者が初期時点 $t=0$ から無限に続く各時点 $t(t=0, 1, \dots)$ において、当該施設のアセットマネジメントを永続的に実施するような状況を考える。社会基盤施設は無期限にわたり供用され、要求性能レベルは一定に保たれるものとする（つまり、機能向上は考慮しない）。各時点 t の直前に目視点検が行われ、社会基盤施設の健全度が判定され、その結果に基づいて、時点 t の直前で必要に応じて補修や更新が実施されると考える。管理すべき社会基盤施設は数多く存在するが、その中にある特定の社会基盤施設 $k(k=1, 2, \dots, K)$ に着目する。対象とする社会基盤施設の健全度は、 J 段階の離散的な健全度 $i(i=1, \dots, J)$ で表され、社会基盤施設の劣化が進むにつれて i の値が大きくなる。健全度 $i=J$ は使用限界状態の健全度であり、健全度が J になっても、当該施設に対してただちに補修が行われない場合、社会基盤施設ごとに設定されたリスク費用が発生するものとする。

以上のような条件の下で、社会基盤施設の管理者がアセットマネジメントを実践していくためには、社会基盤施設の健全度の推移過程を例えばマルコフ過程（具体的には、マルコフ劣化ハザードモデル³⁰⁾）によって記述した上で、その劣化予測結果と連動する形であらかじめ最適補修施策を決定しておく必要がある。ここで、「最適」とはライフサイクルを通した補修費用とリスク費用の総和で算出される期待ライフサイクル費用の最小化を意味する。

(4) **社会基盤施設の補修過程** 最適補修施策を決定するためには、複数の補修施策案を作成して、それらのライフサイクル費用を相対比較する必要がある。それぞれの補修施策の内容は、社会基盤施設の各健全度に対して採用された「補修アクション」と「補修費用」の組合せにより記述される。

補修アクションは、健全度に応じて補修工法を決定するルールである。いま、社会基盤施設 k の補修アクションベクトル η^k を

$$\eta^k = (\eta^k(1), \dots, \eta^k(J)) \quad (3.69)$$

と表す。ここに補修施策 $d_k \in D_k$ は、各健全度 i に対して、その時点で実施する補修アクションを指定する一連のルールである。また、 D_k は社会基盤施設 k に対して適用可能な補修施策の集合を表す。補修施策 d_k を構成する補修アクション $\eta^k(j) \in \eta_k(j)$ は、健全度 j の社会基盤施設 k に対して補修を実施し、健全度

が $\eta^d(j)$ に推移することを意味する。例えば、補修アクション $\eta^d(j)=i$ は健全度が j のときに補修を実施すると、補修により健全度が i に回復するというアクションを表現する。 $\eta_k(j)$ は健全度 j の社会基盤施設 k に対して採用可能な補修アクションの集合を表し、補修アクション集合と呼ぶ。補修アクション集合には、「補修をしない」というアクションも含まれ、 $\eta^d(j)=j$ と表される。

つぎに、補修費用について定義する。補修アクションベクトル η^d に必要となる社会基盤施設 k の補修費用を費用ベクトル $c^d = (c_1^d, \dots, c_J^d)$ により表す。社会基盤施設 k の健全度を j から $i (1 \leq i \leq j)$ へ回復させるための補修費用を c_{ji}^d と表せば、 $\eta^d(j)=i$ のとき、 $c_j^d = c_{ji}^d$ が成立する。補修を実施しない場合 ($\eta^d(j)=j$ が成立する場合) には $c_j^d = c_{jj}^d = c$ が成立する。ここで、 c は定常的な清掃・維持費用である。ただし、補修費用は条件

$$c_{ii}^d \leq \dots \leq c_{ji}^d \leq \dots \leq c_{jj}^d \quad (i \leq j \leq J; j=1, \dots, J) \quad (3.70)$$

を満足すると仮定する。このことは補修前の健全度が悪い方が同一の健全度に回復するための費用が大きくなることを意味する。このとき、社会基盤施設 k の補修施策 $d_k \in D_k$ の内容は、各健全度 i に対して採用される補修アクション $\eta^d(j)$ と補修費用 c_j^d の組合せ ($\eta^d(j), c_j^d$) により記述される。各健全度に対して利用可能な補修アクションの数は有限個である。補修施策は各健全度に対して利用可能な補修アクションの組合せにより定義できるため補修施策も有限となる。

時点 t の健全度を状態変数 $h(t)$ によって表す。さらに、時点 t の健全度 $h(t)=i$ から、時点 $t+1$ で健全度 $h(t+1)=j$ に推移する確率を

$$\text{Prob}[h(t+1)=j | h(t)=i] = \pi_{ij} \quad (3.71)$$

と表すこととする。ここで推移確率 π_{ij} はマルコフ劣化ハザードモデルを利用して式 (3.71) で与えられる。さらに、社会基盤施設 k のすべての健全度間の推移確率を

$$\Pi_k = \begin{bmatrix} \pi_{11} & \pi_{12} & \dots & \pi_{1J} \\ 0 & \pi_{22} & \dots & \pi_{2J} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \pi_{JJ} \end{bmatrix} \quad (3.72)$$

と行列表記して定義する。推移確率行列 Π_k の (i, j) 要素である π_{ij} は推移確率であり、当然ながら非負の値をとる。補修がない限りつねに劣化が進行するため $\pi_{ij}=0 (i > j)$ が成立する。さらに、推移確率の定義よ

り、 $\sum_{j=i}^J \pi_{ij}=1$ が成立する。また、補修がない限り、 π_{JJ} はマルコフ連鎖における吸収状態であり、 $\pi_{JJ}=1$ が成立する。

つぎに、補修施策 $d_k \in D_k$ を構成する補修アクション $\eta^d(i)$ により生じる社会基盤施設の健全度の変化を

$$q_{ji}^d = \begin{cases} 1 & \eta^d(j)=i \text{ のとき} \\ 0 & \text{それ以外のとき} \end{cases} \quad (3.73)$$

と定義する。つまり、補修が実施された後の健全度 j は確率 1 で健全度 i に推移し、補修が実施されない場合は、確率 1 で健全度 j にとどまることを示している。式 (3.72) に示すように、補修を考慮しない場合には社会基盤施設の健全度が自然に回復することはない ($\pi_{ij}=0 (i > j)$)。したがって、補修による健全度の回復を定義する必要がある、これを推移確率 Q^d として整理することにより、次式を得る。

$$Q^d = \begin{bmatrix} q_{11}^d & q_{12}^d & \dots & q_{1J}^d \\ q_{21}^d & q_{22}^d & \dots & q_{2J}^d \\ \vdots & \vdots & \ddots & \vdots \\ q_{J1}^d & q_{J2}^d & \dots & q_{JJ}^d \end{bmatrix} \quad (3.74)$$

以上のような補修施策の下で管理される社会基盤施設の劣化・補修過程を健全度分布の推移として表現する。社会基盤施設 k に対する目視点検が z 期ごとに実施されると想定する。このとき、任意時点 $t=T (t \leq z)$ における健全度分布 s^{T, d_k} は

$$s^{T, d_k} = s^0 d_k \Pi^{z-1} \{Q \Pi^z\}^{l-1} Q \Pi^{\tau+1} \quad (3.75)$$

と表される (ただし、 Π の添字 k および Q の添字 d_k は略記している)。ここで健全度分布 s^{T, d_k} は、補修施策 d_k を採用したときに、時点 $t=T$ における健全度の比率を示した行ベクトルである。また、上式中の l は時点 T までの点検回数、 τ は最終点検の実施時点から時点 T までの期間であり、 $T=lz+\tau$ が成立する。ただし、初期時点 $t=0$ において目視点検と補修が実施されるものとする。さらに、ここではより単純化するために、① 最も健全な状態を表す健全度 1 では補修を実施しない: $\eta^d(1)=1$ 、② いずれの補修工法を用いた場合であっても健全度は 1 に完全に回復する $\eta^d(j)=1 (j=2, \dots, J)$; という二つの仮定を設ける。なお、このような仮定を設けたとしても大半の問題に対しては実用性を損ねるほどの影響はないものと考えているが、上記の仮定を設けない一般的な劣化・補修過程に関しては文献 32) を参照されたい。ちなみに補修施策を考慮しない単純な劣化過程を健全度分布の

推移で表現する場合には、 Q^{d_k} を単位行列と考え、次式を得る。

$$s^T = s^0 \Pi^{z-1} \{ \Pi^z \}^{t-1} \cdot \Pi^{z+1} = s^0 \Pi^{tz+z} = s^0 \Pi^T \quad (3.76)$$

(5) ライフサイクル費用評価と最適補修施策

現在時点における健全度分布 s^0 、劣化過程に関する推移確率行列 Π_k 、補修施策 $d_k \in D_k$ 、目視点検・補修の実施間隔 z が決まれば、将来時点 t の健全度分布 s^{t, d_k} を求めることができる。さらに、この健全度分布に対し、各社会基盤施設の補修費用、リスク費用を用いることで、対象期間における期待ライフサイクル費用を算出することが可能となる。対象とする K 個の社会基盤施設すべてに対して補修施策 $d \in D$ 、目視点検・補修の間隔 z を採用した場合を想定する。任意の社会基盤施設 k に対する現在時点の健全度分布を s_k^{0, d_k} 、劣化過程に関する推移確率行列を Π_k とすると、将来時点 t の健全度分布 s_k^{t, d_k} が式 (3.76) に示した方法により求まる。

ここで、時点 t において補修が実施される場合に生じる費用に着目する。補修施策 $d_k \in D_k$ に基づいて各健全度における補修の実施の有無、補修内容が決まり、各健全度における補修費用 $c_k^{d_k} = (c_{k,1}^{d_k}, \dots, c_{k,J}^{d_k})$ が定まる。このとき、期待補修費用は

$$CM_k^{t, d_k} = s_k^{t, d_k} \{ c_k^{d_k} \}^T \quad (3.77)$$

となる。補修が実施される場合、健全度が J の社会基盤施設に対しては補修が必ず実施されるために、リスク費用は発生しない。つぎに、時点 t において補修が実施されない場合に生じる費用に着目する。補修を実施しない場合、補修費用は生じないが、最も健全度が悪い健全度が J の社会基盤施設には社会的損失が発生する。このとき、期待リスク費用は

$$CR_k^{t, d_k} = x_k^{t, d_k}(J) c_k^r \quad (3.78)$$

となる。ただし、 $x_k^{t, d_k}(J)$ は時点 t において社会基盤施設 k が健全度 J に達する確率、 c_k^r は部材 k のリスク費用である。以上より、部材 k の現在時点から対象期間 T におけるライフサイクル費用 $LCC_k^{d_k}$ は

$$LCC_k^{d_k} = \sum_{t=0}^T \gamma^t \left(\delta^{t, d_k} CM_k^{t, d_k} + (1 - \delta^{t, d_k}) CR_k^{t, d_k} \right) \quad (3.79)$$

と求めることができる。ただし、 γ^t は社会的割引率、 δ^{t, d_k} は補修の実施の有無を表す変数であり

$$\delta^{t, d_k} = \begin{cases} 1 & \text{補修が実施される場合} \\ 0 & \text{補修が実施されない場合} \end{cases} \quad (3.80)$$

である。したがって、 K 個の社会基盤施設すべてのライフサイクル費用 LCC^{d_k} は

$$LCC^{d_k} = \sum_{k=1}^K LCC_k^{d_k} \quad (3.81)$$

である。このとき、期待ライフサイクル費用最小化を実現する最適補修施策は

$$d_k^* = \min_{d_k \in D} \{ LCC^{d_k} \} \quad (3.82)$$

として選定される。

(6) おわりに アセットマネジメントの概要を説明するために、目視点検データに基づく劣化予測手法として近年着目されているマルコフ過程と、それと連動するマルコフ決定モデルによってライフサイクル費用最小化を達成する最適補修施策の決定手法についても説明を行った。一般的なライフサイクル費用評価であれば、ここで述べた方法を適用することによって、ある程度の評価は可能である。しかし、割引率の適用をどのように考えるか、それに関連して割引現在価値最小化法と平均費用最小化法³¹⁾のいずれを適用するのか、という問題を検討していくためには、さらに高度な方法論を習得する必要がある。また、近年では **PFI** (private finance initiative) や **BOT** (build operate transfer) をはじめとして、ある一定年数の間、社会基盤施設を維持管理するという事例も増加してきている。そのような場合には維持管理の終了期における社会基盤施設の健全度をどの段階に設定するかで、それ以前の最適補修施策が変化する。この問題を扱う場合には、本節で述べたような単純なマルコフ決定過程を適用することはできない。さらに、社会基盤施設の廃棄を含めた最適補修施策を検討する際には、リアルオプションアプローチ³²⁾などを援用して問題の解決を図る必要がある。(貝戸清之)

[4] 評価モデル (DEA, AHP)

土木計画学の評価モデルには、多くの場合「多基準」であることが求められる。これは、社会基盤整備の効果や影響が広範囲にわたるからである。このような観点から、多基準分析による評価モデルが、土木計画学において多く利活用されている。

ここでは、多基準分析による評価モデルの代表的手法である包絡分析法 (data envelopment analysis, 以降 **DEA**) と階層分析法 (analytic hierarchy process, 以降 **AHP**) について説明する。

DEA は、事業体の活動に関する効率性を多入力・多出力の比を用いて、比率尺度で相対的に測定することが可能な手法である。既存の重回帰分析等は、事業体データの平均像を分析し、予測などに活用する手法であるが、DEA は最優秀事業体群を発見し、これらをベンチマークとして他の事業体の効率性を評価する

手法である点に特徴を有している。DEA は人間の価値観などの情報は一切含まず、「データに語らせる」という観点から、事業体活動の効率性の客観的評価等に適する手法である。

AHP は、問題を評価要因と代替案に分解し、これらを比較評価して重み付けを行い、評価要因の重要度やその重要度を加味した代替案の評価を定量的に分析することが可能な手法である。すなわち、人間の主観的・感覚的な評価を定量的・多基準的に分析が可能な点に特徴を有している。「人間の価値観を定量化する」という観点の評価モデルであり、参加型計画立案プロセスにおける集団合意形成支援等に適する手法である。

以降において、これらの評価モデルを概説する。

(1) **DEA**^{23), 34)} DEA の基本モデルとして、Cooper らによって提案された CCR (Charnes-Cooper-Rhodes) モデルがある。このモデルは、規模に関して収穫一定を仮定したモデルである。以降においては、入力指向型 CCR モデルを説明する。

まず、DEA では分析対象 (事業体等) を一般に DMU (decision making unit) という。ここで、 n 個の DMU があると仮定し ($DMU_j, j=1, \dots, n$)、それぞれ m 個の入力項目と s 個の出力項目があると仮定する。それらの中で評価対象とする任意の DMU を DMU_o と表し、その入力データを x_{mo} 、出力データを y_{so} と表す。各入力項目に関する各ウエイトを $v_m (m=1, \dots, M)$ 、各出力項目に関する各ウエイトを $u_s (s=1, \dots, S)$ とするとき、それらのウエイトを算出する問題は以下のように定式化される。

$$\begin{aligned} (FP_o) \quad & \max_{v, u} \quad \theta_o = \frac{\sum_s u_s y_{so}}{\sum_m v_m x_{mo}} \\ \text{subject to} \quad & \sum_s u_s y_{sj} \leq \theta_o \sum_m v_m x_{mj} \quad (j=1, \dots, n) \quad (3.83) \\ & v_m \geq 0, u_s \geq 0 \end{aligned}$$

式 (3.83) の最適解を (v_m^*, u_s^*) 、最適目的関数値を θ_o^* と表す。この DMU_o に関する θ_o^* の値が効率性の評価値を与える。このとき、 $\theta_o^* = 1$ ならば DMU_o は効率的であり、 $\theta_o^* < 1$ ならば DMU_o は非効率的であることを示す。

さらに、入力項目の一律 θ_o^* 倍の縮小による効率性改善案を提示する入力指向型 CCR モデルにおける効率性改善案 $(\hat{x}_o, \hat{y}_o)$ は式 (3.84), (3.85) のとおりである。

$$\hat{x}_o = \theta_o^* x_{mo} - \text{slack}^{-*} \quad (3.84)$$

$$\hat{y}_o = y_{so} + \text{slack}^{+*} \quad (3.85)$$

ここで、 slack^{-*} は入力の余剰、 slack^{+*} は出力の不

足である。これらの効率性スコアならびに改善案のモデルイメージ (全 DMU の出力を一定とし、2 個の入力を仮定した入力空間) を図 3.15 に示す。




図 3.15 効率性スコアと改善案のモデルイメージ

図 3.15 において、点 A, B, C は DMU であり、A と B は効率的、C は非効率的である。さらに、C の効率性評価値は $\theta^* = OC'/OC < 1$ となる。また、入力指向型 CCR モデルによる C の効率性改善案は、式 (3.84) のとおり入力値 x の一律 θ^* 倍の縮小 (点 C' への移動) として表される。

DEA の特長は、既述のとおり多入力・多出力の多基準的観点から、事業体の効率性を評価することが可能な点にある。すなわち、一般的な重回帰分析等の手法では、1 出力 (目的変数) と多入力 (説明変数) の関係を分析するものに限られており、多入力・多出力のケースを分析することができなかった。また、式 (3.83) にあるように、最も効率性スコアが高くなるような最適ウエイトが、DMU ごとにそれぞれ異なって設定されることから、それぞれの DMU の特性なども併せて分析・把握することが可能になる。さらに、式 (3.84), (3.85) に示すように、効率性のフロンティアに到達するための効率性改善案も併せて提示できること、等が挙げられる。

適用における注意点として、入出力項目が多数となる場合、効率的と評価される DMU が多数出現することになる。これは、最適ウエイトが DMU ごとにすべて異なって設定されることに起因する。よって、事業体の評価を目的とした適用においては、入出力項目の選定を慎重に行う必要がある。さらに、最適ウエイトの設定が極端になるケースがある。例えば、入力項目 1 にすべてのウエイトが付与され、入力項目 2 にはウエイトがまったく付与されない場合等がある。よって、総合的な観点から事業体进行评估することを分析目的とする場合には、ウエイト設定に制約を設けたモデル (領域限定法) 適用の検討等が必要となる。また、算出された効率性改善案は非効率と評価された DMU が効率性のフロンティアに到達するための指標値を表しているものの、実現可能性等を考慮した改善案ではない、ということを理解しておく必要がある。

このような特性を踏まえ、DEAは公益事業体評価、公共交通事業体評価、バス路線評価、交通システム効率性評価、道路効率性評価、空港運営・経営評価、自治体経営評価、環境・エネルギー効率性評価、等の分野で多く適用されている。

また、今後の手法の発展方向性として、効率性の新たな計測方法の開発、効率性改善案創出に関する新モデルの開発、最適ウエイト設定における意思決定者の選好情報の組入れ、等が挙げられる。

(2) **AHP**³⁵⁾ AHPは、Saatyによって提案された手法であり、多基準の観点から成る複雑な意思決定問題を構造化・定量化することが可能である。これは、図3.16に示すように、問題を総合目的(goal)－評価要因(criteria)－代替案(alternative)に整理し階層図を設定する。




図3.16 階層図の一般例

ここで、 C_i は評価要因($i=1\sim m$)、 A_j は代替案($j=1\sim n$)である。これらから、代替案 A_j の総合ウエイト X_j は式(3.86)により求めることができる。

$$[X_j] = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_j \\ \vdots \\ X_n \end{bmatrix} = \begin{bmatrix} s_{11} & s_{12} & \cdots & s_{1i} & \cdots & s_{1m} \\ s_{21} & s_{22} & \cdots & s_{2i} & \cdots & s_{2m} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ s_{i1} & s_{i2} & \cdots & s_{ii} & \cdots & s_{im} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ s_{n1} & s_{n2} & \cdots & s_{ni} & \cdots & s_{nm} \end{bmatrix} \begin{bmatrix} W_1 \\ W_2 \\ \vdots \\ W_i \\ \vdots \\ W_m \end{bmatrix} \quad (3.86)$$

ここで、 X_j は代替案 j の総合ウエイト、 s_{ij} は評価要因 i に関する代替案 j の評価値、 W_i は評価要因 i のウエイトである。このように、 W_i は被験者の価値観を表しており、どの評価要因がどの程度重視されているかを把握できる。また、 X_j はこの W_i を勘案した総合評価値である。この s_{ij} ならびに W_i は、一般的に pairwise 比較法によって各要素間の重要度を評価し、その評価値に基づき pairwise 比較マトリックスを作成して、その固有値を用いた固有値法(多くの場合、簡易計算法である幾何平均法が用いられる)によって算出される。ま

た、各被験者の回答の整合性については、コンシステンシー指数を用いて確認できる。

AHPの特長は、特に定量化が困難であった人間の価値観を系統的に分析可能な点にある。例えば、既存の費用便益分析等においては、貨幣的計測が可能な項目の便益のみを対象としていたが、AHPを活用すれば、非市場的価値の定量化が可能になることから、多基準の観点から道路整備の評価³⁶⁾が可能になる。また、評価のプロセスにおいては、地域住民などのステークホルダーがアンケートの被験者になることから、手続き的公正を高める効果があり、参加型計画立案プロセスにおける集団合意形成支援等が可能になる。

適用における注意点として、既存の重回帰モデル等においては、その信頼性は統計学的観点から担保されるが、AHPにおいては、各被験者の回答の首尾一貫性はコンシステンシー指標によって判断可能ではあるものの、AHPの評価値と実際の意思決定や行動などの整合性の検証方法は、まだ十分に確立されているとはいえない。また、回答においては、一対比較による要素間の総当たり評価が必要になることから、評価要因と代替案の要素数が多くなる場合、被験者の評価負担が増加し、整合性が担保された回答が得られにくくなる問題点等がある。さらに、新規代替案を追加して再評価した場合、それまでの評価結果の順位が逆転する可能性(順位逆転現象)がある。

このような特性を踏まえ、AHPは道路投資評価、交通施設機能評価、バス事業活性化方策評価、防災計画評価、景観評価、建設優先順位決定、中心市街地活性化計画評価、空港・航空計画評価、都市空間評価、歩行環境評価、鉄道計画評価、居住環境評価、都市・交通バリアフリー評価、住民参加型計画支援、合意形成支援、等の分野で多く適用されている。

また、今後の手法の発展方向性として、各要素間の関連性を考慮可能なモデルの開発、被験者の評価負担の軽減が可能な評価法の開発、等が挙げられる。

(鈴木聡士)

3.1.3 シミュレーション手法

コンピューター演算処理能力の著しい向上により、土木計画分野へのシミュレーション手法の適用が盛んに行われている。ここでは、手法の概要と特性を整理したのち、政策評価の留意点を説明する。

[1] シミュレーションの基礎

土木計画が対象とする問題は、その構造が複雑であり、システム全体の振舞いを直接かつ正確に記述することは難しい。そのような場合、システムがある状態

から別の状態へ移行する要因を単純化したモデルで記述し、計算機を用いて個々の要因の挙動やシステムへの影響を実験的に解析する手法がシミュレーション (simulation) である。シミュレーションは必ずしも計算機を利用するものではないが、大量の計算量や乱数を必要とすることが多く、現在では必然的に計算機を利用している。シミュレーション手法の特性として、つぎのようなことが挙げられる。

- ① 解析的な解の導出が困難である問題に対して、近似解を得る手段となる。
- ② 解あるいは特定の状態に至る動的な過程を観察することができる。
- ③ 確率的事象を簡単に取り扱える。
- ④ 時間的・空間的な連続性を取り扱える。
- ⑤ 感度分析が容易に行える。
- ⑥ 主体の行動合理性を限定したり、主体間の相互作用を考慮することが可能である。
- ⑦ 結果の頑健性を示すには、初期値やパラメータ値の設定、乱数シードを変えながら、多数回計算しなければならない。
- ⑧ 最適解を得られるとは限らない。
- ⑨ 初期値・パラメータ値の自由度が大きいいため、それらの設定により結果が大きく変化することもある。結果の妥当性は慎重に検証する必要がある。

このような特性から、シミュレーション手法はおもにつぎのような場合に用いられる。

- ① 厳密な数理モデル構築が不可能な場合。もしくは数理モデル構築は可能だが、代数的に解を得ることが困難な場合。
- ② 複数の代替案を比較検討する場合。特に、コストやリスクの問題から、現実世界での実験的試行が困難な場合。

(1) 分析の流れ ここではシミュレーションによる分析手順および注意点を説明する。シミュレーション分析においては、問題設定に合致した機能を持つシミュレーションモデルを開発 (もしくは既存のモデルを選択) することが重要であるとともに、分析に耐え得るデータを取得可能かについて吟味し、必要に応じて新たなデータ収集を行う必要がある。一般的なシミュレーション分析の流れはつぎのような段階に分けられる。

- ① 問題の明確化：何をどこまで明らかにしたいのか、すなわち分析対象とする問題を設定することから始まることは通常のシステムズアナリシスのプロセスと変わらない。この段階で特に重要なのは、分析対象範囲 (空間的な範囲や分析対象とす

る時間長、およびそれらの詳細度)、何を主体とするのか (個人、世帯、企業、ドライバー等)、そして主体の詳細な属性設定 (年齢、性別等) である。

- ② シミュレーションモデルの構築：問題設定に合致した機能を有する既存のシミュレーターを選択するか、新たにシミュレーションプログラムを開発する。新たに開発する場合は、まず主体 (間) の行動を表現する数理モデルや論理モデルを作成する。また、コンピューター言語への変換を行う前にシミュレーションクロック (simulation clock) の進行方式を決定する必要がある。進行方式はバリエーションスキニング方式とイベントスキニング方式に分類することができる。バリエーションスキニング方式は、一定の単位時間ずつシミュレーションクロックを進行させる単純な方法であり、前の時刻の状態を前提としてつぎの時刻の状態を順次更新する、車両の軌跡を表現するような場合は一般にこの方法が用いられる。また、シミュレーション内でつぎに変化する事象がいつ生起するのかが予測できる場合には、イベントスキニング方式が効率的である。これは、車両が異なる道路区間に移動するといったなんらかの事象が発生するごとに、不規則でシミュレーションクロックを進行させる方式である。一般に、イベントスキニング方式はバリエーションスキニング方式に比べ演算時間が短くて済む場合が多い。

- ③ データ整備：問題設定に見合った精度のデータを収集する。どのようなデータが必要となるかは、シミュレーションの構造に依存している。大別するならば、統計資料や調査などから入手や観測が可能なデータと、シミュレーションのアルゴリズム上なんらかの値を任意に設定する必要があるパラメーターに分けることができる。パラメーターについては、初期値の与え方や許容設定範囲を事前に整理しておく必要がある。

- ④ 妥当性検証 (internal verification)：プログラムの演算論理の確認を行うとともに可能であれば現況再現を行い、各パラメーターのキャリブレーション (調整) を実施する。

- ⑤ 実験計画とシナリオ分析：問題設定に合致した実験計画を設計し、複数のシナリオの計算結果を比較する。なお、比較に当たっては問題設定に合致した評価指標が求められる。

(2) モンテカルロ法 もともとモンテカルロ法 (Monte Carlo method) とは、決定論的な数学の問題

を乱数を用いて解くことを意味していたが、一般に確率的なモデルを組み込んだシミュレーションと同義に使われる場合もある。モンテカルロ法を実行する場合に不可欠なものが**疑似乱数** (pseudorandom number) である。計算機で疑似乱数を生成する方法はさまざま開発されているが、それらはすべて一様分布に従った乱数 (一様乱数) を生成する。最も普通に使われている方法は、単純な線形漸化式を利用するものであり、その中で SPSS や MATLAB, R などのソフトウェアパッケージに採用されているのが、**メルセンヌツイスター** (Mersenne twister)³⁷⁾ である。きわめて高速なアルゴリズムで、しかもその周期は $2^{19937} - 1$ と巨大であり、そして一様分布性にたいへん優れている。シミュレーションで疑似乱数を利用する場合、一様分布以外の分布に従う疑似乱数が必要となることが多い。例えば定常状態における車頭時間は指数分布に従い、歩行者の歩行速度の分布は正規分布に従うとされている。これらの分布に従う乱数は、一様乱数からの変換によって作成することができる。

- ① 指数乱数への変換：確率密度関数 $f(x) = \lambda e^{-\lambda x}$ に従う指数乱数 X は、一様乱数 U を用いて、式 (3.87) によって得る。

$$X = -\left(\frac{1}{\lambda}\right) \ln U \quad (3.87)$$

- ② 標準正規乱数への変換：二つの独立な一様乱数 U_1, U_2 を用い、式 (3.88) によって変換される X と Y は、確率密度関数 $f(x) = (1/\sqrt{2\pi})e^{-x^2/2}$ に従う独立な標準正規乱数となる。

$$\left. \begin{aligned} X &= \sqrt{-2 \ln U_1} \cos(2\pi U_2) \\ Y &= \sqrt{-2 \ln U_1} \sin(2\pi U_2) \end{aligned} \right\} \quad (3.88)$$

指数分布や標準正規分布に従う疑似乱数の生成法は、多数存在する。また、一般によく用いられる他の確率分布についても、一様乱数の変換という厳密手法によって生成可能である。

(3) **マルコフ連鎖モンテカルロ法** 任意の分布に従う疑似乱数列を近似的に生成する汎用手法として **マルコフ連鎖モンテカルロ法** (Markov chain Monte Carlo method, **MCMC 法**) がある。その概略は、**マルコフ連鎖** (Markov chain) と呼ばれる確率過程の性質を利用し、モンテカルロ法により、所望の確率分布からのサンプリングを行うものであり、**メトロポリス・ヘイスティングス アルゴリズム** (Metropolis-Hastings algorithm, **MH アルゴリズム**) や **ギブスサンプラー** (Gibbs sampler) など複数の技法が提案されている。ある確率密度関数 $f(X)$ を **目標分布** (target distribution) と

し、これに従う疑似乱数列を生成する MH アルゴリズムの概要を以下に示す。

- ① 初期値 X_0 を設定
- ② $t=0, 1, \dots$ に対して以下のステップを実行
 - (i) $Y \sim q(Y|X_t)$ を生成
 - (ii) 一様乱数 U を生成し、確率

$$\alpha(X, Y) = \min \left\{ \frac{f(Y)q(X|Y)}{f(X)q(Y|X)}, 1 \right\} \quad (3.89)$$

に対して

$$X_{t+1} = \begin{cases} Y, & U \leq \alpha(X_t, Y) \text{ の場合} \\ X_t, & \text{その他の場合} \end{cases} \quad (3.90)$$

と更新

- ③ 十分に大きな t 以降の X_t を近似的に $f(X)$ に従う疑似乱数列とみなす

ここで、 $q(Y|X)$ は**提案分布** (proposal distribution) と呼ばれ、状態 X を所与とした条件付き確率分布、つまり状態 X から状態 Y へのマルコフ推移を記述する関数である。また確率 $\alpha(X, Y)$ は**採択確率** (acceptance probability) と呼ばれる。目標分布が多峰型の場合に局所的なサンプリングとならないように、この採択確率によって確率が低い状態もときどきサンプリングし、提案分布によるマルコフ推移を調整する役割を果たす。

提案分布の代表的な設定法に**酔歩過程** (random walk) がある。正規分布などの対称な分布に従う確率変数 Z を用いて $Y = X_t + Z$ とすれば、式 (3.89) は式 (3.91) のように表される。

$$\alpha(X, Y) = \min \left\{ \frac{f(Y)}{f(X)}, 1 \right\} \quad (3.91)$$

例えば、目標分布が効用関数に基づく選択確率を表す場合、式 (3.91) により選択確率式の分母が約分できるため、全事象の効用値を計算することなく、少ない計算量でサンプルが得られる。この性質を利用することで、巨大な選択肢集合からの確率的選択シミュレーションを効率的に行うことができる³⁸⁾。

MH アルゴリズムとともに、よく用いられる MCMC 法の技法にギブスサンプラーがある。MH アルゴリズムとの相違点は X_t の更新方法にあり、提案分布を設定することの代わりに**全条件付き分布** (full conditional distribution) を用いてサンプリングを更新していく。確率密度関数 $f(X)$ に従う具体的なギブスサンプラーのアルゴリズムはつぎのようになる。

- ① 初期値 $X_0 = (X_{(0)1}, X_{(0)2}, \dots, X_{(0)n})$ を設定
- ② $t=0, 1, \dots$ に対して、 $Y = (Y_1, Y_2, \dots, Y_n)$ を以下

のステップによって生成する。

- i) $Y_1 \sim f(X_1 | X_{(1)2}, \dots, X_{(1)n})$ を生成
- ii) $i = 2, \dots, n-1$ に対して
 $Y_i \sim f(X_i | Y_1, \dots, Y_{i-1}, X_{(i)2}, \dots, X_{(i)n})$ を生成
- iii) $Y_n \sim f(X_n | Y_1, \dots, Y_{n-1})$ を生成

③ $X_i = Y_i$ とする。

④ 十分に大きな t 以降の X_i を近似的に $f(X)$ に従う疑似乱数列とみなす。

MCMC 法は、離散変数・連続変数を問わず、また目標分布が高次元であっても適用できるという利点がある一方、得られた標本は高い相関を持つ、目標分布からの厳密な独立標本による推定量よりも分散が大きくなる場合があるなどの問題点を持つ。(菊池 輝)

〔2〕 マイクロシミュレーション

(1) **マイクロシミュレーションの特徴** シミュレーションのうち、**活動主体** (agent) が個人やドライバーなどのように個別の行動をとる場合、あるいは世帯や企業などのように目的に照らして個別の行動をとるとみなせる場合、**マイクロシミュレーション** (micro simulation) と呼ぶ。社会現象を個々の主体の行動ベースで捉えようとする手法群の一つである。交通流解析、土地利用モデル、大気環境予測、財政・税・社会保障制度の影響評価などに用いられ、その活用範囲が広がっている³⁹⁾。各主体間のマイクロな相互関係を扱うことができ、その影響が全体のシステムにどのように及ぶかを知ることができるツールである。

(2) **セグメント** 取り扱う問題に求められる精度、入手できるデータ制約、コンピューター性能などによって、主体の**セグメント** (segment) を設定する。そのとき、どの主体間相互関係に着目するかが重要なポイントとなる。例えば、土地利用モデルにおいて、ある個人が、異なる勤務先を持つパートナーと夫婦であり、地元小学校区と密接な関係を持つ子供を持ち、介護の心配を抱える親を郊外に独居させているといったケースでは、夫婦・同居親族・家族といったセグメントとそれらの相互関係の設定がそれぞれ可能である。同居・別居するか、転居するか、リフォームするか、どこに住むかといった選択行動は、セグメント内外の相互関係を踏まえた個々の主体の意思決定に基づき行われる。

(3) **シミュレーションサイクル** 多くの場合、目標年次は設定されているであろうが、それに向けてシミュレーションを実行する時間サイクルを決める必要がある。交通流であれば秒単位、土地利用変化や社会保障制度評価であれば5年単位の場合もある。扱う

主体ごとに遷移サイクルが異なる場合には、設定が複雑になる。交通問題は、時間や日単位で変化可能であるが、その基礎となる土地利用分布は年単位の変化が通常用いられる。シミュレーションサイクルはより短い時間間隔に合わせて設定され、長期変化をする主体の行動は短期変化をする行動分析の与件として扱われることが多い。このとき、短期変化する主体の行動が長期変化する主体の行動に及ぼす影響の盛込み方に配慮が必要である。大別するならば、サイクルの初期あるいは末期などの一時期に一括して相互関係を反映させる場合と、短期変化量の閾値を設定して長期変化に反映させる場合が考えられる。

(4) **主体属性遷移** 時間経過とともに主体属性が遷移する。年次変化による年齢、自然増減・婚姻関係変化などによる家族構成、所得などがこれに当たる。入手可能なマクロデータをできるだけ詳細なセグメント単位で得て遷移確率を設定し、乱数の発生等によって主体の属性遷移を求めることが多い。各主体は、遷移した属性のパラメーターに基づき行動することになる。ただし、例えば、10年後の40歳の行動パラメーターが現在の40歳のものと同じとするか異なるとするかといった時期の異なる同じ属性の行動パラメーターの考え方は、分析の前提として定めなければならない。

(5) **クローズかオープンか** シミュレーションする地域範囲や対象属性範囲などは、初期設定の段階で定められる。主体総数を固定しその範囲で行う場合は**クローズシステム** (closed system) となる。一方、主体がシステムの外部と出入りする場合は**オープンシステム** (open system) となる。この場合、システム外への移転を表す転出モデルは作成しやすいが、外部からの転入モデルの作成は困難であり、どのような属性を備えた主体に転入させるかが問題となる。基本的には外生的に与えることになるが、シミュレーション結果に与える影響を感度分析などで把握しておく必要がある。

(6) **初期データの作成** 国勢調査などの全数調査に基づいて作成されたデータであればよいが、多くの場合は属性値の集計された周辺分布とサンプルデータによる詳細属性値しか知ることができない。マイクロシミュレーションを実施するに当たり、初期状態を表現するデータ群を作成する必要がある。ここでは、おもに、**IPF** (iterative proportional fitting) 法⁴⁰⁾ と**モンテカルロサンプリング** (Monte Carlo sampling) による方法を説明する。

a) **IPF 法** 属性の周辺分布を制約条件として、サンプルデータから得られた分布に近い分割表の

各要素を推計する方法である。二次元の場合は、式(3.92)に基づき行われる。ベースとなる考え方は、最も確率的に生じやすい分布を推定するということである。

$$\left. \begin{aligned} p_{ij(k+1)} &= \frac{p_{ij(k)}}{\sum_j p_{ij(k)}} Q_i \\ p_{ij(k+2)} &= \frac{p_{ij(k+1)}}{\sum_i p_{ij(k+1)}} Q_j \end{aligned} \right\} \quad (3.92)$$

ここで、 p_{ijk} は、 k 回目における i 行 j 列の分割表の要素で、 Q は周辺分布である。なお、この方法は、式(3.93)で与えられる Kullback-Leibler 情報量の最小化問題と等価である。

$$I(p^*, \pi) = \min_{p \in K} I(p, \pi) = \min_{p \in K} \sum_i \sum_j p_{ij} \log \left(\frac{p_{ij}}{\pi_{ij}} \right) \quad (3.93)$$

ここで、 p^* は推定する分布、 π は初期分布、 K は凸集合である。この方法は、推定後も属性間のオッズ比が等しく、その点での再現性が高いとされる。なお、多次元となった場合、制約条件数および分割表内の要素数が増加することにより初期分布の信頼性が低下することが、この手法の限界と考えられる。

b) モンテカルロサンプリング 属性の一次元の周辺分布を、モンテカルロ法を用いて発生させた乱数に基づいて個別データとして配分し、段階的に各データの複数の属性を決定する作業を繰り返し、最終的に多属性のマイクロデータを作成する手法である。属性決定のときに、サンプルデータによって得られる複数属性間の確率分布を援用し、推定する分布の精度を向上させようとする。作成フローを、図3.17に示す。




図3.17 モンテカルロサンプリングの例

(7) シミュレーション 目的に応じて複数のシナリオを設定し、多数回計算して比較することで、シナリオ設定の違いによる影響を求める。ここでは、マイクロシミュレーションの特徴である主体間の相互作用を盛り込むことが重要である。相互作用には、利己的/利他的行動、協調/非協調(妨害)/回避行動などの種類がある。シミュレーションの中で、なんらかの選択行動や状態変化を取り扱うことになるが、それを説明する効用関数や関係式に、個々の主体間の影響を互いに盛り込む。マイクロシミュレーションは、個々の行動主体のようなマイクロな現象が、全体のシステムの挙動に直観的には把握しにくい変化をもたらす場合に、その効果を発揮する。

(8) 政策マーケティング ドライバーへの交通情報の提供や転居後の居住条件変化、税制の変更による可処分所得の違いなど、個々の主体を直接対象とした政策効果を知ることができることが特徴である。このため、どの属性の主体が各政策によってどのように行動変化するかを見極める政策マーケティング(policy and marketing)が特に必要である。高い精度でシミュレーションを行う上で、政策とそれに対する応答が、適切な属性区分による主体区分によって過不足なく示されることがポイントとなる。その判断には、差の検定や Simpson 指数に端を発して発展したさまざまな多様性指数などの統計量が有効である。

(9) 結果の評価 シミュレーションでは通常同じ条件下であっても複数回計算するため、結果も複数得られる。これらの結果から、ゾーンや時間などで集計した値の平均値や最大/最小値(あるいは5%除外値等)や分散などの統計指標を求めてアウトプットとすることになる。また、個々の結果は起こり得る一つの可能性を示していると考えて、リスク評価のための統計指標を求めてアウトプットすることも考えられる。そしてそのアウトプットを用いて、どのような基準でどのような主体群に対して評価するかを定めておく必要がある。大別すれば、シミュレーション結果が最大化されているか、あるいは基準値を満たしているかという判断を行うことが多いが、それらの条件を個々の主体すべて(あるいはある一定比率以上)に対して求める場合、政策ターゲット単位ごとに集計された主体群に対して求める場合、対象とする全主体について集計した値に対して求める場合などがあり得る。マイクロシミュレーションの特徴からいえば、個々の主体に対して評価を行うことが適切であるが、個々の評価の総括をする際にはやはり集計を求められることになる。

また、多様なアウトプットの可視化技術が求められ

る。これは、分析者が結果を総合的に判断するためGISや3D画像などで表示された結果群を見ることを想定したもののほか、市民参加や複数のステークホルダー間での合意形成の場面で、シナリオ選択や政策決定のための結果群の表示を想定したものなどが考えられる。異なる意図を持つ主体が、主体ごとの結果と総合的な結果を共に見ながら議論できることは、マイクロシミュレーションの一つの大きなメリットとなっている。

マイクロシミュレーションは、計算結果が多様に存在するため、問題設定や目的の明確化、それに応じたシミュレーションの枠組み設定から計算、評価に至るまでの全体像の設計が、特に重要なツールであると認識されて利用されるべきものである。(北詰恵一)

引用・参考文献 (3.1 節)

- 1) 飯田恭敬編著：土木計画システム分析（最適化編），森北出版（1991）
- 2) 藤田素弘編著：社会基盤の計画学—確率統計・数理モデルと経済諸法—，理工図書（2013）
- 3) 新田保次監修，松村暢彦編著：図説 わかる土木計画，学芸出版社（2013）
- 4) 河上省吾：土木計画学（土木教程選書），pp.228～235，鹿島出版会（1991）
- 5) 秋山孝正，上田孝行編著：すぐわかる計画数学，pp.115～131，コロナ社（1998）
- 6) 藤井 聡：土木計画学（公共選択の社会科学），pp.109～120，学芸出版社（2008）
- 7) 柳浦睦憲，茨木俊秀：組合せ最適化—メタ戦略を中心として，朝倉書店（2001）
- 8) Ribeiro, C. and Hansen, P.: Essays and Surveys on Metaheuristics, Kluwer Academic Publishers, Dordrecht, The Netherlands (2001)
- 9) Michalewicz, Z. and Fogel, D.B.: How to Solve It: Modern Heuristics, Springer-Verlag, Berlin, Germany (2002)
- 10) Glover, F. and Kochenberger, G.A.: Handbook of Metaheuristics, Kluwer Academic Publishers, Boston, MA (2003)
- 11) Herz, A. and Widmer, M.: Guidelines for the use of metaheuristics in combinatorial optimization, European Journal of Operational Research, 151, pp.247～252 (2003)
- 12) Resende, M.G.C. and Pinho de Sousa, J.: Metaheuristics: Computer Decision-Making, Kluwer Academic Publishers, Dordrecht, The Netherlands (2004)
- 13) 古川正志，川上 敬，渡辺美知子，木下正博，山本雅人，鈴木育男：メタヒューリスティクスとナチュラルコンピューティング，コロナ社（2012）
- 14) Gogna, A. and Taya, A.: Metaheuristics: review and application, Journal of Experimental & Theoretical Artificial Intelligence, 25, No.4, pp.503～526 (2013)
- 15) Bryan, D.L. and O'Kelly, M.E.: Hub-and-spoke networks in air transportation: an analytical review, Journal of Regional Science 39, No.2, pp.275～295 (1999)
- 16) Campbell, J.F.: Hub location and the P-median problem, Operations Research 44, No.6, pp.923～935 (1996)
- 17) Lohatepanont, M. and Barnhart, C.: Airline schedule planning: integrated models and algorithms for schedule design and fleet assignment, Transportation Science 38, No.1, pp.19～32 (2004)
- 18) Barnhart, C., Belobaba, P., and Odoni, A.R.: Applications of operations research in the air transport industry, Transportation Science 37, No.4, pp.368～391 (2003)
- 19) B.コルテ，J.フィーゲン：組み合わせ最適化，第5章 5.6，シュプリンガーフェアラーク東京（2005）
- 20) ネムハウザーほか編著（伊理正夫，今野 浩，刀根薫監修）：最適化ハンドブック，第6章，整数計画法，朝倉書店（1995）
- 21) 今野 浩，鈴木久敏：整数計画法と組み合わせ最適化，日科技連出版社（1982）
- 22) Barnhart, C., et al.: Branch-and-price: column generation for solving huge integer programs, Operations Research 46, No.3, pp.316～329 (1998)
- 23) Ropke, S. and Cordeau, J.F.: Branch and cut and price for the pickup and delivery problem with time windows, Transportation Science 43, No.3, pp.267～289 (2009)
- 24) イツァーク・ギルボア著，松井彰彦訳：合理的選択，みすず書房（2013）
- 25) 武隈慎一：ミクロ経済学，新世社（1989）
- 26) 織田澤利守，長谷川専，小林潔司：インフラ経営における事業評価制度—リアル・オプション価値の計測—，日本リアルオプション学会（編）リアルオプションと経営戦略，シグマベイスキャピタル（2006）
- 27) 長江剛志，赤松 隆：連鎖的な意思決定構造を持つプロジェクトの動学的評価法：オプション・グラフ・モデルとその解法，土木学会論文集，No.772/IV-65, pp.185～202 (2004)
- 28) 五十嵐日出夫編著：土木計画数理，朝倉書店（1976）
- 29) 大石進一：待ち行列理論，コロナ社（2003）
- 30) 津田尚胤，貝戸清之，青木一也，小林潔司：橋梁劣化予測のためのマルコフ推移確率の推定，土木学会論文集，No.801/I-73, pp.69～82 (2005)
- 31) 貝戸清之，保田敬一，小林潔司，大和田慶：平均費用法に基づいた橋梁部材の最適補修戦略，土木学会論文集，No.801/I-73, pp.83～96 (2005)
- 32) 織田澤利守，石原克治，小林潔司，近藤佳史：経済的寿命を考慮した最適修繕政策，土木学会論文集，No.772/IV-65, pp.169～184 (2004)
- 33) Cooper, W.W., Seiford, L.M., and Tone, K.: Introduction to Data Envelopment Analysis and its Uses, Springer (2006)

- 34) 刀根 薫：経営効率性の測定と改善，日科技連出版社（1993）
- 35) 木下栄蔵：AHPの理論と実際，日科技連出版社（2000）
- 36) 道路投資の評価に関する指針検討委員会：道路投資の評価に関する指針（案）第2編（総合評価），日本総合研究所（1999）
- 37) Matsumoto, M. and Nishimura, T.: Mersenne Twister: A 623-dimensionally equidistributed uniform pseudorandom number generator, ACM Transactions on Modeling and Computer Simulation, 8, No.1, pp.3~30 (1998)
- 38) 菊池 輝, 山本俊行, 芦川 圭, 北村隆一：MCMC法を用いた巨大選択肢集合下での目的地選択行動の再現，土木計画学研究・論文集, 18, No.3, pp.503~508 (2001)
- 39) Zaidi, A., Harding, A., and Williamson, P.(eds) : New Frontiers in Microsimulation Modeling, Ashgate (2009)
- 40) Waddell, P., Borning, A., Noth, A., Freier N., Becke M., and Ulfarasson, G.: Microsimulation of Urban Development and Location Choice: Design and Implementation of UrbanSim, Networks and Spatial Economics, 3, No.1, pp.43~67 (2003)

3.2 統 計

3.2.1項では、まず、土木計画における統計調査・分析の重要性について簡単に説明する。3.2.3項では、土木計画において用いられる標準的な統計分析に用いる指標や解析手法をいくつか紹介する。それらの内容を理解する上で必要となる、あるいは統計調査そのものを行う際に知っておくべき、確率・統計学に関する基礎的な概念については、その前の3.2.2項で説明する。

3.2.1 土木計画における統計調査・統計分析

社会資本の整備や地域あるいは都市の計画を考える際には、まず、その地域や都市の特性や実情とともにそこでの課題を適切に把握する必要がある。わが国では、可住地面積、人口、従業者数など、地域の地理的あるいは社会経済的な状況に関するさまざまな**地域統計** (area statistics) や**経済統計** (economic statistics) が整備されている（例えば、東京大学教養学部統計学教室¹⁾参照）。都道府県や市町村といった自治体を単位とした統計だけでなく、国土を緯度・経度により方形の小地域区画（メッシュ）に細分し、それぞれのメッシュに統計調査の結果を対応させて編集された地域メッシュ統計も整備されている。そういったデータを3.3.3項で紹介するような統計解析手法を用いて分

析することで、地域の特徴を把握したり、複数時点のデータを時系列的に分析して動向を考察したりすることが可能となる。また、地価公示のような地点に対する統計情報も、社会基盤整備の企画・立案等の基礎資料として用いられている。例えば便益評価において、資産価値法へのヘドニックアプローチ（I編5.2.8項参照）の適用のために地価関数を同定する際には、公的地価調査のデータを用いてパラメーターの推定を統計学的に行うことが多い。

土木計画学分野、とりわけ交通計画に関しては、さまざまな調査が行われてきている。例えば、一定の調査対象地域（都市圏）内において「人の動き」を調べるパーソントリップ（PT）調査は、代表的な交通調査の一つである。PT調査では、発着場所や時刻、交通目的・手段、手段別所要時間などのトリップ特性に加え、住所、性別、職業、自動車の保有台数といった世帯・個人属性等の詳細なデータを得る。これにより、都市圏における複雑で多様な交通実態を把握することが可能となり、総合的な将来交通計画・マスタープランの策定、交通における個別課題への対応や駅等の特定施設の計画に関するさまざまな検討を行う上で必要となる交通需要予測が可能となる（I編4.2.4項など参照）。

土木計画学分野では、現実の複雑な社会経済システムを経済理論に基づきモデル化し、将来予測等の計量分析を行うことも盛んに行われている（I編5.3節参照）。そのような経済モデルのパラメーターは、多くの場合、分析の対象とする地域によって異なるため、上述のような実際の統計データを用いることでその値を推定する。その際には、3.2.3項で説明するような回帰分析を用いることが多い。

公的機関が作成する統計（公的統計）とは別に、各種事業や施策の計画・立案あるいは土木構造物の維持管理のために、独自にアンケートや点検等の調査によりデータを取得する場合も多い。その際、データを分析する段階ではもちろんのこと、どれだけの標本（サンプル）をどのように取得するのかという調査設計の段階においても、統計学的な知見が必要となる。最近では、行動の変容だけでなく、社会心理学のアプローチに基づく態度の変容に関する研究も盛んであり（II編14章参照）、そこでは、直接観測できない要因が多数に絡み合った現象を分析することも多い。

このように、土木計画のさまざまな場面で、統計解析手法を用いたデータ分析が必要となり、そのためには、統計学や計量経済学などの専門書を参考にしながら、適切な解析手法を選んで用いなければならない。

なお、土木計画学分野で扱うデータの中には、地

理空間的な位置を持ったデータも少なくない。そのようなデータを用いた統計解析手法については、**空間統計学** (spatial statistics) や**空間計量経済学** (spatial econometrics) と呼ばれる分野で新たな解析手法が開発されている。瀬谷・堤²⁾などを参照されたい。

(堤 盛人)

3.2.2 標準的な統計分析における基本的な考え方

さまざまな統計ソフトウェアが普及した今日、データや統計手法に関する知識がほとんどなくても統計分析の結果を得ることが可能となった。それとともに、背後にある理論を理解しないまま誤った統計分析やそれに基づく結論を導く可能性も高くなっており、データや統計手法について理解することの重要性がますます増しているともいえる。

そこで本項では、統計分析を行う上で最低限理解しておきたい事項や基本的な考え方を概説する。

〔1〕 データの種類

図 3.18 に示すように統計分析で用いられるデータは**質的データ** (qualitative data) と**量的データ** (quantitative data) に分類できる。




図 3.18 データと尺度の分類

質的データ (カテゴリーデータ、カテゴリカルデータ、定性的データ) とは、男性・女性のように四則演算ができないデータである。質的データは、その尺度に応じてつぎの 2 種類に分類できる。

- ① **名義尺度** (nominal scale) を用いたデータ：各カテゴリーが順序を持たない質的データである。例えば、交通機関選択 (自動車、鉄道、…) はその一例である。
- ② **順序尺度** (ordinal scale) を用いたデータ：各カテゴリーが順序を持つ質的データである。例えば、住環境に対する 5 段階評価などはその一例である。

一方、量的データ (定量的データ) とは、数値で推し量ることができ、数字の大小に意味を持つデータである。量的データは、その尺度に応じてつぎの 2 種類に分けることができる。

- ① **間隔尺度** (interval scale) を用いたデータ：時間や摂氏温度など、数値の差には意味があるが、絶対的な原点を持たないために比率には意味がな

いデータである。例えば、西暦が 1000 年から 2000 年になることは、「1000 年経過する」とはいうが「西暦年が 2 倍になる」とは解釈しない。

- ② **比例尺度** (ratio scale) を用いたデータ：人口や交通量など、数値の差だけではなく、数値間の比率にも意味があるデータである。例えば、居住人口が 50 万人から 100 万人になることは「人口が 50 万人増加する」とも「人口が 2 倍になる」とも解釈できる。

名義尺度に順序の情報を導入したものが順序尺度、順序尺度に観測値間の差の情報を導入したものが間隔尺度、間隔尺度に比率の情報を加えたものが比率尺度と、理解することもできる。

統計分析を行う際に用いる方法は、データの種類に応じて適切に選択しなければならない。量的データについては、各観測値の起こりやすさを表現する分布 (本項〔5〕参照) をあてはめることで分析が進められることが多い。

上述のようなさまざまなデータは、通常、長方形型または正方形型 (図 3.19 参照) に格納された後に一般に提供される (松原ら³⁾)。長方形型データとは各主体に対して一つまたは複数の属性を付与したデータであり、正方形型データとは主体間の関係を記述したデータである。土木計画で用いられる典型的な長方形型、正方形型のデータを表 3.4、表 3.5 に示す。

データの尺度だけでなく、データの構造によっても適用可能な分析手法は異なり、統計手法は慎重に選択する必要がある。




図 3.19 長方形型データと正方形型データ
(参考：松原³⁾)

〔2〕 母集団と標本

土木計画で用いられるデータの多くは何らかの調査を通して収集される。調査の対象となる集団全体は**母集団** (population) と呼ばれる。例えば国勢調査の場合であれば母集団は日本国内に居住するすべての人であり、母集団全体そのものを対象とした調査 (全数調

表 3.4 土木計画における長方形型データの例

	データの内容
時系列データ	単一主体 ($n=1$) の複数時点 ($p>1$) における属性
クロスセクションデータ	複数主体 ($n>1$) の単一時点 ($p=1$) における属性
パネルデータ	複数主体 ($n>1$) の複数時点 ($p>1$) における属性
コーホートデータ	性別等で分類された集団 (主体: $n>1$) ごとの世代別人口 (属性: $p>1$)

表 3.5 土木計画における正方形型データの例

名 称	データの内容
OD (origin-destination) データ	発着地 (それぞれ $n>1$) 間の人や物の流量・所要時間

査: census) が 5 年に 1 度実施されている。母集団は、そのサイズ N が無限大の無限母集団と N が有限の定数で与えられる有限母集団に分類できる。

母集団全体を調査するのは調査時間や調査コストの観点から困難、あるいは不可能である場合が多く、実際には母集団の一部を取り出した**標本** (sample) について調査されることが多い (図 3.20 参照)。その際に抽出する標本の数は**標本数** (sample size)^{†1} と呼ばれる。例えば、家計調査やパーソントリップ調査などは標本調査の例である。標本の具体的な抽出方法については本項〔3〕を参照されたい。




図 3.20 母集団と標本

多くの場合、標本を用いた分析の目的は母集団の特性を明らかにすることである。したがって、標本と母集団の関係を知ることは非常に重要である。例えば平均と分散については、無限母集団を仮定すると、標本の平均値である**標本平均** (sample mean) 式 (3.94) は標本数を大きくするにつれて母集団の平均 (**母平均**, population mean) μ に収束する (限りなく近付く)

が、標本の分散である**標本分散** (sample variance) 式 (3.95) は標本数を大きくしたとしても母集団の分散 (**母分散**, population variance) σ^2 には収束しないことが知られている^{†2}。

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i \quad (3.94)$$

$$\hat{s}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2 \quad (3.95)$$

ここで、 x_i ($i=1, 2, \dots, n$) は標本の実現値である。そのため、母集団の分散を知りたい場合は、母分散に収束するように標本分散を修正した不偏分散の式 (3.96) が用いられる。

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \hat{\mu})^2 \quad (3.96)$$

以上では無限母集団を仮定してきたが、有限母集団の場合の不偏分散は式 (3.97) となる。

$$\hat{\sigma}_{\text{finite}}^2 = \frac{N-1}{N} \frac{1}{n-1} \sum_{i=1}^n (x_i - \hat{\mu})^2 \quad (3.97)$$

N を極限まで大きくすると、 $\hat{\sigma}_{\text{finite}}^2$ は式 (3.96) となる。また、有限母集団全体で x_i を定義した場合、 $N=n$ となり、 $\hat{\sigma}_{\text{finite}}^2$ は標本分散の式 (3.95) に一致する。

母平均や母分散のような母集団についての特性値は**母数**または**パラメーター** (parameter) と呼ばれる。本項〔5〕以降ではパラメーターの推定について概説する。

さて、標本平均 $\hat{\mu}$ が既知の下では、標本 $x_1, \dots, x_n$ の一つ x_i が欠けていたとしても x_i の値は式 (3.94) から逆算できる。そのため、既知の $\hat{\mu}$ を含む標本分散の値は $(n-1)$ 個の標本の実現値のみで決まることとなる。このような、特性値を決める変数の数は自由度 (degree of freedom) と呼ばれる。自由度に基づいて標本分散を修正したものが不偏分散である。

〔3〕 標 本 抽 出

母集団の特性を十分に反映するような標本を抽出することは、統計分析の第一歩として重要となる。標本抽出の基礎的な方法に**有意抽出** (non-random selection) と**無作為抽出** (random sampling) がある。有意抽出とは属性データや専門家の意見等を踏まえながら標本を意図的に選択する方法である。例えば、募集に応じた調査協力者を標本とする方法や、属性データから典型的と判断された対象を標本とする方法は、有意抽出の例である。有意抽出は調査を容易にする反面、標本抽出が恣意的となる可能性や、無作為抽出とは異なり標本の信頼性が統計学的に評価できない点などの短所がある。

無作為抽出とは乱数を用いて標本を無作為に選択する方法であり、この方法を用いることで客観的な標本

†1 サンプル数、サンプルサイズなどとも呼ばれる。

†2 変動しない (唯一の値をとる) 母平均 μ と標本のとり方に応じて変動する標本平均 $\hat{\mu}$ 、という差異に起因する。

図 3.21 $N(0, 1)$ に従う確率変数の視覚化の例

抽出が可能となる。無作為抽出は選択される標本の重複を許す**復元抽出** (random sampling with replacement) と許さない**非復元抽出** (random sampling without replacement) に分類できる。

無作為抽出を用いた場合、標本平均の分散 $\sigma_{\bar{x}}^2$ が評価できる (復元抽出の場合: σ^2/n , 非復元抽出の場合: $\{(N-n)/(N-1)\}\sigma^2/n$)。標本平均が母平均に収束することを勘案すれば、分散 $\sigma_{\bar{x}}^2$ は「標本平均が母平均からどの程度ずれるか」の指標と解釈できる。標本平均と母平均のずれのように、母集団と標本から得られる特性値間の乖離は**標本誤差** (sampling error) と呼ばれる。

上述の標本抽出法に加え、無作為抽出の考え方を基礎としつつ、有意抽出のように属性データを考慮することで効果的に標本の抽出を行おうという標本抽出法が数多く提案されてきた。例えば、母集団を年齢や性別などに応じた複数のグループに分け、各グループ内で無作為抽出を行う**層化抽出** (stratified sampling) はその一例である。グループ内の等質性を高め、かつグループ間の異質性を高めるように層化抽出を行うことで、理論上は標本誤差の小さい標本の抽出が可能となる。また、調査の対象が空間的な広がりを持つ場合、調査エリアを選定するための無作為抽出を行い、つぎに選択されたエリア内で無作為抽出を実施する**二段階抽出** (two-stage sampling) も幅広く用いられている。二段階抽出を行うことで調査エリアが限定されるため、調査コストが削減できる。なお、二段階抽出を多段に拡張した抽出法は**多段階抽出**と呼ばれる。より簡便に、母集団に番号を付けて等間隔で標本を抽出する**系統抽出** (systematic sampling) もしばしば用いられる。

[4] 標本分布と統計量

統計分析を進めるに当たり、抽出された標本の特性を知ることは重要である。標本の特性を表す数値は**統計量** (statistic)、特に分布の特性を要約する統計量は

要約統計量 (summary statistics) と呼ばれる。

要約統計量は $(m \text{ 次})$ モーメント (積率, moment) 式 (3.98) に基づくものも多い。

$$\frac{1}{n} \sum_{i=1}^N (x_i - \mu_0)^m \quad (3.98)$$

μ_0 と m はパラメーターである。例えば、標本平均の式 (3.94) ($\mu_0 = 0, m = 1$) や標本分散の式 (3.95) ($\mu_0 = \bar{\mu}, m = 2$) は基礎的な要約統計量である。また、標本分散は二乗された値であり観測値とは次元 (単位) が異なるため、実際には標本分散の平方根である (標本の) **標準偏差** (standard deviation) が用いられることも多い。上記以外にも、分布の非対称性の統計量である歪度 ($\mu_0 = \bar{\mu}, m = 3$) や、分布の峰の鋭さを表す尖度 ($\mu_0 = \bar{\mu}, m = 4$) などが広く用いられている。なお、モーメントに基づく要約統計量を質的データには適用できない。これは式 (3.98) が和、差およびべき乗を含むためである。

モーメントに基づく要約統計量以外には、値の順序に基づく統計量である**順序統計量**が存在する。例えば n が奇数の場合、 n 個の観測値を昇順に並べたときの 1 番目、 $(n+1)/2$ 番目、 n 番目のそれぞれの値である**最大値** (maximum)、**中央値** (median)、**最小値** (minimum) はその代表例である。なお、 n が偶数の場合の中央値は $n/2$ 番目と $(n/2)+1$ 番目の両観測値の算術平均で与える。昇順のうちの $[(1/q)n]$ 番目[†]の観測値である **q 分位点** (q -quantile) も頻繁に用いられる。加えて順序 (統計量) を視覚化する便利なツールに**箱ひげ図** (box plot) がある。図 3.21 (a) には最小値、第 1 四分位点、中央値、第 3 四分位点、および最大値を示しており、これにより観測値の大まかな分布を把握することができる。順序等計量は名義尺度以外の各尺度で定義されたデータに適用できる。

[†] $[(1/q)n]$ は $m \leq (1/q)n$ を満たす最大の整数 m を表す (床関数)。これは、任意の実数をとって得る $(1/q)n$ を整数に対応付けるために用いられる。

さらに、値の大小に基づいて区分された各階級内の標本の数（度数，frequency）の分布である**度数分布**（frequency distribution）や、度数分布を棒グラフで視覚化した**ヒストグラム**（histogram）は観測値の分布を知る上で役立つ（図 3.21（b）参照）。度数が最大となる階級の値は**最頻値**（mode）と呼ばれる。

〔5〕 確 率 分 布

ここでは、母集団をモデル化するために用いられる「確率分布」について説明する。

いま、ある人 A の通勤に要した時間を 100 日にわたって分単位で記録してプロットしたものが図 3.22 であるとする。この図によれば、通勤時間が 55 分となる確率は $25/100$ となる。また 60 分となる確率は $2/100$ である。このように各値に確率が付随した変数は**確率変数**（stochastic variable, probability variable, random variable）と呼ばれる。土木計画で用いられるデータの多くは確率変数である。




図 3.22 ある人 A の通勤所要時間の確率分布。それぞれの棒は通勤時間が x 分台となった割合を表しており、それらの横幅自体には意味はない。

確率変数 x がある値 $k_j (j=1, 2, \dots, m)$ をとる確率は $\Pr(x=k_j)$ のように表記する。上の例であれば $\Pr(x=55)=25/100$ と $\Pr(x=60)=2/100$ である。ここで、確率の特性より $\Pr(x=k_j) \geq 0$ かつ $\sum_j \Pr(x=k_j)=1$ である。また $p(x)=\{\Pr(x=k_j), j=1, 2, \dots, m\}$ を k_j の各値について並べたものは**確率分布**（probability distribution）と呼ばれる。すなわち、図 3.22 は A の通勤時間の確率分布である。

つぎに、A が退勤時間帯ごとに帰宅に要した所要時間を縦軸に、退勤時刻（時）を横軸にとることで、通勤所要時間と退勤時間帯の関係を考える（図 3.23 参照）。図中の $p(x)$ は図 3.22 で示した所要時間の確率分布に相当する。この図が示すような二つ以上の変数によって確率が付与された確率分布は**同時分布**または**結合分布**（joint distribution）と呼ばれる。 x を所要時間、 y を退勤時刻とすると、同時分布は $p(x, y)$ のように表記される。




図 3.23 同時分布、周辺分布、および条件付き分布のイメージ

x についての情報のみを取り出すことで得られる分布である。このように、同時分布から特定の変数の影響のみを抽出することで得られる確率分布は**周辺分布**（marginal distribution）と呼ばれる。また、 y が与えられた下での x の確率分布は**条件付き確率**（conditional distribution）と呼ばれ、 $p(x|y)$ のように表現される。例えば退勤時間帯が 9 時台であった場合の所要時間の条件付き分布は $p(x|y=9)$ である。

ここで、 $p(x)p(y)=p(x, y)$ が成り立つ場合「 $p(x)$ と $p(y)$ は**独立**（independent）である」といわれ、 x と y は無関係に決まることとなる。しかしながら、図 3.23 を見ると、退勤時間 y が遅い場合に、所要時間 x が長い。したがって、この例では $p(x)$ と $p(y)$ は独立ではない。

上の例では離散値をとる確率変数（離散確率変数）の分布が $p(x)=\{\Pr(x=k_j), j=1, 2, \dots, m\}$ と表現されることを示した[†]。一方、連続値をとる確率変数（連続確率変数）の場合は、一つの値 k_j をとる確率は 0 となるため（数直線上の一点の長さはゼロであるように）、 $\Pr(x=k_j)$ ではなく、 x の値が区間 (a, b) に入る確率 $\Pr(a \leq x \leq b)$ を用いて分布が表現される。

さらに $\Pr(a \leq x \leq b) = \int_a^b f(x)dx$ が仮定される。

$f(x)$ はそれぞれの値の相対的な起こりやすさを表す**確率密度関数**（probability density function）と呼ばれる関数であり、 $f(x) \geq 0$ かつ $\int_{-\infty}^{\infty} f(x)dx=1$ である。

多くの統計分析では、母集団の特性を明らかにするためにデータになんらかの**理論分布**（theoretical distribution）があてはめられる。離散確率変数の場合は理論分布を $p(x)$ に直接あてはめ、連続確率変数の場合は理論分布を $f(x)$ にあてはめる。

[†] 厳密には、所要時間も時刻も連続変数であるが、上の例では、時間帯等の区間を設定して離散化している。

連続確率変数に対する代表的な理論分布として**正規分布** (normal distribution) が知られている。正規分布は提案者のドイツの数学者 Carolus Fridericus Gauss (1777~1855 年) の名を冠して**ガウス分布** (Gaussian distribution) とも呼ばれる。正規分布はつぎの確率密度関数に従う。

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (3.99)$$

正規分布は平均 μ と分散 σ^2 のみに依存する分布であり $N(\mu, \sigma^2)$ のように表記する。正規分布を例示した図 3.24 からわかるように、 μ は分布の位置を決めるパラメーター、 σ^2 は分布の幅を決めるパラメーターである。また、正規分布は**再生性** (reproductive property) を有し、二つの正規分布 $N(\mu_1, \sigma_1^2)$ と $N(\mu_2, \sigma_2^2)$ から独立に生成した二つの確率変数の和は正規分布 $N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ に従う。




図 3.24 正規分布の例

いま、 N 個の変数 $w_j (j=1, \dots, N)$ に依存する連続確率変数 x を $x = \frac{1}{N} \sum_{j=1}^N w_j$ と表現する。 N が十分に大きな数であり、 w_j が平均 μ 、分散 σ^2 の任意の分布に従って独立に発生していると仮定すると、 x は w_j の分布によらず正規分布 $N(\mu, \sigma^2/N)$ に収束することが知られている (**中心極限定理**, central limit theorem)。そのため、正規分布は、多数の要因の影響を受けて実現値が決まるような連続確率変数のばらつきを表現する確率分布として重要視されてきた。なお、 $N(0, 1)$ は**標準正規分布** (standard normal distribution) と呼ばれている。

非負の離散確率変数に対する代表的な確率分布に次式で定義される**ポアソン分布** (Poisson distribution) がある。

$$p(x) = \frac{\lambda^x e^{-\lambda}}{x!} \quad (3.100)$$

ここで、 λ はパラメーター、 e は自然対数の底 (= 2.7182...) である。ポアソン分布は「ある一定の期間あるいは領域において平均的に λ 回発生することが期

待されるランダムな事象が x 回発生する確率」を求めることで得られる確率分布であり、その平均と分散はともに λ となる。例えば、交通事故発生数や犯罪件数のばらつきはポアソン分布で表現できる。なお、独立なポアソン分布の和はポアソン分布となる (再生性)。いくつかのポアソン分布の例を図 3.25 に示す。




図 3.25 ポアソン分布の例

離散確率変数と連続確率変数の**期待値** (expectation) は、それぞれ式 (3.101)、(3.102) で定義される。

$$E[x] = \sum_j k_j \Pr(x = k_j) \quad (3.101)$$

$$E[x] = \int_{-\infty}^{\infty} x f(x) dx \quad (3.102)$$

正規分布に従う確率変数の期待値は μ 、ポアソン分布に従う確率変数の期待値は λ となる。

以上で説明した $\Pr(x=X)$ や $\Pr(a \leq x \leq b)$ に加え (X は任意の実数)、一定以下 (以上) の値をとる確率 $\Pr(x \leq X)$ を知ることが、例えば後述の仮説検定などで重要となる。 $\Pr(x \leq X)$ をとり得るすべての X について並べた関数は**累積分布関数** (cumulative distribution function) と呼ばれる。累積分布関数 $F(X)$ は、離散確率変数に対しては $F(X) = \sum_{x \leq X} p(x)$ 、連続確率変数に対しては $F(X) = \int_{-\infty}^X f(x) dx$ で定義される。 $F(X)$ は定義から非減少関数であり、 $\lim_{X \rightarrow \infty} F(x) = 1$ かつ $\lim_{X \rightarrow -\infty} F(x) = 0$ である。正規分布の累積分布関数の例を図 3.26 に示す。




図 3.26 正規分布の累積分布関数の例

理論分布となる確率分布は、このほかにもこれまでに数多くのものが知られており、データの特性に応じて適切に選択する必要がある。確率分布について詳しくは養谷⁴⁾を参照されたい。

〔6〕 統計モデルと推定

通常、統計分析はデータになんらかの統計モデルをあてはめることで行われる。例えば、連続値をとるデータであれば正規分布を統計モデルとして用いることで後述の仮説検定などが可能となる。統計モデルのあてはめは、データに最も適合するパラメーター θ （例えば正規分布の場合であれば平均 μ あるいは分散 σ^2 ）の値をデータ $\mathbf{x} = \{x_1, \dots, x_n\}$ の関数 $\hat{\theta}(\mathbf{x})$ で推定することで行う。この関数は**推定量** (estimator) と、またその実現値は**推定値** (estimate, estimated value) と、それぞれ呼ばれる（簡単のため、以降では $\hat{\theta}(\mathbf{x})$ は $\hat{\theta}$ と表記する）。

$\hat{\theta}(\mathbf{x})$ を例えば $\sum_i w_i x_i$ で与えることを考える。 w_i は標本 i の重みでありデータ $\mathbf{x}$ から推定する。 $\hat{\theta}(\mathbf{x}) = \sum_i w_i x_i$ は、**線形性** (linearity) を有する、すなわち変数 x_i の加重和（線形和、線形結合）で表現される意味で、**線形推定量** (linear estimator) と呼ばれる。

推定量 $\hat{\theta}$ が満たすことが望ましい統計学的な性質に**不偏性** (unbiasedness)、**有効性** (efficiency)、**一致性** (consistency) がある。不偏性とは $\hat{\theta}$ の期待値 $E[\hat{\theta}]$ が θ の理論値に一致すること、すなわち $E[\hat{\theta}] = \theta$ を満たす性質である。有効性とは不偏性を満たす推定量の中で $E[(\theta - \hat{\theta})^2]$ が最小であるという性質である。一致性とは標本数が大きくなるにつれて $\hat{\theta}$ が一意的値に収束する性質であり、任意の数 $\varepsilon > 0$ に対して $\lim_{n \rightarrow \infty} \Pr(|\theta - \hat{\theta}| > \varepsilon) = 0$ となる性質を意味する。それぞれの性質のイメージを図3.27に示す。

これまで、不偏性、一致性、有効性を有するさまざまな推定量（線形推定量以外にも含む）が提案されてきた。ここでは代表的な推定法として**最小二乗法** (least squares method) と**最尤法** (maximum likelihood method)

の二つを紹介する。

最小二乗法とは残差二乗和の式(3.103)を最小化する θ を推定する手法である。

$$\frac{1}{n} \sum_{i=1}^n w_i \{x_i - f_i(\theta)\}^2 \quad (3.103)$$

ここで w_i は i 番目の標本の重みである。 f_i には線形和 $\sum_p z_{i,p} \beta_p$ が仮定されることが多い。 $z_{i,p}$ は x_i を説明し得る p 番目の変数、 β_p はその影響の強さを表すパラメーターである。 w_i にはいろいろな値のとり方があるが、特に $w_i = 1$ とし、また $f_i = \sum_p z_{i,p} \beta_p$ とした場合の最小二乗法は**通常最小二乗法** (ordinary least squares method) と呼ばれる（詳しくは3.2.3項参照）。 $f_i = \sum_p z_{i,p} \beta_p$ を仮定した場合の最小二乗推定量は標準的な仮定の下では不偏性、一致性、有効性を有し、また、一般に $f_i \neq \sum_p z_{i,p} \beta_p$ とした場合でも一致性は成り立つことが知られている（養谷⁵⁾）。

なお、最小二乗法は二次モーメントの最小化を行う手法であるが（式(3.98)参照）、より高次のモーメントまで考慮しようという**一般化モーメント法** (generalized method of moments) もまた幅広い適用が見られる推定法である。

最尤法とは標本データの分布パターンに最も近い確率分布を求める方法である。例えば、ある標本データを正規分布に当てはめる場合であれば、観測値の組合せが起こる確率（**尤度**, likelihood）が最大となるような正規分布（のパラメーター μ と σ^2 ）を推定することとなる。観測値 x_i の起こりやすさは x_i を確率密度関数式(3.97)に代入した $f(x_i)$ で評価できるため、確率の乗法定理を用いれば、観測値の組合せ $\{x_1, x_2, \dots, x_n\}$ の起こりやすさは $L = f(x_1)f(x_2) \dots f(x_n)$ となる。 L は**尤度関数** (likelihood function) と呼ばれ、これを最大化する μ と σ^2 を求めることとなる。ただし、積を繰り返す L は非常に小さな値をとり得るため、実際には対数尤度 $\log L = \sum_i [\log f(x_i)]$ を最大化することが多い。先述の正規分布の例において対数尤度は式(3.104)となる。

$$\begin{aligned} \log L &= \sum_{i=1}^n \log \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right) \right] \\ &= -n \log(\sqrt{2\sigma^2}) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \end{aligned} \quad (3.104)$$

$\log L$ を最大化する μ と σ^2 は、それぞれ $\partial \log L / \partial \mu = 0$ と $\partial \log L / \partial \sigma^2 = 0$ を解くことでつぎのとおり求められる。

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i \quad (3.105)$$

† 最小二乗推定量は、一般に後述の漸近正規性も有する。




図3.27 推定量に望まれる性質。 $\hat{\theta}_1$ は望ましい推定量、 $\hat{\theta}_2$ はそうでない推定量を表す。

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2 \quad (3.106)$$

ここで式 (3.106) は不偏分散の式 (3.96) に一致しないことがわかる。しかしながら、標本数 n を大きくするにつれて式 (3.106) は不偏分散に近づく。この「近づく」性質は**漸近性** (asymptotic property) と呼ばれる。

尤度を最大化する推定量 $\hat{\mu}$ や $\hat{\sigma}^2$ は**最尤推定量** (maximum likelihood estimator) と呼ばれる。一般に最尤推定量はつぎの特性を有する (養谷⁵⁾)、一致性；漸近的正規性 (n を大きくするにつれて推定量の確率分布が正規分布に近づく)、漸近の有効性 (漸近的不偏性と漸近的正規性を有する推定量の中で最も分散が小さくなる)。また多くの場合、不偏性あるいは漸近的不偏性 (n を大きくするにつれて推定量の偏りが小さくなる (不偏となる)) も成り立つことが知られている。

以上で説明した一つの値 $\hat{\theta}$ を推定する**点推定** (point estimation) のほかに、パラメーターが入る区間を推定する**区間推定** (interval estimation) がある。一般に、パラメーター θ が区間 (I_1, I_2) で値をとる確率が $\alpha[\%]$ であれば、この区間は θ の $\alpha[\%]$ **信頼区間** ($\alpha[\%]$ confidence interval) と呼ばれる。 α は 90, 95, 99% など与えられる。

例えば、正規分布の母平均 μ の 95% 信頼区間を求めたいとする。正規分布は μ を中心に左右対称であり、中心極限定理に基づけば、 μ の分布は n が十分に大きくなるにつれて $N(\hat{\mu}, \hat{\sigma}^2/n)$ に収束する。したがって、 μ の 95% 信頼区間は次式で表現できる。

$$\hat{\mu} - c\sqrt{\frac{\hat{\sigma}^2}{n}} \leq \mu \leq \hat{\mu} + c\sqrt{\frac{\hat{\sigma}^2}{n}} \quad (3.107)$$

標本数が十分に大きければ c は 1.96 となる。これは標準偏差 $\sqrt{\hat{\sigma}^2/n}$ の 1.96 倍が正規分布の上裾 2.5% の点 (すなわち $\Pr(\hat{\mu} + 1.96\sqrt{\hat{\sigma}^2/n} \leq \mu) = 2.5\%$) であることから与えられる (図 3.28 参照)。式 (3.107) は正規分布の [上側 47.5%] + [下側 47.5%] で 95% 信頼区間を与える式である。適切な c の値は標本数と α




図 3.28 正規分布の母平均 μ の 95% 信頼区間のイメージ。
ここでは $\sigma_x = \sqrt{\hat{\sigma}^2/n}$ とした。

によって変化する。そのため、標本数別 α 別に c の値 (通常、それらが整理された正規分布表を基に) を与える必要がある。

さて、最尤法のような、母集団の分布になんらかの仮定を置くパラメーター推定法は**パラメトリック推定**と呼ばれる。これに対し、母集団の分布に一切の仮定を置かない推定法は**ノンパラメトリック推定法**と呼ばれる。例えば、カーネル関数を用いた平滑化によりデータに最も適合する関数を特定するカーネル密度推定は、代表的なノンパラメトリック推定法の一つである。ノンパラメトリック推定はデータに分布を仮定することが困難な場合などに用いられ、標本数が小さい場合でも比較的良好な結果を与える傾向である、すなわち**頑健** (robust) であることが知られている。一方で、データがなんらかの分布に従う場合は、パラメトリック推定の有効性がノンパラメトリック推定を上回ることが知られており、どちらを用いるかは頑健性と有効性のトレードオフを踏まえて決める必要がある。

最尤法が、データ $\mathbf{x}$ が得られる確率 $p(\mathbf{x}|\theta)$ を最大にするパラメーター $\theta = \{\theta_1, \dots, \theta_p\}$ を探索する手法であるのに対し、**ベイズ推定** (Bayesian estimation) 法はデータが所与の下で θ が得られる確率 $p(\theta|\mathbf{x})$ を最大にするパラメーター推定法として知られている。ベイズ推定を行うことで尤度の評価が困難となるような複雑なモデルの推定が可能となる場合があり、近年その議論が活発化している (例えば、安道⁶⁾ 参照)。

[7] 仮説検定

仮説検定 (hypothesis testing) とは、あらかじめ定めた母集団についての仮説が**真** (true) か**偽** (false) かを検定することである。その一般的な方法では、まずは (a) 否定したい**帰無仮説** (H_0 : null hypothesis) と、帰無仮説を否定することで立証したい**対立仮説** (H_1 : alternative hypothesis) を設定する。例えば節電キャンペーンの前後で住民の電力使用量が変化したかを検定したい場合の帰無仮説 H_0 は $\bar{x}_{bef} = \bar{x}_{af}$ 、対立仮説 H_1 は $\bar{x}_{bef} \neq \bar{x}_{af}$ となる。ここで $\bar{x}_{bef}$ と $\bar{x}_{af}$ はそれぞれキャンペーン前後の平均電力使用量を表す。つぎに (b) 帰無仮説、上の例であれば「キャンペーン前後で平均電力使用量が変化していない ($\bar{x}_{bef} = \bar{x}_{af}$)」が真である確率 $\hat{p}$ を評価する。最後に、(c) この確率 $\hat{p}$ があらかじめ決めた**有意水準** (significance level) p を下回れば帰無仮説を**棄却** (reject) して対立仮説を**採択** (accept) する。例えば $p = 0.05$ の場合、帰無仮説が真である確率 $\hat{p}$ が 0.05 未満であれば帰無仮説を棄却する。

有意水準 p としては 0.10, 0.05, 0.01 などが用いられる。 p を小さくすることで、「帰無仮説が真であ

るにもかかわらず対立仮説を採択する」という**第一種の過誤** (type I error) を減らすことができる。しかしながら、有意水準を小さくしすぎると帰無仮説を採択する確率が限りなく0に近付く。したがって、 p は第一種の過誤の起こりやすさをどの程度まで許容するかを踏まえて慎重に設定する必要がある。一方、「対立仮説が真であるにもかかわらず帰無仮説を採択する」という**第二種の過誤** (type II error) は、標本数を増やしたりモデルを適切に選択したりすることで減らすことができる。

上述の手順 (a)～(b) では、帰無仮説が真である確率 $\hat{p}$ を評価することで仮説を検定している。 $\hat{p}$ はデータに確率分布をあてはめることで評価できる。先の例であれば、キャンペーン前の電力使用量が正規分布 $N(\bar{x}_{bef}, \sigma^2)$ に従うと仮定すれば、キャンペーン前の平均電力使用量は $N(\bar{x}_{bef}, \sigma^2/n)$ に従う[†]。したがって、帰無仮説 $\bar{x}_{bef} = \bar{x}_{af}$ の下でのキャンペーン後の平均電力使用量は $N(\bar{x}_{af}, \sigma^2/n)$ となる。ここで σ^2 は母分散である以上の結果を用いると、 $\bar{x}_{af}$ と $\bar{x}_{bef}$ の差の分布を基準化した z は標準正規分布 $N(0, 1)$ に従うことがわかる (式 (3.108) 参照)。

$$z = \frac{\bar{x}_{af} - \bar{x}_{bef}}{\sqrt{\frac{\sigma^2}{n}}} \quad (3.108)$$

そのため、 z がどの程度0に近いかを見ることで帰無仮説 $\bar{x}_{bef} = \bar{x}_{af}$ が正しいか否かが検定できる (図 3.28 参照)。この検定方法は **z 検定** (z -test)、また式 (3.108) の値は **z 値** (z -value) と呼ばれる。

母分散 σ^2 が未知の場合は、式 (3.108) の σ^2 を標本分散 s^2 に置き換えた **t 値** (t -value) 式 (3.109) が検定に用いられる。 t 値による検定は **t 検定** (t -test) と呼ばれる。

$$t = \frac{\bar{x}_{af} - \bar{x}_{bef}}{\sqrt{\frac{s^2}{n}}} \quad (3.109)$$

t 値の確率分布 (**t 分布**, t -distribution) は標本数が小さくなるにつれて裾野が広くなり、また標本数が大きくなるにつれて正規分布に近付く。 t 検定は、標本数が小さい場合でも妥当な結果を与える傾向がある、すなわち**頑健** (robust) といわれる。

z 値や t 値を用いた検定には2種類ある。一つめは $H_0: \bar{x}_{bef} = \bar{x}_{af}$, $H_1: \bar{x}_{bef} \neq \bar{x}_{af}$ のように一方と他方が等しいかどうかを検定する**両側検定** (two-sided test) である。有意水準 p [%] での両側検定を行う場合であれば、分布の下裾 $p/2$ [%] 未満または上裾 $p/2$ [%]

以上であれば対立仮説を採択する (図 3.29 (a) 参照)。もう一つは、 $H_0: \bar{x}_{bef} = \bar{x}_{af}$, $H_1: \bar{x}_{bef} > \bar{x}_{af}$ のように一方が他方よりも大きい (小さい) かどうかを検定する**片側検定** (one-sided test) である。有意水準 p [%] での片側検定を行う場合、分布の上裾 (下裾) p [%] 未満であれば対立仮説を採択する (図 3.29 (b) 参照)。




図 3.29 $p=5\%$ の場合の両側検定 (図 (a) 参照) と片側検定 (図 (b) 参照) のイメージ。ここで $\sigma_x = \sqrt{\sigma^2/n}$ である (z 検定の場合)。 $\bar{x}_{af}$ が網掛け部分のエリア (棄却域) に入れば帰無仮説が棄却され、対立仮説 H_1 が採択される。

なお、仮説検定の方法にはここで紹介した方法以外にもさまざまな方法が存在する。仮説検定について詳しくは東京大学教養学部統計学教室⁷⁾などを参照されたい。(村上大輔)

3.2.3 標準的な統計解析の指標・手法

統計解析に用いられる指標や手法には、多種多様なものがあり、それらを本書の限られた紙面の中で網羅的に説明することは不可能に近い。ここでは、それらの中で、最も基礎的かつ土木計画学の分野において用いられることの多い統計指標と**多変量解析** (multivariate analysis) 手法を紹介する。

多変量解析とは、多変量間の関係を統計学的手法に基づきデータ解析することの総称である。多変量解析にはさまざまな手法があるが、以下では、武藤⁸⁾に従って、データ解析の目的とそのおもな解析手法を列挙する (下線は、[2]～[6] で扱う手法を示す)。

- ① ある特定の要因の予測: 回帰分析, 数量化理論Ⅰ類
- ② 対象の分類: 判別分析, 数量化理論Ⅱ類
- ③ 対象の類似度の測定: 正準相関分析, 数量化理論Ⅲ類, クラスター分析
- ④ 対象の特性を要約する総合的指標の作成: 主成分分析
- ⑤ 各要因間の関係を説明: 因子分析
- ⑥ 各要因の効果およびその交互作用についての検定・推定: 分散分析, 共分散分析
- ⑦ 各要因・各対象の関係を表す尺度の構成: 数量

[†] 中心極限定理を用いた。

化理論Ⅳ類

以下、〔1〕では、本格的な統計解析を行う前の変量間の予備的な分析において最もよく用いられる指標の一つである相関係数について説明する。続いて、〔2〕において回帰分析について説明し、その後〔3〕～〔6〕において、主成分分析、因子分析、判別分析、クラスター分析について説明する。これらとは別に、①と②の双方の分析目的で、土木計画学において用いられることの多い離散選択モデルについて、〔7〕で簡単に説明する。

ところで、わが国においては統計学者の林知己夫氏によって開発された数量化理論(Hayashi's quantification methods)に基づく手法もデータ解析の中で広く用いられてきた。土木計画学においても、いまなお盛んに数量化理論が用いられている。しかし、例えば数量化Ⅰ類と呼ばれる手法は質的変数 X によって量的変数 Y (外的基準と呼ばれる)を予測する手法であるが、〔2〕で説明する量的変数 X を用いる回帰分析において、説明変数にダミー変数または代理変数(dummy variable, 質的データ(3.2.2項〔1〕参照)に対して例えば男性は0, 女性は1のように、代理の数字によって表したものを)を用いたものであり、同様にして、質的変数 X によって質的変数 Y を予測する手法である数量化Ⅱ類は、量的変数 X を用いる判別分析と類似するため、あえてそれらについてここで触れることはしない(なお、数量化理論は元来Ⅰ類からⅥ類までであったが、現在でも使用されているのはⅠ類からⅣ類までの手法にとどまるようである)。詳細は武藤⁸⁾などを参照されたい。

ここで扱う伝統的な多変量解析に加え、特に、人々の行動とその背後にある意識や心理のような、観測できない要因が多数に絡み合った現象を分析する際には、因子分析、主成分分析、回帰分析、パス解析を組み合わせて拡張した共分散構造分析などの手法も、土木計画分野では盛んに用いられている(それに用いるモデルは構造方程式モデル, structural equation model と呼ばれる)。これについては、豊田⁹⁾などの文献を参照されたい。

その他、多次元尺度構成法(multi-dimensional scaling, MDS)などの手法も土木計画で用いられることの多い統計解析手法である。

なお、ここで扱う解析の手法は、原則としてクロスセクションのデータ(cross section data), すなわちある一時点のデータを前提としている。時系列データを原系列のまま伝統的な多変量解析の手法に適用することは誤った結果を導く場合が多いため、注意を要する。本来であれば、本書でも時系列データの統計分析

手法について説明すべきであるが、時系列解析(time series analysis)は統計学の中で一つの分野ともいえるほどの内容があるため、ここでは説明を割愛する。単変量/多変量の時系列データの分析については山本¹⁰⁾や沖本¹¹⁾を参照されたい。

さらに近年では、個別主体に関するデータが時系列的にも標本として得られているパネルデータ(panel data)が広く利用可能となっている。マーケティングの分野やミクロ計量経済学と呼ばれる分野を中心に、パネルデータ分析(analysis of panel data)に関する研究の進展も著しい中、土木計画学の分野においても時系列解析と併せて重要な内容となりつつある。これについては、シャオ¹²⁾などを参照されたい。

(堤 盛人)

〔1〕相 関 係 数

一般に、二変量間の関係を相関関係と呼び、特に統計学では二変量間の直線(線形)関係について相関関係という語を用いる。両変数ともに質的データの場合は分割表(contingency table)またはクロス表(cross table), 連関表が用いられる。一方の変数が質的データでもう一方が量的データの場合は、量的データの側を適当な階級で分割することで分割表の形式を用いることができ、これは相関表と呼ばれる。二変量の関係を表によってではなく一つの代表値(スカラー)として表す際に相関係数(correlation coefficient)が用いられる。

ここでは、二変量の分割表について考える(なお三変量の分割表は多重分割表と呼ばれる)。第一の変数 A が $A_1, \dots, A_k$ の k カテゴリー、第二の変数 B が $B_1, \dots, B_l$ の l カテゴリーである場合、分割表は表3.6のように表される。

表3.6 $k \times l$ 分割表

$A \setminus B$	B_1	$\dots$	B_l	計
A_1	f_{11}	$\dots$	f_{1l}	$f_{1\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
A_k	f_{k1}	$\dots$	f_{kl}	$f_{k\cdot}$
計	$f_{\cdot 1}$	$\dots$	$f_{\cdot l}$	n

ここで、実測度数を f_{ij} とするセル (i, j) の期待度数は

$$F_{ij} = \frac{f_{i\cdot} f_{\cdot j}}{n} \quad (3.110)$$

によって定義される。任意の (i, j) に対して

$$f_{ij} = \frac{f_{i\cdot} f_{\cdot j}}{n} \quad (3.111)$$

が成立するとき、変数 A と変数 B は**独立**である。二変量間の関連の強さはカイ二乗 (χ^2)

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^l \frac{(F_{i,j} - f_{i,j})^2}{F_{i,j}} \quad (3.112)$$

によって測定することができる。カイ二乗は

$$0 \leq \chi^2 \leq n \times \min(k-1, l-1) \quad (3.113)$$

の範囲の値をとり、無連関の場合には 0 を、高い連関の場合には高い値をとる。最大値をとる場合は完全連関の状態にある ($k=l$)、または最大連関の状態にある ($k \neq l$) と呼ばれる。

相関係数には積率相関係数と順位相関係数があるが、単に相関係数と表記されている場合はピアソンの**積率相関係数** (Pearson product moment correlation) を指す場合が多い (例えば、東京大学教養学部統計学教室⁷⁾)。ピアソンの積率相関係数 $r_{x,y}$ は二変量 (x, y) の量的データに対して適用され、次式によって与えられる。

$$r_{x,y} = \frac{\text{Cov}(x,y)}{\sqrt{V(x)}\sqrt{V(y)}} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} \quad (3.114)$$

ここで、 $\text{Cov}(x, y)$ は上の式の分子で定義される二変量 (x, y) の**共分散** (covariance)、 $V(x)$ 、 $V(y)$ は、 x, y の分散をそれぞれ表す。

$r_{x,y}$ は -1 から 1 までの値をとり、1(-1) に近い値の場合には両変数が正(負)の相関関係にあると呼ぶ。変数のうち少なくとも一方が順序尺度の場合、ピアソンの積率相関係数ではなく**順位相関係数** (rank correlation coefficient) を適用する。順位相関係数の定義としてはスピアマン (Spearman) による定式化とケンドール (Kendall) による定式化が知られている。

ここで、相関関係は**因果関係** (causality) の必要条件でも十分条件でもないことに留意が必要である。いかなる因果関係にもない二変量であっても、**疑似相関** (spurious correlation) によって強い相関関係を示す相関係数が計算される場合があり、逆に非線形的な因果関係のためにピアソンの積率相関係数では相関関係を捉えられない場合もある。疑似相関を生じさせている第三の変数 (交絡因子と呼ばれる場合がある) が既知である場合には、この第三の変数 (z) の影響を除外した二変量 (x, y) の線形関係を**偏相関係数** (partial correlation coefficient)

$$r_{x,y|z} = \frac{r_{x,y} - r_{x,z}r_{y,z}}{\sqrt{1-r_{x,z}^2}\sqrt{1-r_{y,z}^2}} \quad (3.115)$$

によって計算することができる。ここで、 $r_{x,y}$ 、 $r_{x,z}$ 、 $r_{y,z}$ は、それぞれ式 (3.114) に基づく。

なお、相関係数を用いた分析という意味で、「相関分析」という用語もよく見かけるが、『統計学辞典』(竹内編¹³⁾) やその他の多くの専門書の索引には掲載されておらず、以下の〔2〕以降と比べた際に統計解析手法と呼ぶほどの内容に乏しいため、本書では〔2〕以降の手法とは区別して指標としての相関係数という見出しとした。

〔2〕回 帰 分 析

回帰分析 (regression analysis) は統計的方法の中で最も広く使用されており、変数 X, Y のデータの関係を**回帰式** (回帰方程式, regression equation) によって定量的に表すものである。 Y を**従属変数** (dependent variable)、**応答変数** (response variable)、**被説明変数** (explained variable) などと呼び、 X を**独立変数** (independent variable)、**説明変数** (explanatory variable) などと呼ぶ。以下、ここでは、それぞれ被説明変数、説明変数と表記することとする。

(1) **回帰方程式** 最も標準的な分析では Y と X の関係を、未知の定数 β_0, β_1 (パラメーター (母数) (parameter) と呼ぶ) を用いて次式のように表す。

$$Y = \beta_0 + \beta_1 X \quad (3.116)$$

この式を**回帰方程式** (regression equation)、**回帰関数** (regression function) などと呼び、「 Y を X に回帰する」と表現する。

式 (3.114) のように、被説明変数をパラメーターの線形関数 (線形結合) で仮定する場合を**線形回帰** (linear regression) と呼ぶのに対し、それ以外の非線形的な関係を仮定する場合を**非線形回帰** (non-linear regression) と呼ぶ。ここでは前者のみを扱うこととする。

実際に観測される Y や X の複数のデータに関して、同一の回帰方程式が厳密に満たされることはきわめてまれである。そこで、回帰方程式に**誤差項** (error term) ε を導入した

$$Y = \beta_0 + \beta_1 X + \varepsilon \quad (3.117)$$

を**回帰モデル** (regression model) あるいは母回帰方程式 (population regression equation) と呼ぶ。ここで誤差項 ε は**攪乱項** (disturbance term) とも呼ばれる。 β_0, β_1 は(母) **回帰係数** ((population) regression coefficient) または母集団偏 (partial) 回帰係数と呼ばれる。

回帰分析においては複数の変数 ($X_1, X_2, \dots$) が説明変数として採用されることも多く、このような回帰分析を、式 (3.117) のような説明変数が一つの場合

の単回帰 (simple regression) モデルと区別して重回帰 (multiple regression) モデルと呼ぶ場合があるが、本書では特に両者を区別することなく単に回帰モデル、あるいは回帰分析のように呼ぶこととする。サンプルのうち i 番目を Y_i のように示すこととすれば、定数項を除いて k 個の説明変数がある回帰モデルは次式で表される。

$$Y_i = \beta_0 + \beta_1 X_{i,1} + \beta_2 X_{i,2} + \beta_k X_{i,k} + \varepsilon_i \quad (3.118)$$

ここで、説明変数や回帰係数を

$$Y = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}, X = \begin{bmatrix} 1 & X_{1,1} & \cdots & X_{1,k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n,1} & \cdots & X_{n,k} \end{bmatrix}, \beta = \begin{bmatrix} \beta_0 \\ \vdots \\ \beta_k \end{bmatrix}, \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \quad (3.119)$$

のように行列ベクトル表記すれば、回帰モデルは

$$Y = X\beta + \varepsilon \quad (3.120)$$

と表される。 X の 1 列目は定数項部分に相当する。以降では行列ベクトル表記で記述する。

後述する最小二乗法などの方法によって推定された回帰係数を標本回帰係数と呼び、この標本回帰係数 $\hat{\beta}$ を用いて

$$\hat{Y} = X\hat{\beta} \quad (3.121)$$

とすると、実測値 Y とあてはめ値 $\hat{Y}$ の差

$$e = Y - \hat{Y} = Y - X\hat{\beta} \quad (3.122)$$

を計算できる。この e を残差 (residual) または回帰残差と呼ぶ。残差は誤差項の推定値に相当すると考えることができる。

古典的回帰モデル (classical regression model, CRM) では以下のような仮定が置かれる。

仮定 1 $E(\varepsilon) = 0$

仮定 2 $V(\varepsilon) = \sigma^2 I$ (誤差は均一分散で独立)

仮定 3 X は非確率で所与

σ^2 は定数 (分散) であり、仮定 1 と仮定 2 は

$$E(\varepsilon_i) = 0 \quad (\forall i) \quad (3.123)$$

$$V(\varepsilon_i) = \sigma^2 \quad (\forall i) \quad (3.124)$$

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0 \quad (i \neq j) \quad (3.125)$$

を意味しており、 $V(\varepsilon)$ は、分散共分散行列 (variance-covariance matrix) と呼ばれる。

これらの仮定の順番や記述の仕方は文献によって多少異なり、回帰モデルが線形であることを最初の仮定に加えるものもある。また、仮定 2 については、式 (3.124)、(3.125) のように (自己) 分散と共分散のそれぞれ別の仮定とするものもある。仮定 3 に関しては、 $(k+1) < n$ と

$$\text{rank}(X) = k+1 \quad (3.126)$$

が暗黙に仮定されているが、それらが明示的に仮定として示されている場合もある。

このあと説明するとおり、モデルのパラメーターを最尤法で推定する際や、推定されたモデルの有意性を検定する際には、上述の仮定に加えてつぎの仮定が追加される。

仮定 4 $\varepsilon \sim N(0, \sigma^2 I)$

これは、仮定 1 により $E(Y) = X\beta$ が成立することから、仮定 2 と仮定 3 により $Y \sim N(X\beta, \sigma^2 I)$ と同値である。

仮定 1~4 の仮定を満足する回帰モデルを、古典的正規回帰モデルと呼ぶことがある。

(2) **回帰係数の推定と検定** 回帰分析を行うには、現実を得られたサンプル (標本) によって真の回帰係数 (母回帰係数 β) の推定を行う必要がある。最も標準的な手法の一つは**最小二乗法** (ordinary least squares, method of least squares) であり、これはモデルの残差二乗和

$$e'e = \sum_{i=1}^n e_i^2 \quad (3.127)$$

を最小にするように母回帰係数を推定するものである。最小化問題の一階の条件

$$\frac{\partial}{\partial \beta} e'e = \frac{\partial}{\partial \beta} (y - X\beta)'(y - X\beta) = 0 \quad (3.128)$$

より回帰の正規方程式 (normal equation) $X'Y = X'X\beta$ が導出でき、これによって

$$\hat{\beta} = (X'X)^{-1}X'Y \quad (3.129)$$

が得られる。幾何学的には、誤差項ベクトル ε と説明変数ベクトル X が直交するときに誤差二乗和が最小となることを用いて、つぎのように求めることもできる。

$$0 = X'\varepsilon = X'(Y - X\beta) = X'Y - X'X\beta \quad (3.130)$$

最小二乗法によって推定された古典的回帰モデルの回帰係数は**最良線形不偏推定量** (best linear unbiased estimator, BLUE) となることが知られており、これを**ガウス・マルコフの定理** (Gauss-Markov theorem) と呼ぶ。ここで最良 (best) とは、最小分散のことを意味しており、線形かつ不偏な推定量の中で最小分散となる推定量が得られることを意味する (3.2.2 項 [5] 参照)。

被説明変数 Y が従う条件付きの分布が既知である場合、回帰係数は**最尤法** (maximum likelihood method) によって推定することもできる。最尤法とはパラメーター (回帰モデルの場合では回帰係数や誤差分散に相当) で条件付けた際のデータ (回帰モデルの場合では被説明変数 Y) の得られる確率を**尤度** (likelihood) として、データ (Y) の確率密度関数によって**尤度関数** (likelihood function) を定義し最大化することによってパラメーターを得る手法である。例えば仮定 4 が成

立する場合、既述のとおり被説明変数 Y が正規分布に従う。 i 番目の被説明変数 Y_i の確率密度関数 f は、 i 番目の説明変数ベクトル (X の第 i 行目を取り出した行ベクトルを転置した列ベクトル) を x_i と表すこととすると

$$f(Y_i | x_i, \beta, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (Y_i - x_i' \beta)^2 \right\} \quad (3.131)$$

であるから、尤度関数 L は

$$L = \prod_{i=1}^n f(Y_i | x_i, \beta, \sigma^2) \quad (3.132)$$

として定義される。この対数をとってつぎのような対数尤度関数とすることで、代数的な扱いが容易となる。

$$\begin{aligned} l = \log L &= \sum_{i=1}^n \log f(Y_i | x_i, \beta, \sigma^2) \\ &= -\frac{1}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - x_i' \beta)^2 \end{aligned} \quad (3.133)$$

対数尤度関数を最大化することは式 (3.133) の中で

$$\sum_{i=1}^n (Y_i - x_i' \beta)^2 = (Y - X\beta)'(Y - X\beta) = e'e \quad (3.134)$$

の部分を最小化することに等しくなる。つまり残差二乗和の最小化に等価となり、この場合、 β の最尤推定量は最小二乗推定量に一致する。

推定された個別の係数を検定する方法のうち、最もよく用いられる **t 検定** (t -test) について説明する。

上述の四つ目の正規性の仮定によって回帰係数の推定量が正規分布に従うことが導かれ、これによって j 番目の説明変数 X_j について

$$\frac{\hat{\beta}_j - \beta_j}{S_j} \sim t(n - (k+1)) \quad (3.135)$$

$$S_j = \sqrt{\frac{e'e}{n - (k+1)} (X'X)^{j,j}} \quad (3.136)$$

が成立する。 S_j は X_j の標本回帰係数 $\hat{\beta}_j$ の標準誤差 (standard error) であり、 $t(n - (k+1))$ は自由度 $\{n - (k+1)\}$ の t 分布を表し、 $(X'X)^{j,j}$ は行列 $X'X$ の j 行 j 列目の成分を表す。ここでは、 $\beta_0, \dots, \beta_k$ の合計 $(k+1)$ 個の未知パラメーターを有する回帰モデルを n 個のサンプルを用いて推定することを考えており、**自由度** (degree of freedom) とは、この未知のパラメーターが動くことのできる空間の次元数のことである (蓑谷^[4] 参照)。自由度がゼロのときには、誤差ゼロとして回帰方程式が解けてパラメーターが確定的に求まることとなる。

これによって、推定された標本回帰係数 $\hat{\beta}_j$ がある

特定の値 $\beta_{j,0}$ と有意に差があるか否かについて t 検定を行うことができる (3.2.2 項 [6] 参照)。

多くの場合では $\beta_{j,0} = 0$ 、つまり $\hat{\beta}_j$ が有意に 0 と異なる値をとるか否かを検定することが多い (帰無仮説: $\hat{\beta}_j = 0$)。

推定された標本回帰係数について個別に検定を行うのではなく係数の部分ベクトルに対して検定を行う場合は **F 検定** (F -test) が用いられる。詳細は、例えば浅野・中村^[15] を参照されたい。

(3) **回帰モデルの評価・診断とモデル選択** 推定された回帰方程式の当てはまりの良さ (説明変数 X が被説明変数 Y をどの程度説明したか) を測る基礎的な指標は決定係数 (coefficient of determination) R^2 であり、次式によって定義される。

$$R^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}} = 1 - \frac{\sum e_i^2}{\sum (Y_i - \bar{Y})^2} \quad (3.137)$$

決定係数の正の平方根は (**重**) **相関係数** ((multiple) regression coefficient) と呼ばれ、実測値 Y とあてはめ値 $\hat{Y}$ のピアソンの積率相関係数に等しい。**TSS** (total sum of squares) は被説明変数の平均 $\bar{Y}$ からの乖離の二乗和、**ESS** (explained sum of squares) は説明変数によって説明された変動、**RSS** (residual sum of squares) は TSS のうち説明変数によって説明されなかった変動であり、三者の間には $(\text{TSS}) = (\text{ESS}) + (\text{RSS})$ の関係が成り立つ。TSS は総変動、RSS は残差二乗和と呼ばれる。 R^2 は 0 から 1 の間の値を取り、 X が Y の変動を説明するのにまったく役立っていない場合は $R^2 = 0$ 、逆に X によって Y の変動を完全に説明できている場合には $R^2 = 1$ となる。

回帰モデルに説明変数を追加すれば残差二乗和 RSS は必ず減少するが、思考節約の原理 (「オッカムの剃刀」とか「ケチの原理」とも呼ばれる) の観点からはなるべく少ない説明変数が望ましい。そこで、説明変数の数の増加による ESS の上昇を割り引いたあてはまりの尺度として、次式で定義される **自由度修正 (済み) 決定係数** (adjusted coefficient of determination) (または **自由度調整済み決定係数**) が広く用いられている。

$$\begin{aligned} R^2 &= 1 - \frac{\text{ESS}}{\text{TSS}} \frac{n-1}{n - (k+1)} \\ &= 1 - (1 - R^2) \frac{n-1}{n - (k+1)} \end{aligned} \quad (3.138)$$

ただし、この自由度修正済み決定係数を、候補となる複数の回帰モデルの中でいずれのモデルを選択するか (**モデル選択** (model selection)) の基準としては用い

るべきではないとされる。

モデル選択の基準として広く用いられているのが**赤池情報量規準** (Akaike information criterion, **AIC**) である。AIC は一般に

$$\text{AIC} = -2 \log f(\mathbf{X}|\hat{\theta}) + 2p \quad (3.139)$$

で与えられる。 $\hat{\theta}$ は最大対数尤度をもたらすパラメータの推定量 (最尤推定量) で、 p はパラメータの数を示す。最大対数尤度は大きいほど説明力が高いため、それに負の定数 (-2) を乗じた第 1 項は小さいほどよく、モデルの複雑性を表現する第 2 項も小さいほどよい。モデル選択においては AIC がより小さいモデルが選択される。AIC は予測力の最大化を目的とした情報量規準であり、真のモデルを選択する規準としては定義されていない点に留意すべきである。AIC のほかに**ベイズ型情報量規準** (Bayesian information criterion, **BIC**) や**一般化情報量規準** (generalized information criterion, **GIC**) など複数の情報量規準があり、それぞれ適用の前提としている仮定や目的が異なる。詳細は小西・北川¹⁶⁾を参照されたい。

(4) **回帰分析を行う上での注意** 推定された回帰モデルは、ここまで説明した回帰係数の検定、決定係数等による評価に加えて、経済学的な理論基礎や長年にわたって一般に認められた定説などに基づく符号条件によっても検証・診断される。

古典的回帰モデルの仮定のうち、仮定 1 については、これが満足されるように定数項 (β_0) で調整可能であるので、通常憂慮する必要はない。

仮定 2 に対する違背のうち**不均一分散** (heterogeneity) に対しては、加重最小二乗法と呼ばれる方法が適用されることが多い。誤差項間が独立でない場合のうち、時系列データで頻繁に見られる**系列相関** (serial correlation) に対しては時系列分析の手法 (例えば山本¹⁰⁾) を適用する必要がある。地理空間データで頻繁に見られる**空間的自己相関** (spatial autocorrelation) に対しては空間計量経済学の手法 (例えば瀬谷・堤²¹⁾) を適用することができる。

仮定 3 (非確率的 X) の違背に対しては、いくつかの条件下では X 所与の下で導かれた結論を変える必要はない (簀谷¹⁷⁾)。 X の rank に対する違背に関連して多重共線性に起因する問題が知られている。

多重共線性 (multi-collinearity) は複数の説明変数が似通った変動をすることによって生じる現象で、推定される回帰係数の標準誤差が大きくなるという問題を引き起こす。説明変数のうちいずれかが他の説明変数の一次結合によって表されるとき、つまり $X_1 = a + bX_2$ のような関係が成立しているときは説明変数間に

完全な多重共線性が存在すると呼ばれる。例えば、男性を 1 とするダミー変数と女性を 1 とするダミー変数を両方説明変数としてモデルに投入した場合には、このような問題が生じる。完全な多重共線性が生じている場合、回帰係数を推定することはできない (式 (3.126) が満たされず、 $(X'X)^{-1}$ が存在しないため)。完全ではない多重共線性が生じている場合には回帰係数を数值的に計算することはできるものの、係数の標準誤差が大きくなる、データのわずかな変動に対して推定値が過敏に反応する (推定の不安定性) という問題が生じる。回帰係数の標準誤差が大きくなることで t 値は小さくなり、個別の回帰係数についての帰無仮説は棄却されにくくなる。またデータの小さな変動に対して不安定になるために、回帰係数の推定値が理論的に想定される値や許容範囲から著しく乖離する可能性がある。多重共線性を検出するために一般的に用いられるのは**分散拡大因子** (variance inflation factor, **VIF**) (分散増幅因子ともいう) で、 j 番目の説明変数に対しては

$$\text{VIF}_j = \frac{1}{1 - R_j^2} \quad (3.140)$$

によって定義される。ここで R_j^2 は j 番目の説明変数を他の説明変数 ($\{1, \dots, j-1, j+1, \dots, k\}$ 番目の説明変数行列) に回帰した際に得られる決定係数である。VIF が 5 から 10 程度の大きさを超えている説明変数については多重共線性が生じていると判断されるケースが多い。計量経済学の立場からは、多重共線性を生じさせている説明変数を回帰モデルから除外することは、特定化の誤りを起こし望ましくないとの見方があるが (浅野・中村¹⁵⁾)、工学的な観点からは別の変数に置き換えることも行われ得る (奥村¹⁸⁾)。また、リッジ回帰 (ridge regression) などの正則化手法や [3] の最後で説明する主成分回帰を適用することもある。

仮定 4 (Y の正規性) を満たさない場合、変数の**対数変換** (logarithmic transformation) や対数変換を特殊形として含む **Box-Cox 変換** (Box-Cox transformation) (例えば、簀谷¹⁴⁾) を適用して対処することが多い (これらは、誤差項の不均一分散への対処法として用いられることも多い)。あるいは一般化線形モデルの適用などが試みられる (ドブソン¹⁹⁾ 参照)。

回帰モデルにおいて推定されたパラメーターは、検定のところでも説明したとおり誤差を含む確率変数である。したがって、推定されたパラメーターを用いて計算された被説明変数の推計 (**予測**, forecast) 値も確率変数であり、誤差 (予測誤差) を含むことに十分

留意が必要である。予測値とその信頼区間に関しては、^[14] 養谷^[14]などを参照されたい。

(黒田 翔・堤 盛人)

〔3〕主成分分析

主成分分析 (principal component analysis) は、〔4〕で説明する因子分析手法の一つとして提案されたという経緯があるが、現在では異なるものとして区別して考えるのが一般的である。

主成分分析は、データの持つ情報を縮約するための多変量解析手法の一つである。例えば、高齢化率と空家率という二次元の情報を「まちの年齢」という一次元の情報に縮約する例を考えよう（まちの年齢というのはここで便宜的に付けた名称に過ぎない）。図 3.30 において、一つひとつの○は地区の（空家率、高齢化率）という二次元データを座標軸上でプロットしたものである。ここに、まちの年齢という新たな軸を導入し、この座標軸のみでサンプルの特徴を捉えることを考える（例えば、○から新たな軸に垂線を下ろし、その足から原点までの距離によって特徴を捉える）。軸（ア）と軸（イ）を比較すると、軸（ア）の方が各地区の差異をうまく捉えられる。主成分分析は、このように、（サンプルのちらばり）≡（分散）を最大化する方向に軸を設定するのである。




図 3.30 主成分分析の考え方

このことを、空家率と高齢化率の二変量の例で見よう。空家率を表す変数を y_1 、高齢化率を表す変数を y_2 とする。サンプルサイズを n とすれば、各データは、高齢化率と空家率のペアとして

$$y_1 = (y_{1,1}, y_{2,1})', y_2 = (y_{1,2}, y_{2,2})', \dots, y_n = (y_{1,n}, y_{2,n})' \quad (3.141)$$

と書ける。これらのデータを、「まちの年齢」を表す Z 軸に射影すると、 i 番目のサンプルは

$$Z_i = w_1 y_{1,i} + w_2 y_{2,i} = w' y_i \quad (3.142)$$

によって与えられる（ただし、 $w = (w_1, w_2)'$ は係数ベクトル）。 $Z_1, \dots, Z_n$ の平均と標本分散は、それぞれ

$$\bar{Z} = w' \bar{y} \quad (3.143)$$

$$s^2 = w' S w \quad (3.144)$$

となる（小西^[20]）。ただし、 $\bar{y} = (\bar{y}_1, \bar{y}_2)'$ は標本平均から成るベクトル、 S は 2×2 次元の標本分散共分散行列であり、合成変数 Z の分散は、いわゆる二次形式の形で与えられる。

前述のとおり、主成分分析では、合成変数の分散を最大にするように軸を定める。したがって、 $w' S w$ を最大化すればよい。ただし、係数を大きくすればするほど分散はいくらでも大きくできるため、通常 $w' w = 1$ という制約を置く。本制約下での分散最大化問題は、ラグランジュの未定乗数法を用いて次式のように定式化できる。

$$F(w, \lambda) = w' S w + \lambda(1 - w' w) \quad (3.145)$$

F を w で微分して 0 と置けば、 $S w = \lambda w$ が得られる。この解は、固有方程式 $|S - \lambda I| = 0$ （ただし、 $| \cdot |$ は行列・の行列式）を解くことによって得られる最大固有値 λ_1 に対応する固有ベクトル $w_1 = (w_{11}, w_{12})'$ である。ここで、第 1 主成分 Z_1 は $Z_1 = w_1' y$ によって得られ、第 1 主成分の分散は $s_{z_1}^2 = w_1' S w_1 = \lambda_1$ と固有値そのものによって与えられる（小西^[20]）。第 2 主成分は、式 (3.145) の最適化問題に、 w と w_1 が直交するという条件： $w_1' w = 0$ を加えればよいから、分散最大化問題は

$$F(w, \lambda, \gamma) = w' S w + \lambda(1 - w' w) + \gamma w_1' w \quad (3.146)$$

と定式化できる。これを解くと、係数ベクトルは、第 2 番目の固有値 λ_2 に対応する固有ベクトル $w_2 = (w_{21}, w_{22})'$ として得られる。第 2 主成分は $Z_2 = w_2' y$ となり、第 2 主成分の分散は $s_{z_2}^2 = w_2' S w_2 = \lambda_2$ と、固有値によって与えられる。

以上の議論を一般化してまとめよう。いま、 p 次元のデータ $y_i = (y_{1,i}, y_{2,i}, \dots, y_{p,i})' (i=1, \dots, n)$ の平均と標本分散が、式 (3.143)、(3.144) によって与えられるとする（ただし、 $w = (w_1, w_2, \dots, w_p)'$ 、 $\bar{y} = (\bar{y}_1, \bar{y}_2, \dots, \bar{y}_p)'$ であり、 S は $p \times p$ の標本分散共分散行列）。主成分分析においては、対象の各変数のスケールが大きく異なる場合、変数を平均 0、分散 1 となるように基準化（平均成分を引き、標準偏差で除する）する必要がある（Everitt and Hothorn^[21]）。以下では、変数が基準化されているものと考えている。このとき、 $\bar{y} = (0, 0, \dots, 0)'$ が成り立ち、標本共分散行列 S は標本相関行列 R に等しくなる。具体的な主成分分析の流れは以下のとおりである。

まず、標本相関行列 R の固有値分解によって p 個の固有値を計算し、それらを大きい順に $\lambda_1, \dots, \lambda_p$ とする。このとき、第 k 主成分は、 k 番目の固有値に対応する固有ベクトル w_k を用いて、 $Z_k = w_k' y$ と与える

ことができる。したがって、係数 w'_k によって、 i 番目のデータは、 $Z_{k,i} = w'_k y_i$ に射影される。何番目までの固有値を用いるかという主成分数の選択基準にはさまざまなものがあるが、それらについては〔4〕の因子分析の節で説明する。

主成分分析において、 R の固有値は合成変数の分散を表した。したがって

$$\frac{\lambda_k}{\lambda_1 + \cdots + \lambda_p} \quad (3.147)$$

は、第 k 主成分に含まれている情報の量を示し、**寄与率** (contribution) と呼ばれる。また

$$\frac{\lambda_1 + \cdots + \lambda_k}{\lambda_1 + \cdots + \lambda_k + \cdots + \lambda_p} \quad (3.148)$$

は**累積寄与率** (cumulative contribution) と呼ばれる。累積寄与率は、しばしば簡便な主成分数の選択基準としても用いられる (例えば 80% など)。

最後に、主成分分析は、回帰分析における**多重共線性** (multi-collinearity) の問題の緩和策として用いることもできることを指摘しておく (例えば、堤²²⁾)。すなわち、説明変数行列を X としたとき、 $X'X$ を固有値分解し、ゼロに近い固有値に対応する成分を除いた後の固有ベクトルから成る行列を X に右から乗じたものを新たな説明変数とするアプローチであり、主成分回帰と呼ばれる。

〔4〕 因子 分 析

(1) **因子分析の考え方** 〔3〕の主成分分析は、 p 個の変数を固有ベクトルを重みとして総合化し、新たな変量 Z を「合成」する手法であった。一方で因子分析は、潜在的な因子を、観測変数に「分解」する手法である。例えば、節電行動の度合い (無: 0~頻繁に: 100 の間の連続変数とする)、公共交通利用頻度 (回/月) という 2 要素が観測されているとき、因子分析は、「環境意識」という因子 (潜在変数) をこれらの観測変数で説明するモデルである。因子は複数設定することができ、図 3.31 において、因子から観測変数への影響は、実線と点線の 2 種類で示されている。ここで、点線を削除することを考える




図 3.31 因子分析の考え方

と、環境意識は節電行動の度合いと公共交通利用頻度に影響を与え、防災意識は避難訓練参加の頻度 (回/年)、ハザードマップ認知の度合い (無: 0~非常に詳しく知っている: 100 の間の連続変数とする)、防災投資額 (円/世帯所得) に影響を与える。このように、なんらかの理論仮説や事前知識に基づいて事前に因果関係を想定し、その因果関係を検証するタイプの因子分析は、**確証的因子分析** (confirmatory factor analysis, **CFA**) と呼ばれる。それに対して、実線と点線を区別せずに、すべての観測変数がすべての因子の影響を受けているとするタイプの因子分析は、**探索的因子分析** (exploratory factor analysis, **EFA**) と呼ばれる。ここでは、このうち特に後者について説明を行う (無論、図 3.31 の例の場合は CFA のほうが妥当である)。

因子分析の流れの概略を、図 3.32 に示す。まず、因子数の決定およびモデルのパラメーター推定を行い、それに基づいて解釈を容易にするための因子の回転を行う。以下、これらを具体的に説明する。




図 3.32 因子分析の流れ

(2) **因子分析のモデル** 探索的因子分析 (EFA) の基本モデルを以下に示す。

$$y_{k,i} = a_{k1}f_{1,i} + \cdots + a_{km}f_{m,i} + \sigma_k u_{k,i} \quad (k=1, \cdots, p, i=1, \cdots, n) \quad (3.149)$$

ただし、 $y_{k,i}$ は個人 i の k 番目の属性を示す。ここで、主成分分析のときと同様に、 $y_{k,i}$ は基準化されていると仮定しよう。 $f_{j,i}$ は**共通因子** (common factor) と呼ばれる個人 i の j 番目の潜在変数であり、その係数 a_{kj} は**因子負荷** (factor loading) と呼ばれる。 $f_{j,i}$ の具体的な値は、**因子スコア** (factor score) と呼ばれる。上の式を行列表記すると

$$y_i = A f_i + D u_i \quad (i=1, \cdots, n) \quad (3.150)$$

が得られる。ただし、 $y_i = (y_{1,i}, \cdots, y_{p,i})'$ 、 A は、 a'_{kj} を 1 から p まで縦に並べたもの (因子負荷行列)、 f_i は $f_{1,i}$ から $f_{m,i}$ を縦に並べたもの、 D はその対角成分を σ_k で与える $p \times p$ 行列、 $u_i = (u_{1,i}, \cdots, u_{p,i})'$ である。また、 $f_i \sim N(0_m, I_m)$ 、 $u_i \sim N(0_p, I_p)$ が仮定される (ただし、 0_m はその成分を 0 で与える次元 m のベクトル、 I_m は次元 $m \times m$ の単位行列である)。このとき、 y_i は、平均ベクトルを 0_p 、分散共分散行列を

$AA' + D^2$ で与える多変量正規分布 $y_i \sim N(0_p, AA' + D^2)$ に従う。このとき、対数尤度関数は

$$\log p(y|\Sigma) = \text{const} - \frac{n}{2} \left[\text{tr}(\Sigma^{-1}R) - \ln|\Sigma^{-1}| \right] \quad (3.151)$$

で与えられる。最尤推定量を得るためには、 D と A に関して本式を最大化すればよい。具体的なアルゴリズムとしては、例えばEMアルゴリズムが用いられる(豊田²³⁾)。パラメーターの推定方法としては、ほかに最小二乗法、主因子法、ベイズ推定法などがある(市川²⁴⁾)。

各個人の因子スコアに興味がある場合、 $Y = (y_1, \dots, y_n)'$, $F = (F_1, \dots, F_n)'$, $U = (u_1, \dots, u_n)'$ とし、式(3.150)を

$$Y = FA' + UD \quad (3.152)$$

と書いたとき、例えばThurstoneの最小二乗法により、 $\hat{F} = YR^{-1}A$ と推定することができる。ただし、因子スコア行列 F は不定であり、ある因子負荷行列 A に対して、無数の組合せで存在することには注意が必要である。すなわち、 F は算出(calculate)することはできず、推定(estimate)しなければならない。

(3) 因子数の決定 因子数の決定のために現在までにさまざまなアプローチが提案されてきた。代表的なアプローチとしては、標本相関行列 R の固有値に基づくものと、適合度指標を用いるものが挙げられる。

前者のうち、その単純性から広く用いられているアプローチは、カイザー・ガットマン基準(Kaiser-Guttman criterion)を用いるものである。本基準は、標本相関行列 R の1より大きい固有値の数を因子数とする簡便なものである。スクリーテスト(scree test)は、 R の固有値を降順に並べてプロットした折れ線グラフに基づき、固有値の大きさが急激に減少する直前までの固有値の個数を用いるというアプローチである。平行分析(parallel analysis)は、データと同じサイズの乱数データを作成し、 R の固有値と乱数データの相関行列の固有値との比較によって因子数を決定する方法である(豊田²³⁾)。他のアプローチについては、市川²⁴⁾や豊田²³⁾を参照されたい。

適合度指標に基づくアプローチには、尤度比検定を用いるものや、情報量規準に基づくものがある。後者では、次式に基づくAICやBICを最小化するような因子数を求める。

$$AIC = \chi^2 - 2 \times df \quad (3.153)$$

$$BIC = \chi^2 - \ln(n) \times df \quad (3.154)$$

ここで

$$\chi^2 = (n-1) \{ \text{tr}(\hat{\Sigma}^{-1}R) - \ln|\hat{\Sigma}^{-1}R| - p \} \quad (3.155)$$

$$df = \frac{p(p+1)}{2} - \left[pm + p - \frac{m(m-1)}{2} \right] \quad (3.156)$$

(4) 因子数の回転 因子数として、2因子以上を想定した場合、結果の解釈上の理由から、因子(負荷行列)の回転を行うことが一般的である。すなわち、各観測変数が多くの因子から影響を受ける場合、因子の解釈がしにくいため、各観測変数が少数の因子からのみ影響を受けるように因子負荷行列を変換(回転)する。

因子負荷行列の回転に当たっては、因子負荷行列の複雑さが小さくなることを目標とする。ここで、複雑さは、 A の回転後の行列 Λ の各列における0でない成分数によって定義でき、次式

$$\Lambda = \begin{bmatrix} * & * & * & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & * & * & * & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & * & * \end{bmatrix} \quad (3.157)$$

のように9個の観測変数がそれぞれ一つの因子からのみ影響を受けているような状況(複雑さが1)は、完全クラスター解(perfect cluster solution)と呼ばれる(*は0でない実数)。回転は、このような単純性を志向して行われる(市川²⁴⁾)。

因子の回転には、直交回転と斜交回転がある。直交回転は、因子間の相関を許容せず、因子が相関を持たないという制約下で回転を行う。一方で斜交回転は、このような制約を置かない。例えば、図3.15の例でいえば、「環境意識」と「防災意識」に相関があることを許容しないのが直交回転である。実証研究では、斜交回転が妥当な場合が多いであろう。

直交回転は、適当な回転行列 T を A に右から乗じることによって行う。回転後の因子負荷行列を Λ と呼べば

$$\Lambda = AT \quad (3.158)$$

によって与えられる。一方、斜交回転の場合は

$$\Lambda = A(T'^{-1}) \quad (3.159)$$

となる(豊田²³⁾)。

因子負荷行列の回転は、基本的には Λ が単純構造となるような T を探索する形で行う。具体的には、直交回転の場合は、 $TT' = I$ 、斜交回転の場合は、 $\text{diag}(TT') = I$ の条件下で、単純構造の指標 $Q(\Lambda)$ を最大化(または最小化)する。例えば、直交回転の基準としては、バリマックス基準が有名である。

$$Q = \sum_{k=1}^m \sum_{j=1}^m \lambda_{kj}^4 - \frac{1}{p} \sum_{j=1}^m \left(\sum_{k=1}^p \lambda_{kj}^2 \right)^2 \quad (3.160)$$

ただし、 λ_{jk} は回転後の因子負荷である。また、斜交

回転には、オブリミン基準

$$Q = \sum_{j=1}^m \sum_{i \neq j}^m \left\{ \sum_{k=1}^h \lambda_{kj}^2 \lambda_{ki}^2 - \frac{w}{p} \left(\sum_{k=1}^h \lambda_{kj}^2 \right) \left(\sum_{k=1}^h \lambda_{ki}^2 \right) \right\} \quad (3.161)$$

などがある (w は 0, 1/2, 1 などを与える重み)。詳細については、豊田²³⁾などを参照されたい。

以上をまとめると、因子分析は、まず大きく確証的因子分析と探索的因子分析に分けられる。不定性の問題により、因子分析の結果は因子スコアの推定法、因子回転の方法に依存し、また、パラメーター推定法や因子数の決定法、回転の種類 (直交, 斜交) によっても結果は大きく変わり得る。したがって因子分析を実施した際には、これらを適切に報告する必要がある。

(瀬谷 創)

〔5〕判別分析

判別分析 (discriminant analysis) とは、標本の属性情報を基に各標本がどの 2 群 (カテゴリー) に所属するかを推定する手法である。例えば航空写真の各ピクセルにおける三原色 (赤色, 緑色, 青色) を用いて判別分析を行うことで、各ピクセルが緑地か否かを判別できる。以降ではこの例のような 2 群の判別を例に議論を進める。

判別分析では**判別関数** (discriminant function) と呼ばれる関数の符合を基に、各標本の群を推定する。例えば、基本的な判別分析として知られる**線形判別分析** (linear discriminant analysis) の判別関数は次式で与えられ、その実現値が正の場合は群 1、負の場合は群 2、のように割り振られる (図 3.33 参照)。




図 3.33 線形判別分析のイメージ

$$y_i = \sum_p x_{i,p} \beta_p \quad (3.162)$$

ここで $x_{i,p}$ は標本 i の p 番目の説明変数、 β_p はその係数である。判別関数の実現値 y_i は**判別得点** (discriminant score) と呼ばれる。

β_p は次式で示されるフィッシャーの判別基準 (Fisher's linear discriminant) J を最大化することで推定される。

$$J = \frac{S_{\text{between}}^2}{S_{\text{within}}^2} \quad (3.163)$$

$$S_{\text{between}}^2 = (\bar{y}^{(1)} - \bar{y}^{(2)})^2$$

$$S_{\text{within}}^2 = \sum_{i \in n^{(1)}} (y_i - \bar{y}^{(1)})^2 + \sum_{i \in n^{(2)}} (y_i - \bar{y}^{(2)})^2$$

$\bar{y}^{(1)}$ ($\bar{y}^{(2)}$) は群 1 (群 2) に判別された標本についての判別得点 y_i の平均値、 $\bar{y}$ は y_i の平均値である。また S_{between}^2 は群間の y_i のばらつき (群間変動)、 S_{within}^2 は群内のばらつき (群内変動) を表す。 J を最大化することで、群間の分離度を表す S_{between}^2 を大きくするとともに (図 3.30 参照)、群内の変動を表す S_{within}^2 を小さくする。なお、 S_{within}^2 を小さくすることで判別の精度が大きく向上することが一般に知られている。

J を最小化する β_p を特定するために式 (3.162) を代入した J を β_p で偏微分すると次式が得られる。

$$\begin{bmatrix} s_{1,1} & s_{1,2} & \cdots & s_{1,p} \\ s_{2,1} & s_{2,2} & \cdots & s_{2,p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p,1} & s_{p,2} & \cdots & s_{p,p} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix} = \begin{bmatrix} \bar{x}_1^{(1)} - \bar{x}_1^{(2)} \\ \bar{x}_2^{(1)} - \bar{x}_2^{(2)} \\ \vdots \\ \bar{x}_p^{(1)} - \bar{x}_p^{(2)} \end{bmatrix} \quad (3.164)$$

$$s_{p,q} = \frac{1}{n^{(1)} + n^{(2)} - 2} \left(\sum_{i \in n^{(1)}} (x_{i,p}^{(1)} - \bar{x}_p^{(1)}) (x_{i,q}^{(1)} - \bar{x}_q^{(1)}) + \sum_{i \in n^{(2)}} (x_{i,p}^{(2)} - \bar{x}_p^{(2)}) (x_{i,q}^{(2)} - \bar{x}_q^{(2)}) \right)$$

ここで $\bar{x}_p^{(q)}$ は群 q に判別された標本についての $x_{i,p}$ の平均値である。式 (3.164) を $S\beta = \bar{\mathbf{x}}^{(1)} - \bar{\mathbf{x}}^{(2)}$ と表現すると、 η^2 を最小化する係数ベクトル β の推定値は次式で与えられることがわかる。

$$\hat{\beta} = S^{-1} (\bar{\mathbf{x}}^{(1)} - \bar{\mathbf{x}}^{(2)}) \quad (3.165)$$

これから推定された係数を式 (3.164) に代入することで線形判別関数が与えられ、この関数を用いて新たな標本の判別が可能となる。

以上では線形の判別関数を仮定したが、実際には線形の関数ですべての標本を正しく判別することは不可能である場合が多い。近年では非線形の判別関数を用いる手法や、ニューラルネットワーク (neural network) やサポートベクターマシン (support vector machine) といったより柔軟な判別手法が**パターン認識** (pattern recognition) の分野で活発に議論されており、例えば画像認識や音声認識などへの幅広い応用が見られる。それらの手法についてはビショップ²⁵⁾に詳しい。

(村上大輔)

〔6〕クラスター分析

分析の対象とするデータにいくつかの特徴のものが混在している際、それらを群 (グループ) に分類したり、群に分類した上で各群についてさらに詳しく分析したりする場合がある。図 3.34 の●■▲で示した点は、ある地域の地区ごとの (昼間人口, 夜間人口) を

座標軸上にプロットしたものとする。これらの地区は、例えば、 C_1 は夜間人口に対して昼間人口が少ないベッドタウン型の地区、逆に C_3 は昼間人口が多いのに対して夜間人口は少ない業務都心型の地区、 C_2 は昼間人口と夜間人口があまり変化しないそのどちらでもない地区に分類することができそうである。また、それ以外にも、さまざまな分類が考えられそうである。

判別 (discrimination) が、興味の対象となるデータがある群に属するときに対象がどの群に所属するかを推測するのに対し、分類 (classification) は、なんらかの類似性 (あるいは非類似性/差異性) に基づいてデータをいくつかの群 (クラスター, cluster) に分けることをいう。〔5〕で説明した判別分析が**教師ありの分類** (supervised classification) 法と呼ばれるのに対し、ここで説明するクラスター分析 (あるいはクラスター化法, クラスター生成法) は**教師なしの分類**

(unsupervised classification) 法と呼ばれる。(ここでの「教師」は「正解」の意味である)。教師データがある場合には、いかにそれが精度良く再現できるかで手法の善し悪しを判断することができるが、教師データがない場合には、得られた結果が直感に整合的であるとか解釈が容易であるといった主観によって手法の善し悪しを判断せざるを得ない。そのため、多くの研究分野において扱うデータの特性や分類の目的等に応じてさまざまな手法が提案され、今日に至っている。『統計学辞典』¹³⁾によれば、「**クラスター分析** (cluster analysis) とはデータを分類する手法のかなり漠然とした総称であり、ある特定の手法が存在するわけではない」。したがって、ここで紹介するクラスター分析も代表的な一例に過ぎないことを断っておく。

データをクラスターに分ける (クラスタリングする) ためには、扱うデータの種類や目的などに応じて、類似度あるいは非類似度を定義する必要がある。

最も簡単でよく用いられるのは、非類似度を対象 i, j の属性ベクトル x_i, x_j のユークリッド距離 (Euclidean distance) で定義する方法であろう。

N 個の対象から成るデータに対し、初めに、1 個の対象だけを含む N 個のクラスター $C_1, C_2, \dots, C_N$ を設定する。クラスター間の非類似度 (距離 $d(C_i, C_j)$) を定義し、最も距離が小さいクラスターを併合する。併合されたクラスターとそれ以外のすべてのクラスターとの間で同様に距離を計算し、同様の併合作業を決められた回数あるいはクラスターが一つになるまで





図 3.34 クラスターの例



(a)



(b)

図 3.35 階層的クラスター分析の結果の例

逐次統合していく。このような方法は「階層的クラスター分析」と呼ばれる。それは、図 3.35 (a) に示す樹形図 (dendrogram) が示すように、階層構造を作るような分類手法であるためである。代表的な手法はウォード (Wald) 法であり、クラスターの重心まわりの偏差平方和を最小にするように他のクラスターを併合する方法である (例えば、村山・駒木²⁶⁾)。この方法は、鎖状効果 (chaining effects) と呼ばれる連鎖的な分類 (大きなクラスターへの吸収) が起こりにくく、また、球形のクラスターを作りやすいことから解釈が容易であるため、比較的良好に用いられている。

茨城県 44 市区町村の 5 歳階級別人口構成比データを対象に、ウォード法を用いた階層的クラスター分析を行った分析例を図 3.35 に示す。図 3.35 (b) は 4 クラスターに分けたときの地域区分を地図に示したものである。比較的高齢者の多い県北地域とつくば市などの若い世代が多い県南地域が区分されているなど、おおむね直観に沿った結果といえるだろう。

階層的クラスター分析に対し、図 3.34 のように、階層を持たないようにクラスター化する手法もある。最も代表的なものは、 k -means (k -平均) 法と呼ばれる手法であり、クラスターの代表点を c_i (通常は C_i に属する各データの算術平均ベクトル) とするとき、あらかじめ決めたクラスターの個数 k に対して、以下の最小化問題を解くものである。

$$\min \sum_i \sum_{x \in C_i} d(x, c_i) \quad (3.166)$$

判別分析同様、機械学習の分野でもさまざまなクラスター分析の手法が開発されている (例えば、ピショップ²⁵⁾ 参照)。土木計画学で扱うことの多い地理空間データでは、クラスターが地理空間上で連担することが解釈の容易さから求められることもあり、そのような手法の開発も進んでいる。

(吉田崇紘, 堤 盛人)

[7] 離散選択モデル

個人が限られた選択肢の中から一つを選ぶ事象を記述する際に離散選択モデルが用いられる。最も単純な離散選択は、ある行動をするかしないかといった 1 か 0 の二項変数で置き換えることができ、二項選択と呼ばれる。被説明変数のとり得る値が 1 か 0 の 2 項では二項選択モデル、3 項以上では多項選択モデルとして区別されるが、ここでは二項選択モデルについて説明する。多項選択モデルに関する詳細は I 編 4 章などを参照されたい。

被説明変数が質的変数である場合、[2] で説明した線形回帰モデルを用いた分析は望ましくない。 $y = (y_1, y_2, \dots, y_n)$ が二項変数のときを例にとると、線

形回帰モデル $y_i = X_i\beta + \varepsilon_i$ は $y_i = 1$ となる確率 $p_i = \Pr(y_i = 1 | X_i)$ をモデル化したものとなり、 β_k は X_k が 1 単位変化したときの $y_i = 1$ となる確率の変化を表していることと捉えることができる (線形確率モデルと呼ばれる)。したがって、推定されたパラメーターを基に統計的推論を行うことはある程度可能である。しかしながら誤差項は、 $y_i = 1$ のとき $\varepsilon_i = 1 - X_i\beta$ 、 $y_i = 0$ のとき $\varepsilon_i = -X_i\beta$ 、とそれぞれ確率 p_i と $1 - p_i$ で二つの可能な値をとるため、その分散は $\text{Var}(\varepsilon_i) = X_i\beta(1 - X_i\beta)$ となり、不均一分散となる (Greene²⁷⁾)。さらに、予測確率は誤差項に制約を課さない限り $0 \leq \hat{p}_i = X_i\hat{\beta} \leq 1$ とはならないため、得られる結果は解釈が困難となるおそれがある。一方で、離散選択モデルでは予測確率がつねに 0 から 1 の間をとる特徴を有している。

最も基本的な離散選択モデルであるロジットモデル (logit model) は、選択確率の式が閉形式であり解釈が容易であることから広く使用されている。なお、ロジットモデルとロジスティック回帰モデルは同じモデルであり、プロビットのアナロジーとして Berkson²⁸⁾ がロジットという単語を用いたのが始まりとされている (Cramer²⁹⁾)。

条件付き確率の対数オッズ比が X の線形和で表されると仮定すると

$$\log \frac{\Pr(y_i = 1 | X_i)}{\Pr(y_i = 0 | X_i)} = \log \frac{p_i}{1 - p_i} = X_i\beta \quad (3.167)$$

となる。 $\text{logit}(z) = \log[z/(1-z)]$ はロジット関数と呼ばれる (ただし $0 \leq z \leq 1$)。また、条件付き確率をロジスティック分布の分布関数 (標準シグモイド関数) $F(z) = \exp(z) / [1 + \exp(z)]$ を用いて

$$p_i = F(X_i\beta) = \frac{\exp(X_i\beta)}{1 + \exp(X_i\beta)} \quad (3.168)$$

と表すこともでき、 $0 \leq p_i \leq 1$ となることがわかる。ロジット関数と標準シグモイド関数は互いに逆関数であるから、式 (3.167) と式 (3.168) はどちらも同じロジットモデルである。ロジットモデルの対数尤度関数は、ベルヌーイ試行における成功確率を式 (3.168) と置くことで

$$\ln L = \sum_{i=1}^n \left\{ y_i \log F(X_i\beta) + (1 - y_i) \log (1 - F(X_i\beta)) \right\} \quad (3.169)$$

となるため、一般化線形モデルの枠組みで反復重み付き最小二乗法 (iterative reweighted least squares method) を用いてパラメーター推定を行うのが一般的である。

一方、条件付き確率を標準正規分布の分布関数

$\Phi(z)$ を用いて

$$p_i = \Phi(X_i\beta) = \int_{-\infty}^{\beta x} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{t^2}{2}\right) dt \quad (3.170)$$

と仮定したものが**プロビットモデル** (probit model) である。したがって、ロジットモデルとプロビットモデルの違いは、条件付き確率に関する分布関数の仮定にあることがわかる。プロビットモデルの対数尤度関数は、式 (3.169) の $F(X_i\beta)$ を $\Phi(X_i\beta)$ に置き換えたものであり、関数の中にインテグラルが含まれ複雑になることから、計算機性能が低かった一昔前は計算の簡便さからロジットモデルの方が好まれていた。

ロジスティック分布と標準正規分布の双方の分布関数は非常に似ており、ロジットモデルとプロビットモデルで得た結果は似る傾向がある。しかし、ロジスティック分布の分布関数の裾は $x \rightarrow \infty$ で漸近的に $\exp(-x)$ に減衰するのに対して、標準正規分布のそれは $x \rightarrow \infty$ で漸的に $\exp(-x^2)$ に減衰することから、プロビットモデルの方が外れ値に対して敏感であるという特徴がある (ビショップ²⁵⁾)。

さて、わが国では土木計画学の分野において「非集計ロジット」、「集計ロジット」という言葉が散見される (例えば、土木学会土木計画学研究委員会³⁰⁾)。これは、分析の際に利用するデータが個票データ $y_i (i = 1, \dots, n)$ か、なんらかの単位 I (例えばゾーン等) で集計されたデータ $S_I = \sum_{i \in I} y_i$ かで区別するために用いられる独自の用語である。集計量で与えられる S_I は二項変数ではないが、これを $P_I = S_I / N_I$ (N_I は $y_{i \in I}$ の総数) と比率データに変換し、ロジットモデルにおける選択確率とみなしてモデルを推定することが可能である。簡便な方法として、式 (3.167) のモデルに対して平均 0、分散 $\sigma_I^2 = 1 / [N_I P_I (1 - P_I)]$ の誤差項 u_i を仮定し、重み付き最小二乗法 (最小カイ二乗法) を用いる方法がある。これは Berkson²⁸⁾ によって提案され Theil³¹⁾ によって多項ロジットモデルへと拡張された手法である。logit(P_I) / σ_I を X_I / σ_I で回帰するのみであり、計算が非常に簡便であるのが特徴だが、近年の計算機性能の向上によりこの方法の利点はほぼ失われている (Cameron and Trivedi³²⁾)。

(爲季和樹)

引用・参考文献 (3.2 節)

- 1) 東京大学教養学部統計学教室：人文・社会科学の統計学 (基礎統計学)，東京大学出版会 (1994)
- 2) 瀬谷 創，堤 盛人：空間統計学，朝倉書店 (2014)
- 3) 松原 望，美添泰人，岩崎 学，金 明哲，竹村和久，林 文，山岡和枝：統計応用の百科事典，

- pp.94~95，丸善出版 (2011)
- 4) 蓑谷千風彦：統計分布ハンドブック，朝倉書店 (2010)
- 5) 蓑谷千風彦，縄田和満，和合 肇：計量経済学ハンドブック，朝倉書店 (2008)
- 6) 安道知寛：ベイズ統計モデリング (統計ライブラリー)，朝倉書店 (2010)
- 7) 東京大学教養学部統計学教室：統計学入門 (基礎統計学)，東京大学出版会 (1991)
- 8) 武藤真介：統計解析ハンドブック (普及版)，p.476，朝倉書店 (2010)
- 9) 豊田秀樹：共分散構造分析 入門編—構造方程式モデリング (統計ライブラリー)，朝倉書店 (1998)
- 10) 山本 拓：経済の時系列分析，創文社 (1988)
- 11) 沖本竜義：経済・ファイナンスデータの計量時系列分析，朝倉書店 (2010)
- 12) チェン・シャオ：ミクロ計量経済学の方法 パネル・データ分析 (国友直人訳)，東洋経済新報社 (2007)
- 13) 竹内 啓編集委員代表：統計学辞典，東洋経済新報社 (1989)
- 14) 蓑谷千風彦：線形回帰分析，p.20，pp.240~241，朝倉書店 (2015)
- 15) 浅野 哲，中村二郎：計量経済学 (第2版)，6章，有斐閣 (2009)
- 16) 小西貞則，北川源四郎：情報量規準，朝倉書店 (2004)
- 17) 蓑谷千風彦：数理統計ハンドブック，p.827，みみずく舎 (2009)
- 18) 奥村 誠：土木計画学 (土木・環境系コアテキストシリーズ E-1)，p.23，コロナ社 (2014)
- 19) アネット・ドブソン (田中 豊，森川敏彦，山中竹春，富田 誠訳)：一般化線形モデル入門 (原著第2版)，共立出版 (2008)
- 20) 小西貞則：多変量解析入門 (第3刷)，p.228，岩波書店 (2014)
- 21) Everitt, B. and Hothorn, T.: An Introduction to Applied Multivariate Analysis with R, Springer, New York (2011)
- 22) 堤 盛人：地価の回帰分析 (土木学会応用力学委員会逆問題小委員会編『土木工学における逆問題入門』(第6章第4節)，土木学会 (2000)
- 23) 豊田秀樹：因子分析入門，東京図書 (2012)
- 24) 市川雅教：因子分析，p.108，朝倉書店 (2010)
- 25) C.M. ビショップ (元田 浩，栗田多喜夫，樋口知之，松本裕治，村田 昇監訳)：パターン認識と機械学習 上・下，丸善出版 (2012)
- 26) 村山祐司・駒木伸比古：地域分析—データ入手・解析・評価，古今書院 (2013)
- 27) Greene, W.H.: Econometric Analysis 7th edition, Prentice Hall, p.684 (2012)
- 28) Berkson, J.: Maximum likelihood and minimum chi-square estimations of the logistic function, Journal of the American Statistical Association, 50, pp.130~161 (1955)
- 29) Cramer, J.S.: The early origins of the logit model,

- Studies in History and Philosophy of Science Part C : Studies in History and Philosophy of Biological and Biomedical Sciences, 35, pp.613~626 (2004)
- 30) 土木学会土木計画学研究委員会：非集計モデルの理論と実際，土木学会（1995）
- 31) Theil, H. : A multinomial extension of the linear logit model, International Economic Review, 10, pp.251~259 (1969)
- 32) Cameron, A.C. and Trivedi, P.K. : Microeconometrics methods and applications, Cambridge University Press, pp.480~481 (2005)